第1章 数据思维

章节导航

- 了解数据思维、数据素养、数据技能和数字领导力。
- 了解并学会分析新兴技术成熟度曲线。
- 理解数据工程的基本流程。
- 了解数据科学在各个行业的应用案例。

本章知识导图

1.1 数据思维无处不在

数据有价，它既是资产，又是生产要素，在数字时代，这是人们的基本共识。数据思维是将工作对象表征作为数据，运用数据工程与技术，开展算法研究，综合实施应用方案，从而获得有效成果的一种解决问题的思考方式。数据思维主要讨论数据资源、数字技术(新一代信息技术)、数据工程、数据科学、数据驱动的智能决策等。目前数据思维已形成了完备的学科体系和生态。

在经济与产业形态上，数据思维催生了新的经济范式，也就是数字经济。2021年，国家统计局发布的《数字经济及其核心产业统计分类(2021)》指出："数字经济是指以数据资源作为关键生产要素、以现代信息网络作为重要载体、以信息通信技术的有效使用作为效率提升和经济结构优化的重要推动力的一系列经济活动。"这一定义明确了数字经济、数据资源、数字技术之间的关系，进而推动了数据思维在社会经济活动中的演化进程。

从数据资源看，数据的特征是数量巨大、类型繁多、价值密度低、产生和流通速度快，因此称为大数据。从数字技术看，进入新工业革命时代后，新兴技术以极短的时间窗口迭代推进，云计算、大数据、人工智能(artificial intelligence，AI)、区块链、元宇宙等技术快速走向市场。从数据工程看，产业市场的旺盛需求驱动技术公司的工程化落地，形成了可重复使用的工具和解决方案。从数据科学看，架构完整的交叉学科体系已经完成，涵盖数字素养、数字技能和数字领导力3个层次，相应地描绘了通识、技能和顶层设计的知识版图。最终，以数据为决策依据，运用数字技术决策的数据思维得以形成。

下面用两个案例简要说明数据思维。这两个案例分别使用了统计学方法、机器学习(machine learning，ML)方法作为数据分析方法。

案例1-1 本案例为数据统计案例，反映了如何用数据说话。以下分别列出数据(算据)、模型、专家知识(结论)。

• 数据：一组脱敏后的公民个人数据，覆盖 1 000 多万人，大概占全国人口的 1%，信息包括姓氏、年龄、籍贯城市、现居城市等。

• 模型：使用上述数据的信息，设计和定义以下指标。

普遍指数＝各姓氏人口数量；

抱团指数＝各姓氏在各省分布的基尼系数；

奔波指数＝各姓氏人均迁徙距离(其中，迁徙距离为户籍地所在地级市与现居住地所在地级市的距离)；

……

• 专家知识：对上述指标(模型的计算结果)总结规律，给出建议，并持续完善模型。

案例 1-2 厦门大学“一带一路”研究院开展数字丝路研究，也就是面向“一带一路”沿线国家和地区，讨论如何建立数字经济创新服务平台(称为“数字丝路”创新服务平台)，如图 1-1 所示。该平台的目标是汇聚数字经济的政策、产业、企业、技术、空间载体等信息，形成一体化数据库和知识库，应用推荐算法、智能问答等技术，实现产业与政策的精准匹配。这是一个用数据服务数字经济产业的案例。

总结上述两个案例，可以发现数据、算法(指标、模型)、专家知识三者形成了数据决策的基本要素，并由超级计算机提供算力支持，最终形成一套在具体场景下，算据、算法、算力协同工作的科学决策模型，为数据思维落地提供了工程保障。

图 1-1 “数字丝路”创新服务平台

1.2 新兴技术蓬勃发展

新一代信息技术、数字技术、新兴技术等是一组不同视角下的概念。新一代信息技术的概念可见于《国务院关于加快培育和发展战略性新兴产业的决定》(国发〔2010〕32 号)，包括网络基础设施、新一代移动通信、下一代互联网、物联网、云计算、集成电路、新型显示、高端软件、高端服务器、信息服务、数字虚拟等技术。数字技术的概念较为宽泛，是指将各种物理信息(包括数值、文本、声音、视频等模态)转化为计算机可以识别、加工、存储、传输、分析和应用的技术，包括大数据、云计算、人工智能、物联网、区块链和 5G 技术等。新兴技术是受公众或市场关注的新技术，可由新兴技术成熟度曲线表征，该曲线由 Gartner(高德纳)公司每年发布。新兴技术的发展分为以下几个阶段。

(1)技术萌芽期(technology trigger)，又称感知期，在此阶段，市场对新兴技术产品和概念开始有感知，并且表现出兴趣。

(2)期望膨胀期(peak of inflated expectations)，又称泡沫期，在此阶段，市场一拥而上，纷纷讨论、尝试新兴技术。

(3)泡沫破裂谷底期(trough of disillusionment)，又称幻想破灭期，在此阶段，市场放弃对新兴技术的过度预期，开始面对严峻的现实。

(4)稳步爬升复苏期(slope of enlightenment)，又称恢复期，在此阶段，市场开始反思，并从实际出发考虑新兴技术的价值。

(5)生产成熟期(plateau of productivity)，又称高原期，在此阶段，市场大范围接受新兴技术。

图 1-2 是 Gartner 公司 2023 年 8 月发布的新兴技术成熟度曲线，该曲线描述了数字技术的市场反应情况。当一种技术成熟的时候，它就会得到广泛的商业化应用。读懂新兴技术成熟度曲线，就可以寻找某一种技术所处的发展阶段，这有助于读者对业界做出准确的判断，从而做出前瞻性的市场规划。

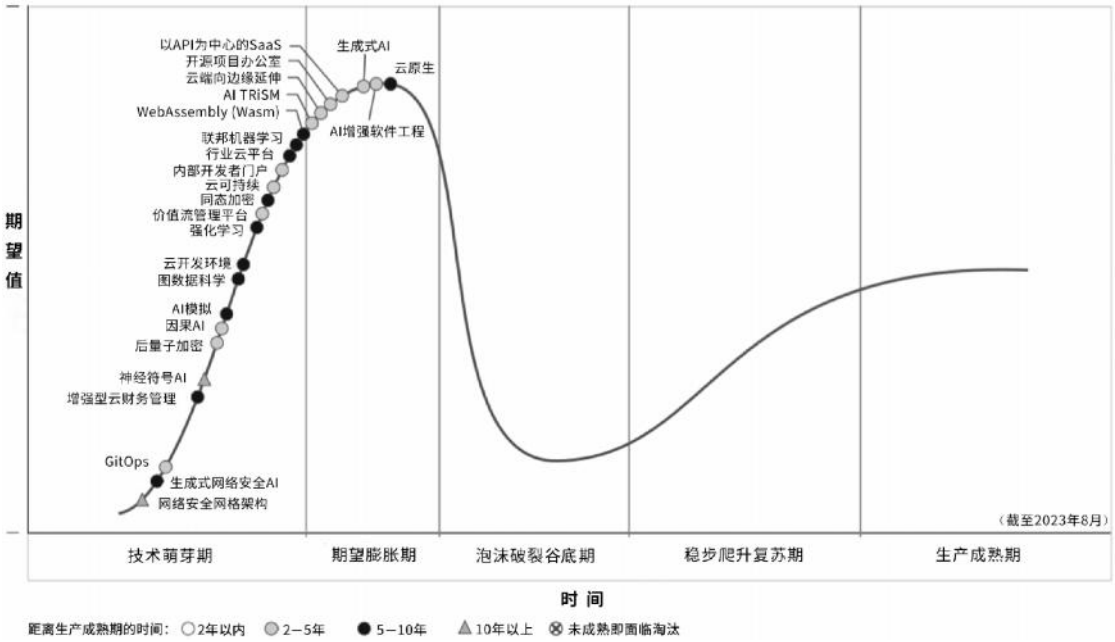

图 1-2　新兴技术成熟度曲线

数字技术的发展使得大数据和人工智能的版图日渐饱满。知名的早期技术类风险投资机构 FirstMark 动态维护了一份机器学习、人工智能与大数据的全景(Machine Learning，Artificial Intelligence & Data Landscape，MAD Landscape)，其中较为完备地展现了数字技术的代表企业。图 1-3 是 2023 年的全景示意图，读者可以访问官方网站获得其清晰版和互动版。从全景示意图中可以发现，数字技术及产业版图由数据资源与接口(Data Sources & APIs)、数据与人工智能咨询(Data & AI Consulting)、开源基础设施(Open Source Infrastructure)、基础设施(Infrastructure)、数据分析(Analytics)、机器学习与人工智能(Machine Learning & Artificial Intelligence)、企业应用(Applications-Enterprise)等组成。

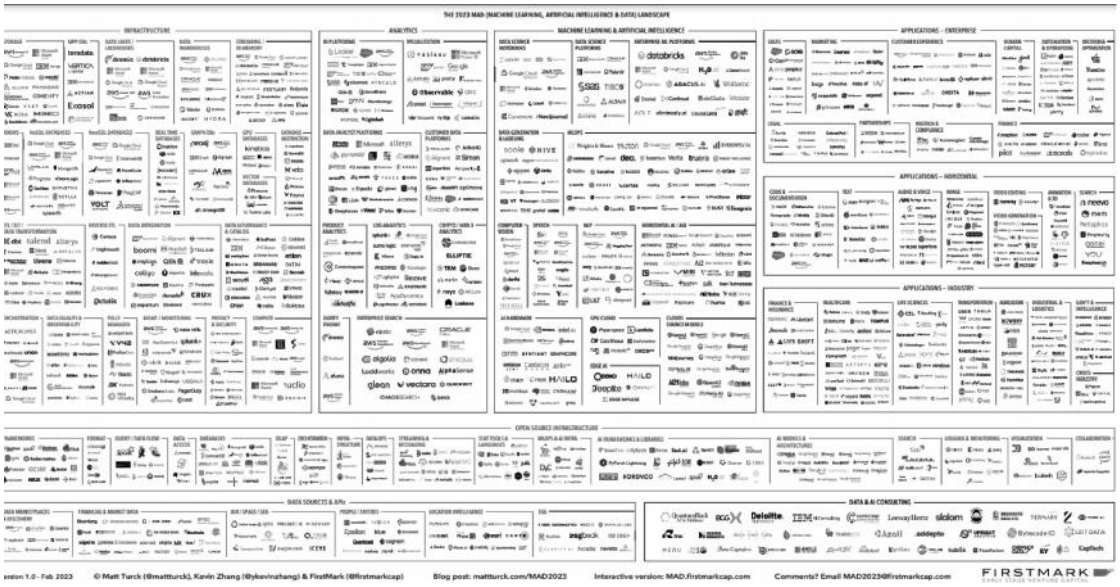

图 1-3　机器学习、人工智能与大数据的全景示意图(2023 年)①

1.3 数据工程的基本流程

数据工程以数据为工作对象，按照数据生命周期有序开展，形成解决问题的闭环。一个完整的数据工程的基本流程一般如图 1-4 所示，包括数据采集与整理、数据组织与存储、数据挖掘与分析、数据应用与决策 4 个阶段，各阶段迭代推进，持续不断地产生和应用数据。

数据工程流程简介

下面以网页数据分析为例来说明上述流程。

1. 数据采集与整理

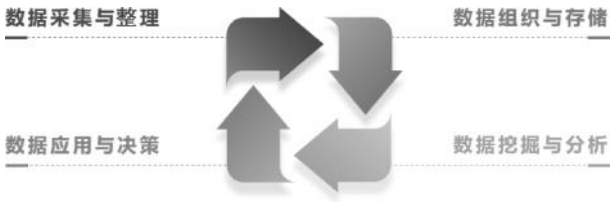

图 1-4　一个完整的数据工程的基本流程

首先，如何解决研究对象中的数据采集与整理问题？网页文件用 HTML (hypertext markup language，超文本标记语言)代码标记，由内容和样式两部分组成。内容是网页中的文本与多媒体，而样式控制网页的格式。目标分析网站以厦门大学研究生院官网为例，登录该网站，显示如图 1-5 所示的页面。要获得网页的内容和样式，可以在网页中右击，在弹出的快捷菜单中选择“显示网页源代码”命令，就可以得到数据文件，从而完成手动作业方式下的数据采集。

网页文件属于半结构化数据，被放在很规整的一对对标签中。例如，一个超链接以＜a＞开头，以＜/a＞结束；文字列表则放在＜li＞＜/li＞标签对中。网页文件的 HTML 源

①此图的清晰版可在 https://mad.firstmark.com/查看。

代码和半结构化数据示例分别如图 1-6 和图 1-7 所示。

图 1-5　厦门大学研究生院官网的页面

```
<div class="customer">
 <div class="customer-icon">
  <a href="http://gs.xmu.edu.cn/student" target="_blank"><em class="fa fa-user-graduate"></em></a>
 </div>
 <div class="customer-title">
  <a href="http://gs.xmu.edu.cn/student" target="_blank">学生</a>
 </div>
</div>
<div class="customer">
 <div class="customer-icon">
  <a href="http://gs.xmu.edu.cn/teacher" target="_blank"><em class="fa fa-user-tie"></em></a>
 </div>
 <div class="customer-title">
  <a href="http://gs.xmu.edu.cn/teacher" target="_blank">老师</a>
 </div>
```

图 1-6　网页文件的 HTML 源代码

```
 </li>
 <li class="has-sub"><a href="jgjx/jggk1.htm">机构介绍</a>
            <ul>
                                    <li><a href="jgjx/jggk1.htm">机构概况</a>
                                    </li>
                                    <li><a href="jgjx/gzfg.htm">工作分工</a>
                                    </li>
                                    <li><a href="jgjx/jcsj.htm">基础数据</a>
                                    </li>
            </ul>
 </li>
```

图 1-7　半结构化数据示例

本节的研究对象(半结构化数据)也是有规律可循的，它的结构介于结构化数据和非结构化数据之间，这就为数据的自动化采集与整理提供了条件。一般来说，在 Python 语言的第一堂课中，都会介绍如何采用 Python 语言完成一个网页爬虫。网页爬虫实现数据的自动化采集，实现 HTML 源代码的下载、保存、解析、存储。解析的基本原理就是找到标签对，理解标签对的含义，取出标签对中的内容。

2. 数据组织与存储

那么应如何解决数据的存储呢？数据库中包括各种各样的存储模型，如关系型、文档型、键值对(key-value)型、流式存储型、网络型、图型等。DB-ENGINES 网站①对数据库管理系统根据其流行度进行了排名，并分别列举了数据库管理系统所采用的数据库模型等基本信息。关系型数据库，如 Oracle、MySQL、SQL Server，是当前非常流行的数据库，使用二维表及联系来刻画数据存储；文档型数据库，如 MongoDB，用来存储文本等非结构数据；键值对型数据库，如 Redis，将数据存在文本文件中，给定一个键，对应地给出一个值。此外，微博、抖音等的视频流文件是使用流式存储型数据库保存的。

3. 数据挖掘与分析

数据组织与存储的下一步是进行数据挖掘与分析。数据挖掘，又称知识发现，是从大量的数据集中发现模式和其他有价值信息的过程。数据分析是通过对数据的整理、分析，发现数据背后的规律和趋势，为决策提供依据的过程。数据分析可以分为两个阶段：描述性分析和预测性分析。

描述性分析是指对数据的现状进行描述，找出数据的整体特征和规律。描述性分析的常见方法包括以下 3 种。

(1)统计量分析：求最大值、最小值、平均值、中位数、众数等。

(2)图表分析：用图表直观地展示数据的特点。

(3)分类分析：将数据按照某一特征进行分类，分析不同类别数据之间的差异。

预测性分析是指对数据的未来趋势进行预测。预测性分析的常见方法包括以下 3 种。

(1)回归分析：根据历史数据预测未来数据。

(2)时间序列分析：根据时间序列数据预测未来趋势。

(3)机器学习：使用机器学习算法从数据中学习规律，进行预测。

以银行客户资产总值为例，描述性分析可以根据客户的基本信息、账户存取记录、贷款信息、理财产品购买记录等数据，计算出客户的资产总值。描述性分析可以帮助银行了解客户的资产状况，为营销和产品开发提供参考。如果银行希望预测客户的未来资产状况，可以使用预测性分析。例如，可以使用回归分析，根据客户的历史收入、年龄、家庭情况等特征预测客户的未来收入，再根据未来收入预测客户的未来资产状况。

4. 数据应用与决策

数据挖掘与分析完成之后，下一步就是数据应用与决策。数据应用是指将数据分析的结果转化为实际的价值，为决策提供依据。数据分析结果可以帮助决策者做出更明智的决策。例如，银行可以使用数据分析预测客户流失率，从而采取措施以减少客户流失。常见的数据应用形式包括以下 4 种。

(1)可视化：将数据以图表、图形等形式展示出来，以便理解和分析数据。

(2)报告：将数据分析结果整理成报告，供决策者参考。

(3)预测模型：使用数据训练出预测模型，用于预测未来趋势。

①https://db-engines.com/。

(4)自动化决策：使用数据驱动自动化决策，减少人工干预。

数据应用与决策是数据工程的最后一个阶段，但这个阶段也会产生新的数据，反馈到数据采集与整理、数据挖掘与分析等阶段，从而形成数据工程全生命周期的闭环。因此，数据工程是一个迭代的过程，用户应该按照实际工作需要和结果反馈及时地对其进行修正。

1.4 数据工程案例

本节以案例研究的形式，介绍数据工程的具体执行过程，讨论数据思维的形成与应用。图 1-8 对比列出了这些数据工程案例及其项目支撑。

研究对象	商品	音乐	人才	专家	新闻	政务信息	专利
典型特征	基础推荐	多媒体推荐	互惠推荐	社交媒体推荐	快速推荐	跨领域推荐	异构数据、多语言素材
关键技术	数据价值链	特征提取	双向特征表示及匹配	多源数据及多维可视化	文本分析	文本挖掘与日志分析	多源数据整合与数据可视化
支撑课题	母婴垂直购物站点	基于混合型信息的音乐智能检索与推荐	人才信息智能搜索与推荐	科技驿站	大数据时代新闻推荐模型与方法研究	政府个性化门户智能推荐	前沿技术在线
项目来源	亚马逊旗下Quidsi	福建省自然科学基金	厦门市人才网	厦门产业技术研究院	国家自然科学基金	厦门市信息技术服务中心	上海荣智工业技术有限公司
线上实例	diapers.com	cadal.cn	i.xmrc.com.cn	5501.cn	17du.info	cloud.xm.gov.cn	ftOnline.cn
	2010	2011	2012	2013	2013	2014	2014-2015

仍在进行中的项目.

图 1-8　数据工程案例及其项目支撑

在开始案例分析之前，首先要理解数据结构和数据类型。数据结构是指数据的组织方式，数据类型是指数据的性质。图 1-8 中的数据工程案例应用了以下数据结构与数据类型。

(1)商品数据。商品数据可以用结构化数据来保存。结构化数据是指数据具有固定的格式，可以用二维表格或其他形式存储。商品数据中的价格、名称、描述和生产厂商等信息都具有固定的格式，可以用表格来保存。

(2)音乐数据。音乐数据中的歌名、专辑名等信息是结构化数据，可以用表格来保存。音乐数据中的音频属于非结构化数据，不能用表格来保存。因此，音乐数据除了结构化数据之外，还有一部分属于非结构化数据。

(3)人才数据。人才数据中的姓名、出生日期等属于结构化数据，工作经历、自我描述等信息是文本数据，属于非结构化数据。人才简历中还可以包含附件，如照片、视频等，这些附件也属于非结构化数据。因此，人才数据中既有结构化数据，也有非结构化数据。

(4)新闻、政务信息和专利等数据。这类数据属于半结构化数据，具有相对稳定的填写框架，但填写的内容使用自由的文本形式，也就是样式与内容分离。优秀的网页文件也是这样考虑的，因此 HTML、XML(extensible markup language，可扩展标记语言)等类型的文件一般也是半结构化数据。

1.4.1　特征发现

下面以商品特征发现为例来讨论数据采集与整理。推荐系统是电商网站的必备功能之一，其应用结果影响用户所能看到的内容。例如，用户观看短视频时，推荐系统列表会持

续地约束用户的选择。因此，推荐系统、精准营销与提高用户复购率是密切相关的。

图 1-9 是笔者早年参与的一个商品推荐与精准营销案例，是某大型电商旗下的垂直网站，这个垂直网站只做婴幼儿产品。这个垂直网站的推荐及数据处理有何不同之处？首先，其潜在客户和服务对象是婴幼儿及其父母，因此在做特征分析的时候，会紧扣潜在客户展开。例如，抚养小孩是一个周期性极强的工作，会用到外部数据，包括婴幼儿的每个年龄段所需要的奶粉量、纸尿裤量，以及每个年龄段的玩具是什么等。

图 1-9　商品推荐与精准营销案例

在这个案例背景下，思考以下问题：推荐系统用到的数据有哪些？可以初步罗列出以下数据：用户和商品的基本特征，用户的兴趣偏好，商品促销信息，用户在网页的浏览、收藏、评论行为等。进行规整后，可以将商品推荐系统的数据分为 3 个方面：用户基本数据、协同数据和行为特征数据。

用户基本数据包括用户的个人资料、兴趣爱好、浏览记录、购买记录等，这些数据可以反映用户的偏好和需求。以地址信息为例，其中可能包括用户的家庭地址、单位地址，甚至是朋友的地址。也就是说，一个用户可能有多个地址，推荐系统要能自动识别出当前推荐使用哪个地址收货。这样，当系统推断用户选购的产品是给朋友买的礼物时，就可以优先推荐使用朋友的地址。

协同数据包括用户对商品的评论、好评量、收藏量等信息，这些数据可以帮助推荐系统了解用户的兴趣相似度。例如，用户想买某品牌的手机之前，会先查找相关商品链接，翻看评论，综合考虑后再决定是否下单。来自社区的评论数据，也就是朋友、网民之间的协同数据，体现了物以类聚、人以群分的特点。

行为特征数据包括用户的浏览行为、点击行为、购买行为等，这些数据可以帮助推荐系统了解用户的购买意愿。当用户浏览一个网页，看到了一个很心动、很想买的商品，但还没有下定决心时，用户会先将商品放入购物车，然后在网页上多次浏览。“浏览时长”“放入购物车”等动作和特征，隐性地表明了用户的偏好，这对卖家极为重要。卖家可以用这类数据来决策是否对应推出降价或搭售优惠来加速用户的购买决策，提升商品的购买转化率。

在这个案例中，还要讨论数据的合规获取、数据共享、数据安全等问题。由于商品的

基本信息是可以共用的，因此各个电商平台就存在竞合关系，一方面希望获得友商的信息，另一方面又不希望自己的信息被友商获得，例如，通过页面信息动态生成、文字图片化等方法引入网页防爬虫机制。各个电商平台之间也有“君子之约”，如通过网站根目录下的 robots.txt 文件，用简单、直接的方式告诉友商对应的爬虫权限。

在数据采集合规的情况下，进一步考虑数据是否稳定，每天产生的数据规模(数据量)、频率(数据产生的速度)、数据类型等，可以决定数据应该用什么介质存储，也就是选择什么样的数据库管理系统。下面以销售虚拟商品的电商网站为例进行介绍。图 1-10 是一个求职招聘网站，求职者通过简历数据将自己虚拟化了。简历中不仅有结构化数据，还有很多的文本数据和半结构化数据，其样例如图 1-11 所示。在进行数据分析前，应该对数据进行分类：有些数据存储在关系型数据库中，可以用结构化数据的处理技术进行处理；有些是文本数据，可以用自然语言处理(natural language processing，NLP)方式进行处理。对简历数据而言，可以用定位词对数据进行解析。例如，“姓名：”后的数据表示求职者的姓名值，“性别：”后的数据为男或女等。使用自然语言处理技术(文本处理技术)能很好地完成这项任务。

图 1-10　求职招聘网站

图 1-11　简历数据样例

1.4.2 文本推荐

文本推荐是一类以文本数据为主要研究对象的问题。下面以政务新闻推荐为例来说明文本数据的有效应用。公共政策平台会发布很多政策文件，如何将政策信息及时、准确地推送给受惠者、执行者？一个普遍做法是广而告之，在多个途径进行公告，让用户自行发现；中间做法是对政策分层分类，通过专门渠道进行通知；最佳做法是根据用户的需求，精准推荐送达。图 1-12 和图 1-13 分别是某市政务信息个性化门户和政务新闻推荐网站的案例，二者成功实践了政务信息的最佳推荐方法，有效地解决了信息碎片化和过度散布的问题，为用户提供了更有针对性的政务信息服务。

新闻推荐案例

图 1-12 某市政务信息个性化门户的案例

图 1-13 政务新闻推荐网站的案例

图书信息应用也是文本推荐的典型案例。笔者曾参与大学数字图书馆国际合作计划的资源检索项目 CADAL(China Academic Digital Associative Library，见图 1-14)，该项目的主要目标是实现图书馆资源的电子化及互联共享。例如，甲大学的学生可以检索乙大学的图书信息，如果有需要的图书，提出申请后，可以访问电子资源，或通过馆际互借获得实体书的邮寄服务。

图 1-14　CADAL 检索项目原型

如何实现图书信息的跨图书馆检索和推荐？图 1-15 是该项目规划的部分功能，可以实现“检索－助手－笔记”3 个阶段的智能推荐。首先，在数据采集上，各图书馆按照数据标准定期交换数据，形成公共数据库及镜像，这个阶段考虑的问题包括数据同步、数据冲突、分布式访问等；其次，部署全文检索工具，制定搜索结果排序规则，讨论检索的准确性，开展搜索引擎优化；再次，引入基于自然语言处理技术的智能助手，进行检索特征的提取和发现，使用基于特征的推荐向用户提供调优以后的检索结果；最后，实现检索结果的自动化记录，记录检索历史、用户反馈等，迭代优化整个检索过程。

图 1-15　CADAL 检索项目的功能

1.4.3　智能制造

本节将介绍一个制造业数据挖掘案例，如图 1-16 所示。该案例有助于用户深入了解数据科学在工业生产中的应用。该案例改编自一条平板计算机生产线，并应用实施，有效地提高了该生产线的良品率。

图 1-16　制造业数据挖掘案例

首先，为了更好地管理和优化产品的生产流程，需要将各个环节的生产数据集中到数据仓库中。图 1-17 为制造业数据仓库示意图，该图说明采集的生产制造过程数据来源繁多，包括工艺/设备参数、测量机数据、物料(批次)品质数据、设备差异/物流载具数据、环境数据等。不同来源的数据，其结构也各不相同。例如，环境数据可能只包含一个时间序列的单值数据，而工艺参数则可能来自某个系统的录入或模式的录入，物料数据可能来自供应链系统或供应商提供的信息。因此，在这个阶段，要解决多源异构数据的融合、对齐问题。

图 1-17　制造业数据仓库示意图

其次，为了更好地理解和分析这些数据，可以采用数据挖掘技术，构建数据挖掘分析平台(见图 1-18)。数据挖掘是数据分析的基础，可以帮助用户从大量数据中提取有价值的信息和模式。在制造业中，数据挖掘可以应用于工艺参数优化、质量控制、预测性维护等多个方面。

最后，通过可视化的方式，可以更直观地展示数据挖掘的结果。例如，通过图表可以清晰地展示不同时间段内生产线的运行状态、产品质量等指标的变化趋势。这种可视化方法不仅有助于用户快速发现问题，还能帮助用户更好地理解生产过程并找到改进方向。

综上所述，本案例通过实际应用展示了数据挖掘在制造业中的重要性和应用价值。通过数据采集、融合和挖掘，用户可以更好地管理和优化工厂的生产流程，提高产品质量和生产效率。

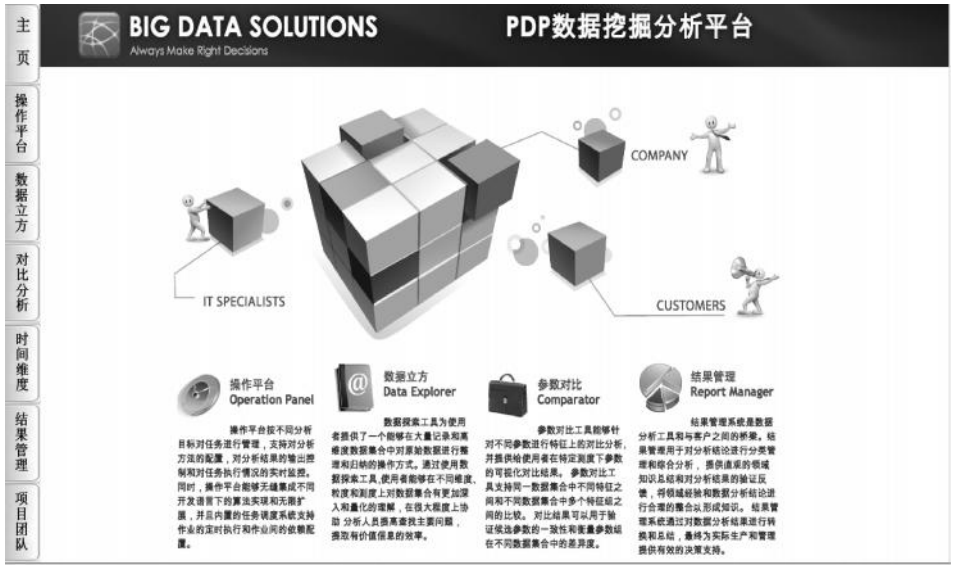

图 1-18　数据挖掘分析平台

1.4.4　技术预测

技术预测是指利用数据分析和统计方法，对未来的技术发展趋势和可行性进行科学预测的过程。通过技术预测，用户可以更好地了解未来技术的发展方向和潜在的产业机会，为决策提供有价值的指导，从而更好地应对未来的挑战并把握发展机遇。本节将数据驱动的技术预测用于企业的技术需求分析和专利预测。

首先，讨论企业技术需求分析案例(见图 1-19)，这个案例的目标是帮助政府理解企业的实际需求。为了实现这一目标，我们建立了一个全面的数据库，该数据库包括专家、技术、论文、专著、新闻和社区等多方面的信息。通过深入挖掘这些数据的潜在联系，用户可以发现企业的真正需求，进而为政府的决策提供有力的支撑。

图 1-19　企业技术需求分析案例

其次，讨论专利分析案例(见图 1-20)，这个案例的目标是找出专利的进化周期。例如，从 3G 到 4G 再到 5G 的技术发展过程中，可以观察到专利的演化和更新。此外，还可以进行专利回溯分析，探究某个专利的起源和发展历程。更进一步，可以通过分析专利之间的关系，预测技术未来的发展趋势。例如，在购买专利时，用户需要了解相关的专利背景，以及需要绕过的专利障碍。

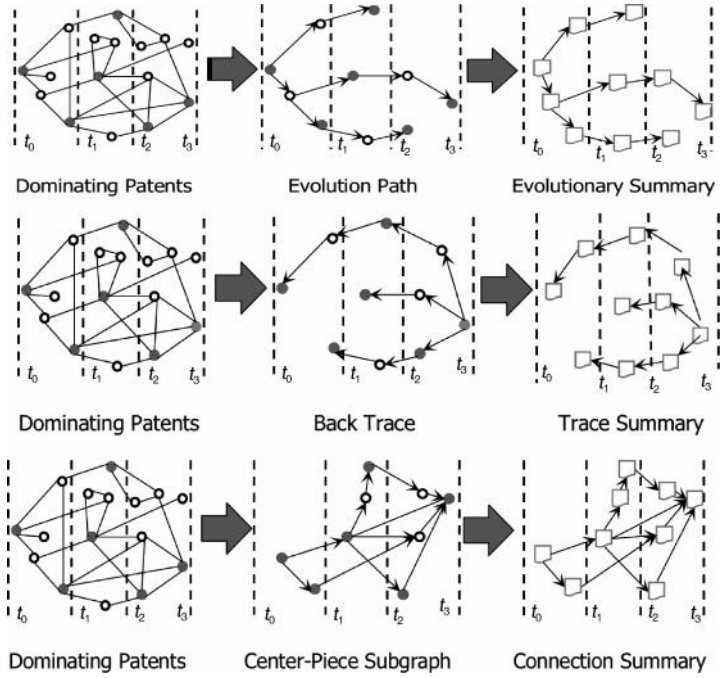

图 1-20　专利分析案例

总而言之，技术预测对用户理解和掌握未来的技术趋势至关重要。无论是政府决策还是企业决策，都需要借助技术预测来把握未来的方向。通过深入挖掘数据和分析专利信息，用户可以更好地预测技术发展，从而做出科学的决策。

习　　题

1. 找出 2020 年以来 Gartner 公司发布的新兴技术成熟度曲线及其分析报告，做出自己的理解和判断。

2. 写出数据工程的 4 个阶段，解释其中每个阶段的主要工作。

3. 选取一个数据分析任务，按照数据工程的 4 个阶段，描述该任务的具体实施方法。注意用词精炼、准确。

习题解析