第 2 章 数据科学基本知识

章节导航

- 了解数据、数据工程、数据科学。
- 理解和掌握数据的特征。
- 掌握数据科学的发展历史、研究内容。

本章知识导图

2.1 认识数据

2.1.1 数据

数据是对物理世界的人、事或物的记录。数据不只是数值，它有很多种类型，如视频、文字、动画、医学影像、天文影像，这些都是数据，如图 2-1 所示。数据科学不仅仅是数值科学，因此它不仅仅涉及数学、统计学等，而是关于所有类型数据的科学。

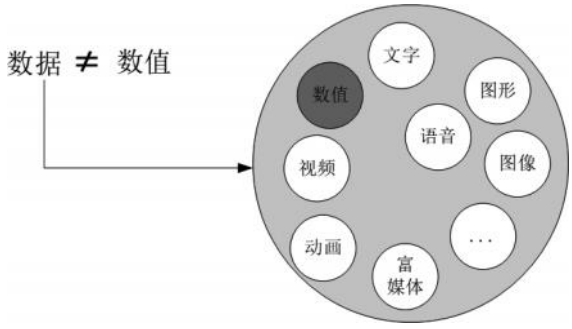

常见的数据类型

图 2-1 数据的类型

DIKW 金字塔模型揭示了数据(data)、信息(information)、知识(knowledge)、智慧(wisdom)之间的区别与联系，如图 2-2 所示。数据是现实世界的记录，它记录了人和事物；信息是进行了一部分抽象和整理的数据；知识是进行了更高层次的抽象和整理的数据，知识可能是人们发现的某个共性规律；智慧是能创造性地做一些预测的能力，这就是人工智能。从数据到智慧不但是人们认识程度的提升过程，而且是从认识部分到理解整体、从描述过去(或现在)到预测未来的过程。

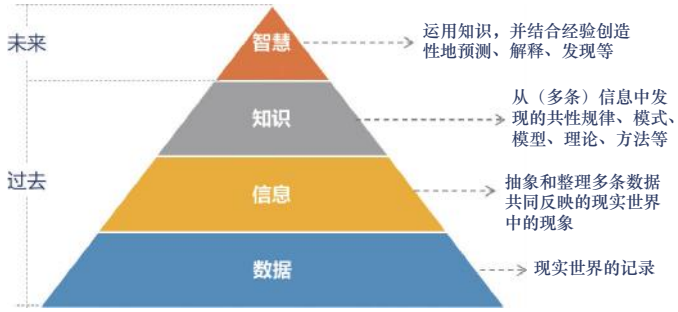

图 2-2　DIKW 金字塔模型

2.1.2　数据的分类

对数据进行分类有两种方法：第一种方法是根据数据的表现形式分类，如文本、数值、图像等；第二种方法是根据数据存储的结构化程度分类，通常将数据分为结构化数据、非结构化数据和半结构化数据 3 种，三者的区别与联系如表 2-1 所示。

表 2-1　结构化数据、非结构化数据和半结构化数据的区别与联系

类型	含义	本质	举例
结构化数据	可以直接用传统的关系型数据库存储和管理的数据	先有结构，后有数据	关系型数据库中的数据
非结构化数据	无法用关系型数据库存储和管理的数据	没有（或难以发现）统一结构的数据	语音、图像文件等
半结构化数据	经过一定的转换处理后，可以用传统的关系型数据库存储和管理的数据	先有数据，后有结构（或较容易发现其结构）	HTML、XML 文件等

在数据科学中，数据的结构化程度对数据处理方法的选择具有重要影响。例如，结构化数据的管理可以采用传统的关系型数据库技术，而非结构化数据的管理往往采用 NoSQL、NewSQL 或关系云技术。

2.1.3　数据的特征

数据科学已经发展到大数据时代。大数据具有海量（volume）、类型多样性（variety）、价值（value）密度低、产生与传播速度（velocity）快的特征，称为 4V 特征，如图 2-3 所示。

第一个 V 即海量，数据体量巨大，从太字节（TB）级跃升至拍字节（PB）级、艾字节（EB）级，数据的容量和复杂性导致使用传统工具和技术已无法处理。可以通过几个例子了解这几个数据单位。例如，可以买到存储量为 128 GB、256 GB 的手机，这里用到 GB（吉字节）；一台计算机的一块固态硬盘或者机械硬盘的容量单位大概到 TB 级；一个电信机房，它的数据量大概在 PB 这个级别。

数据 4V 特征简介

图 2-3　大数据的 4V 特征

在进行数据分析的时候，数据的量级很重要，这就必须考虑数据存储的速度，也就是输入/输出(input/output，I/O)的速度，或者查询速度，以及数据量、数据集是什么量级的。例如，银行每天产生的数据可能到 PB 这个级别，因此数据处理或者数据存储的方法就要匹配这个数据量级。客户在电商平台买东西时，电商平台要给客户推荐，如果平台的算法不够精确，算力跟不上，半个小时以后才给出一个推荐结果，那么在电商应用中就不可能应用这个推荐系统，因为客户早已经因无法忍受长时间的等待而放弃使用这个平台了。因此，数据体量的大小对整个数据科学的应用具有至关重要的影响力。

第二个 V 即数据类型多样性，包括文本、图像、音频、视频等。数据不仅有数值型，还有很多不同的类型，不同的类型带来不同的挑战。试想一下，数据的类型带来哪些数据科学上的挑战？

例如，要用 Excel 进行检索，可以按快捷键 Ctrl＋F 搜索一个数值，或者搜索一个文本，此时弹出一个查找对话框，输入两个字，或者输入一个名字、一个数值，很快就能搜索到想要的结果。这个过程看似非常方便，但是如果有 100 张图片，要找出图片中的某一个人，又该如何检索呢？

如果是数值型数据，用 SQL(structured query language，结构化查询语言)能够快速地找到需要的数据。现在有 100 张图片，要求从图片中找到某一个人；或者有一段新闻联播的视频，要求找到一个事件；或者有一段监控视频，要求找到一个事件、一个人，又该如何检索呢？这表明数据类型的变化将给检索技术带来新的挑战。

很多人认为，未来人工智能会做图像处理，也可能会做图形检索。那么，数据科学是如何做的？也有人认为，未来人工智能会继续做文本检索，如做智能问答，做自然语言处理。那么，自然语言的检索又是如何做的？每个方向都会引来新的问题。例如，自然语言的检索是不是完全精确匹配？“早上好”这 3 个字，一般认为它是问好。可是在闽南地区，不管任何时候，任何地点，人们都用“吃了吗”表示问好。因此，这时检索可能又会遇到新的挑战——语义级别的检索。数值本身如果没有单位，19 就是 19，20 就是 20，这是一个精确值；而作为文本，它是有含义的。就算是精确值，加上单位符号，它的含义也不一样。数据类型发生了变化，运用的数据检索技术也不一样。在实践中，不仅要想到数据类型有很多种，还要思考引入不同类型的数据以后，会带来什么样的研究方向。

第三个 V 即价值密度——创造价值高，价值密度低。价值密度低，也就是要从沙子里淘金。如果有很多数据，但有用的只是其中的一点点，应该怎么办呢？信息论中，信息的价值用单位熵来表示。熵是信息的变化。如果一个摄像头拍的视频里 10 min 的画面都没有任何变化，可以认为它的价值比较低。如果视频内容在凌晨 1 点的时候变化了，某个窗户被砸开了，有个小偷进来，视频内容从静止的画面变成了动画，则视频有了信息。信息的变化(信息熵)带来了信息的价值。网络中存储了海量的视频、各种各样的微博内容、朋友圈的图片，如何找到这些数据信息的价值？这是一个很难的问题。很多人做的数据挖掘或者机器学习算法，就是在发掘数据信息的价值。

第四个 V 即高速——增长速度快，处理速度快。现在全世界最大、最复杂的电子商务网站是“铁路 12306”，虚拟火车票的买卖跟实物的买卖有巨大的区别。卖一瓶矿泉水是一个典型的进销存过程，仓库进、库存出。进了 100 瓶水，卖了 1 瓶水，剩 99 瓶水，这个进销存模型是很固定的。卖一张虚拟火车票则不太一样，最小库存单位的变化非常复杂，如有一趟列车从 A 出发，途经 B 最终到达 C，卖出一张 A 到 B 的票，就会多出一张 B 到 C 的票，则最小库存单位是动态排列组合变化的。可以想象一下，每卖出一张票，不仅要更新网络终端的库存，还要更新全国的售票站、线下售票终端、自动售票机的库存，这是一个很复杂的、产生速度极快、要求处理速度极快的系统。试想一下，春运期间上亿人在同时抢购火车票，网站的访问量是巨大的。

因此，数据的增长速度、处理速度快，也带来了很多技术问题。如果从敏捷研发的角度来看，涉及动态负载均衡、DSN 缓存等相关技术。如今，给大网站提供缓存技术这一服务成为热点，如阿里等公司开始研发该技术，会带来新的技术调整。

2.1.4 信息化、数据化与数字化

信息化、数据化与数字化是一组递进的概念，与数字化转型密切相关。数字化转型在各行各业体现出不同的特点：在智能制造行业，是工业 4.0；在银行业，是银行 4.0，如图 2-4 所示。在此过程中，数据被视为最重要的生产要素。在马克思主义政治经济学中，资本、人力、土地被称为生产三要素。现在，随着技术经济的发展，数据也被加了进来。目前，数据已成为企业的关键生产要素。

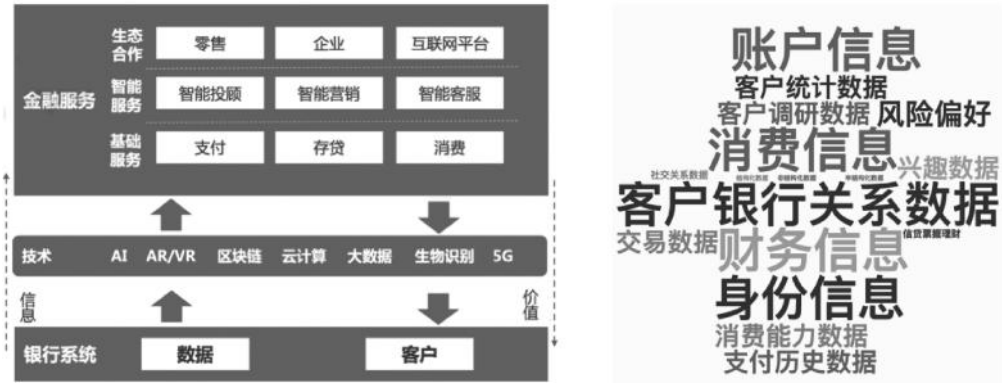

图 2-4 银行 4.0

这里有两个重要的论断：一是数据是资产，二是数据是重要的生产要素。

如果数据成为一种生产要素，那么数据可以进行交易，且具有价值。数据将成为企业经营决策的主要依据，成为商品服务和贸易活动的新内容，还会成为社会全面治理的重要依据。我国政府非常重视数据资源的作用，党中央多次明确指出要“发挥数据的基础资源作用和创新引擎作用”，鼓励利用数据资源开展创新创业活动，最大限度地激发全民创新活力。十九届四中全会也首次明确了数据可作为生产要素按贡献参与分配，即数据可以进行交易，承认其具有价值。十九届五中全会及《关于构建更加完善的要素市场化配置体制机制的意见》《关于新时代加快完善社会主义市场经济体制的意见》中进一步明确了数据作为生产要素的基础和战略性地位。

2020 年 7 月，中国信息通信研究院发布的《中国数字经济发展白皮书(2020 年)》，从生产力和生产关系的视角提出了数字经济发展的“四化”框架，即数据价值化、数字产业化、产业数字化、数字化治理，如图 2-5 所示。2020 年 11 月，中共中央发布了“十四五”规划与 2035 年远景目标的建议，并强调加快发展数字经济，推进数字产业化和产业数字化，进而推动数字经济和实体经济深度融合，打造具有国际竞争力的数字产业集群。

图 2-5　数字经济发展的“四化”框架

目前，随着数字技术的快速发展，数字化转型奠定了数据价值化和资源化的基础，但在具体实施上还存在诸多困难，如数据价值化的过程中，涉及数据采集汇总、数据确权等。什么是数据确权？怎样才能公平合理地实现它？经济学家哈罗德·德姆塞茨(Harold Demsetz)在其发表的《论产权理论》中提到，当确定数据产权的收益大于确定数据产权的成本时，数据就有了确权的经济基础。有学者认为，数据确权即数据产权的确定，其保护的是数据权利人对数据财产直接控制和支配的权利，实际上便是数据制造者在数据资源产生极大价值的新业态中，对社会资源分配的一种主张。虽然数据确权的概念已经被提出，但是确权仍然存在诸多困难，如少量数据资源的定价问题、数据资源使用过程中的个人隐私保护问题、数据所有权的确认问题等。这些问题需要从制度和法律层面上共同探寻解决办法。

一些行业对数据依赖极强，没有数据就无法运营，如银行业。银行最基本的运营模式是什么？收取存贷款利率之间的差价，这便是银行的利润。虽然现在银行产生了很多新的业务，但是其核心的、最基础的还是存款和贷款业务，其表现形式就是一组数据，业务处理方式就是对各项数据的增删改查。现在人们很少使用纸币，使用的都是一堆记账的符号(数字)，未来还可能使用数字货币。这个例子说明了银行从最初使用计算机技术开发信息系统实现业务的信息化到数据化、以数据流表示信息流和业务处理的过程，甚至发展到后续利用数字技术打通全部业务、实现数字化运营新生态的过程与方向。

数据在很多行业已经成为最重要的生产要素，在一些服务行业更是如此。例如，传统制造业的产品可能是有形的，如生产一个轮胎，但产品的产供销的全过程都是以数字化数据的形式表现和管理的。又如，在银行业，它的金融产品可能就是数字数据或可视化的数字数据。

因此，信息化是采用信息技术完成业务创新的过程，数据化则是信息化过程中的业务

流程表示。数字化有两方面的含义：一方面是狭义的数字化，即指利用信息系统、各类传感器、机器视觉等信息通信技术，将物理世界中复杂多变的数据、信息、知识，转变为一系列二进制代码，输入计算机内部，转换为便于计算机处理的形式；另一方面是广义的数字化，即利用现代信息通信技术，如大数据、云计算、区块链、人工智能、物联网等，对组织的战略、架构、运营、管理、生产、营销等各个层面进行系统性的、全面的变革，强调利用数字技术对整个组织进行重塑，实现组织文化的变革，为组织的赋能模式创新和业务突破提供驱动力。

2.2 数据科学

2.2.1 数据科学的概念

数据科学研究什么？图 2-6 为中国人民大学的朝乐门教授编写的《数据科学》一书中对数据科学的定义。这个学科有两个特点：一是“新”；二是属于交叉学科，除了统计学、机器学习等知识以外，还涉及计算机科学，甚至与整个数据产品都有很大的关系。学习交叉学科时，学习者需要把涉及的各个学科作为基础，建立完备的知识体系。

图 2-6　数据科学的定义

2.2.2 数据科学的发展历程(里程碑事件及展望)

数据科学的主要里程碑如图 2-7～图 2-9 所示，虽然其展示的不是很全面，但由此可以大致了解这个学科的发展历史。

数据科学发展里程碑

1974 年是计算机正在开始发展的时间，因此计算科学与数据科学是密切相关的。第一台计算机为什么叫计算机？因为它要计算数据，这大概就是数据科学最早的开始。

随后出现了一些专门介绍数据科学的刊物，2003 年前后，这种期刊出现了很多。

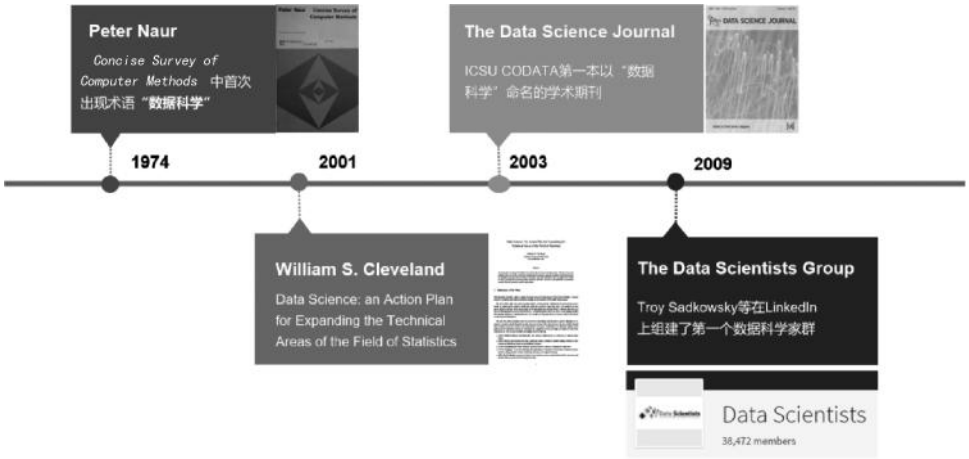

图 2-7　数据科学的主要里程碑(1/3)

学术论文怎么看？通常情况下可以先找一本书，或者找一些综述文章，先了解基本术语，再看最新的研究文献。中国计算机学会(China Computer Federation，CCF)对计算机科学的各个方向有推荐的会议与刊物，可以去推荐列表查找。另外，计算机学科的会议论文往往比期刊论文发表得早，所以中国计算机学会还很看重顶级学术会议。

2010 年，德鲁·康威(Drew Coway)提出了第一个揭示数据科学理论基础的韦恩图。为什么说数据科学是交叉学科？因为它叠加了各个学科。随后出现了一些课程，如数据科学课程。可以学习一下 IBM 公司的数据科学课程，该课程以访谈的形式讲了很多故事，也可以在清华大学线上学堂学习关于数据科学的课程，在学习强国网站上也有相关的课程。

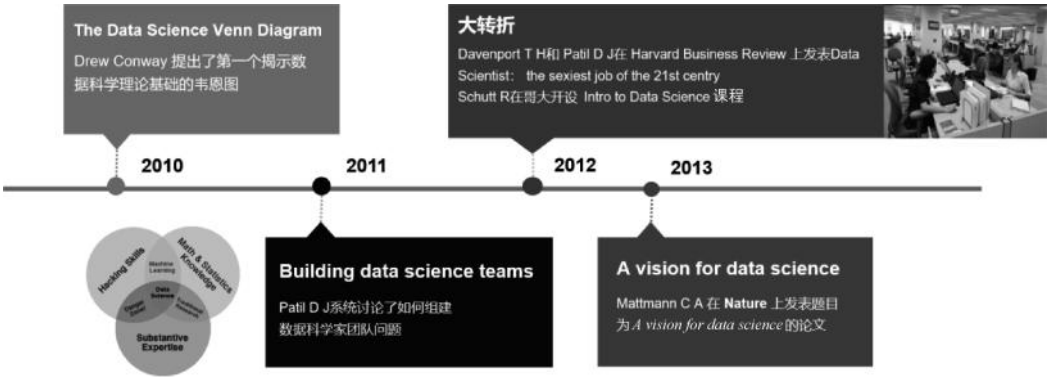

图 2-8　数据科学的主要里程碑(2/3)

2015 年，时任美国总统的奥巴马任命 DJ·帕蒂尔(DJ Patil)为白宫首席数据科学家。现在，很多公司开始设置首席数据官或者数据科学家。

目前，数据工程师、算法工程师的就业情况非常好，这部分岗位缺口很大。企业希望能够找到一些既懂业务知识，又懂数据科学、数据基础的融合型人才。可以多了解就业市场中对数据科学人才的需求情况。

图 2-9　数据科学的主要里程碑(3/3)

2.2.3　数据科学的知识体系

朝乐门教授总结了数据科学的知识体系，如图 2-10 所示。数据科学的数据生态就是以数据为核心，数据科学的研究对象是数据，可以由数据开始讨论各个问题。

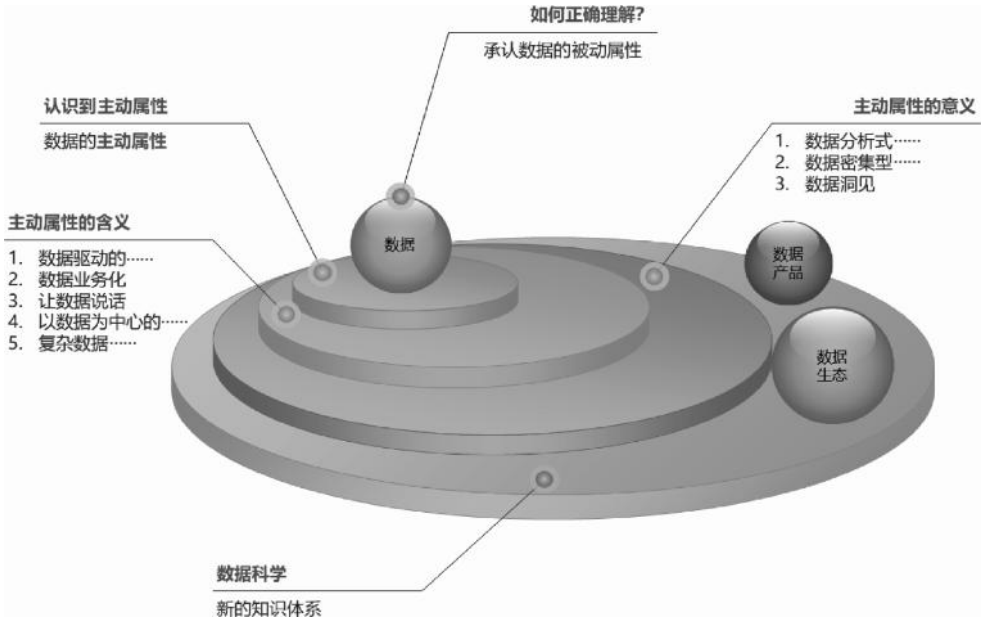

图 2-10　数据科学的知识体系

2.2.4　数据科学的研究目的与任务

数据科学的研究目的有三个：第一，要了解基础知识；第二，要能够动手做一个项目；第三，要对产业有所理解。

图 2-11　数据科学的研究任务

数据科学的研究任务如图 2-11 所示，从上往下看，第一个是“大数据及其运动规律的提示”，它是数据科学的基础，包括数据采集、数据的产生、数据流、数据从哪里到哪里等。这个部分可以是工程问题，可以非常具体。例如，实验室买了一个传感器，这个数据是怎么得到的？又如，想做健康医疗、想做老年人居家监护的数据分析，那么传感器的数据怎么来？装摄像头，可能隐私问题得不到保护，那装其他的传感器合不合适？穿戴在手上的设备舒服不舒服？可穿戴式设备实际上是把各个传感器装在衣服上，然后采集身体体征的数据。这部分工作需要明白数据的生命周期。

第二个是“从数据到智慧的转化”，从 DIKW 金字塔模型最下面的数据开始，最终转化为最上面的智慧。

第三个是“数据洞见”，即数据价值的发现。很多企业都有数据洞察的产品，其实就是数据挖掘。

第四个是“数据业务化”，即业务流程。“数据的业务化”跟“业务的数据化”是两个不同的概念，“什么的什么化”表示重心在第一个“什么”中，把数据变成标准业务流程也是可以的。例如，数据治理、数据标注就是其中典型的工作。现在市场上有很多的数据标注工具，这方面有很多的研究热点。

第五个和第六个分别是“数据分析”和“数据驱动型决策(支持)”。数据决策是在做数据仓库项目时会涉及的工作，这里涉及很多新的名词概念，如数据仓库、数据集市、数据立方体。如果把数据放到一个房间中，则称为数据库；如果把数据放到很多个房间里，则称为数据仓库。按照一个决策主题，如果想知道厦门地区今年流感疫苗的接种情况如何，主题是“厦门”“今年”，面向这个主题，把空间、时间、流感疫苗接种情况的统计数据从仓库中取出来，就把这些统计数据称为数据集市。有了数据集市以后，就要根据智能报表做出一个决策，称为数据驱动的决策，或者叫作商务智能(business intelligence，BI)。导出这些智能报表后，要用学过的基本方法发现一些规律，然后做出判断，这就是商务智能。

2.2.5　数据科学的研究内容

数据科学的研究内容如图 2-12 所示。统计学是从理学的角度来看，研究数学的人觉得他们才是搞大数据的，研究计算机的人觉得数学系的人靠推导计算很慢，计算机有超算功能，可以算得很快。机器学习的流派，如深度学习，包括 AlphaGo、AlphaFold，都是靠算力支撑的新研究范式。

从研究内容看，数据科学是一门典型的交叉学科，涉及从数据中洞察知识和得出结论。数据科学的研究中会用到各领域的技术，并且不断吸收新的方法和技术，广泛应用于各行各业，推动数据驱动决策和智能化发展的进程。鄂维南院士曾提出一种新的科学研究方法，就是利用数据科学，以数据驱动的研究方法为基础，再做理论提升。这里举个例子，鄂院士曾

提到，大家都在研究自然语义的分析，在研究自然语言或语言的翻译，如做同声传译，从英语翻译到中文，从中文翻译到葡萄牙语等，他想知道不同语言之间的翻译有没有通用的数学模型？如果掌握了这个模型，是否可以得到一个万能的翻译？现在鄂院士及其研究团队真的提出了这个模型。他们在从数据的角度积累各种各样语料的基础理论上做了一个抽象。

图 2-12　数据科学的研究内容

2.3 数据科学的基本流程

以银行 4.0：数字力为例，数据科学的基本流程如图 2-13 所示。

图 2-13　数据科学的基本流程

第一个环节是数据采集，其中涉及的问题是不同数据来源、不同数据结构的数据的获取方法，如有些数据来自业务系统，有些数据来自外部环境。

第二个环节是计算引擎。不同来源的数据通常会被放到不同的数据库中，现在银行的数据库系统理论上是一个混合型数据库，不全都是关系型数据库，也不全都是图型数据库，而是将各种各样的数据库放在一起。2.1.3 节提到的“铁路 12306”网站的案例，网站中有海量数据涌进来，网站会考虑使用一些新的数据计算引擎，即流式存储型数据库。实时计算要求响应必须及时，达到秒级或者毫秒级，例如，无人驾驶的汽车，它的环境感知来自摄像头、传感器，为了让汽车足够灵敏，在发生撞车时能够及时停车，这个数据的实时感知、

传输必须很快。为什么 5G 的一个很重要的应用场景是无人驾驶？因为 5G 的传输速度够快，带宽够宽。这里引入了一些新的技术，即流式计算。例如，浏览微博、朋友圈产生的数据，或者产品生产线上生成的数据，都与时间有极大的关联，属于时间序列数据，要实时计算海量的视频流、图片流、信息流，就需要引入流式计算。有了数据以后，怎么把数据进行组织与存储，在这个环节就会涉及计算引擎。

数据存储以后，就会进入第三个环节——数据加工，包括基础的数据可视化、数据整理等。数据整理包括很多工作，例如，数据的冲突检测，从一个数据源得到今天的最高温度是 36.5 ℃，从另外一个数据源得到同一个时间点、同一个地点的最高温度是 37 ℃，该怎么处理？碰到数据冲突，就要做数据融合。又如，数据对齐，一个传感器系统需要记载三个传感器的值，但有些传感器的值一直丢失或者缺失，或者有些传感器传回来的值的存储格式不一样，此时就要补齐缺失值，要预估这个缺失值是什么，或者对数据进行适当的转换，转换成相同的格式。图 2-13 右上角的 MR，表示映射-化简（map reduce，MR）。如果一个人发了一个朋友圈，北京的朋友 12:00 可以查看，杭州的朋友 12:01 才可以查看，在信息查阅这个事情中，同样的动作可以分开处理。信息查阅这个动作，北京的朋友早 1 min 查看，杭州的朋友晚 1 min 查看，造成的影响应该不大，等查看完以后再合并，就是分而治之。在处理超大数据量的时候，分而治之是一个普遍的常识。例如，要做数据标注，一共要标 5 000 行，找 10 个员工每人标注 500 行，最后再把它们合并，这是可行的。

第四个环节是数据分析，商务智能和可视化都在这个环节中，它们是数据分析的基础工作。对于可视化，可以做数据统计量级的可视化，也可以做可视分析、动态分析。现在智能报表特别多，以前都是用 Excel 制作，现在用 Python 语言做的报表更漂亮，或者可以使用一些快速报表工具，报表更灵活、更快速。传统的数据挖掘和统计都在数据分析这一环节中。

第五个环节是机器学习。坦率地说，机器学习算法的突破其实是相对比较难的。但是把某个算法用到某个特殊的数据集，或者结合业务场景想出一些新的研究方向，这是很有可能得到结果的。例如，同样是决策树，用在具有层次结构的数据上，可能就是层次决策法、决策分析法。在应用机器学习算法时，要对研究对象、数据的特征有深入的理解，根据这些数据的特征适用合适的算法。机器学习中，包括常说的深度学习、深度神经网络。

第六个环节是数据应用，可以多参加比赛，多动手实践，多做一些应用，从而提升数据应用能力。

以上就是数据科学的基本流程，本书研究的很多问题也能在图 2-13 中找到踪迹。

习　题

1. 大数据的 4V 特征会带来哪些新的技术上的挑战？
2. 简述数据库、数据仓库、数据集市的概念。
3. 阅读 5 篇最近的数据科学研究综述，简述哪些内容可以作为未来的研究方向。

习题解析