第 5 章 数据可视化

章节导航

- 了解数据可视化的概念及其分类、基本流程、常用工具与评判标准。
- 掌握 Tableau 与数据探索，实现数据可视化分析系统并进行交互。
- 掌握 Python 语言数据可视化，利用常用数据可视化工具库实现项目的可视化与提升。

本章知识导图

5.1 数据可视化概述

由于数据受众常是不具备专业数据知识的，将数据以图表的形式更直观、突出地展现与交互，有助于降低数据受众读懂数据的门槛，并进行良性互动，提高数据沟通的效率。

5.1.1 什么是数据可视化

数据可视化(data visualization)指运用计算机图形和图像处理技术，将数据映射为图形或图像形式呈现，并允许用户进行交互的理论、方法和技术。数据可视化是数据分析的基础形式，是关于数据视觉表现形式的科学技术研究。这种数据的视觉表现形式被定义为一种以某种概要形式抽取出来的信息，包括相应信息单位的各种属性和变量。基本的数据可视化展现方式有条形图、折线图、散点图(scatter plot)、饼图、组织流程图等，各类图形可以很方便地观察数据的各类型占比或变化趋势，展示数据包含的信息。此外，还有动态交互图表，以及根据非传统的数据类型进行灵活变动的可视化系统。数据可视化常用于数据的分析与探索。

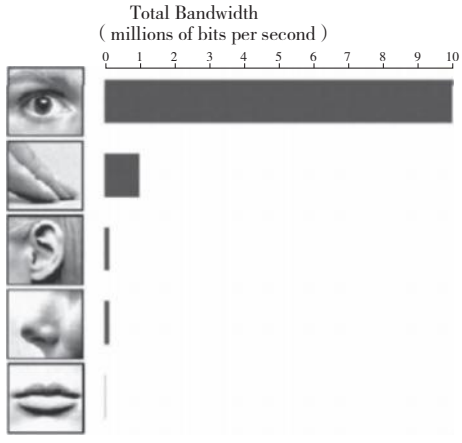

图 5-1 视觉接收的信息量远大于其他感官接收的信息量

美国哈佛商学院的研究数据表明，人从视觉上获得的信息量比其他感官要多，接收信息最多的途径是视觉，它对信息的接收量比其他四种感官的接收量的总和还多，如图 5-1 所示。

以下是一个直观认识数据的例子。F. J・安斯库姆(F. J. Anscombe)在 1973 年的一篇论文 *Graphs in*

Statistical Analysis 中分析散点图和线性回归(linear regression)的关系，提到了图像的表示方法对数据分析的重要性。

图 5-2 中为 4 组图像与数据分析的案例数据，每组共 11 个点，均为数字。

I		II		III		IV	
x	y	x	y	x	y	x	y
10	8.04	10	9.14	10	7.46	8	6.58
8	6.95	8	8.14	8	6.77	8	5.76
13	7.58	13	8.74	13	12.74	8	7.71
9	8.81	9	8.77	9	7.11	8	8.84
11	8.33	11	9.26	11	7.81	8	8.47
14	9.96	14	8.10	14	8.84	8	7.04
6	7.24	6	6.13	6	6.08	8	5.25
4	4.26	4	3.10	4	5.39	19	12.5
12	10.84	12	9.13	12	8.15	8	5.56
7	4.82	7	7.26	7	6.42	8	7.91
5	5.68	5	4.74	5	5.73	8	6.89

图 5-2　4 组图像与数据分析的案例数据

从数据中无法直接判断各组点之间的差异。通过采用数理统计的方法观察各组数据的特征，计算可得如下结果：

平均值(mean)：　$\overline{x}=9$，$\overline{y}=7.5$

方差(variance)：　$S_x^2=11$，$S_y^2=4.1$

相关系数(correlation coefficient)：　$Y_{xy}=0.816$

线性回归方程(linear regression equation)：　$y=3.0+0.5x$

采用常用的数理统计方法计算时，4 组数据有相同的平均值、方差、线性回归方程，此时无法判断 4 组数据之间的差异。

但当采用图形展示 4 组数据后，其散点图如图 5-3 所示，可轻易发现这 4 组数据具有完全不同的特征。

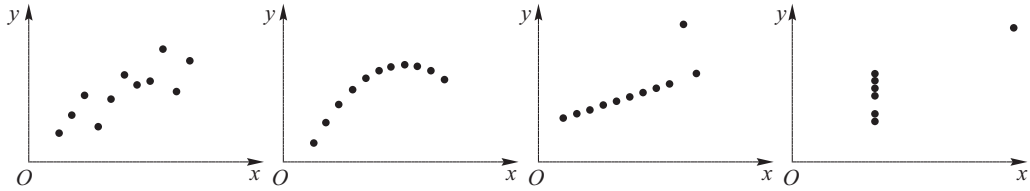

图 5-3　4 组数据的散点图

第 1 组数据，x 和 y 之间是比较弱的线性关系。

第 2 组数据，x 和 y 之间是曲线的回归关系。

第 3 组数据，x 和 y 之间是非常强的线性关系，但仍有一个异常点。

第 4 组数据，除了一个异常点以外，其他点的 x 坐标都是相同的。

通过上述例子可知，图形的直观性能够更好地帮助人们更快地找出事物的本质特征。人脑在完成理解和学习的任务时，图文搭配能够帮助读者更好地了解所需学习的内容，图文更易于理解、更有趣味性，也更易记忆。

5.1.2　数据可视化的分类

数据可视化当前主要分为 3 类：科学可视化、信息可视化、可视分析学。

1. 科学可视化

科学可视化是可视化领域最早、最成熟的一个跨学科的研究与应用领域。科学可视化主要面向科学和工程等自然科学领域的测量或计算数据，如医学、化学工程、气象环境学、机械等领域具有空间几何特征的数据。

科学可视化常处理那些具有天然几何结构的数据，如磁共振成像(magnetic resonance imaging，MRI)数据、气流。图 5-4 是科学可视化示例图形，是南海海啸波在不同时间段的实时可视化显示结果，该图形的应用需要具有专业知识的气象专家的支持。

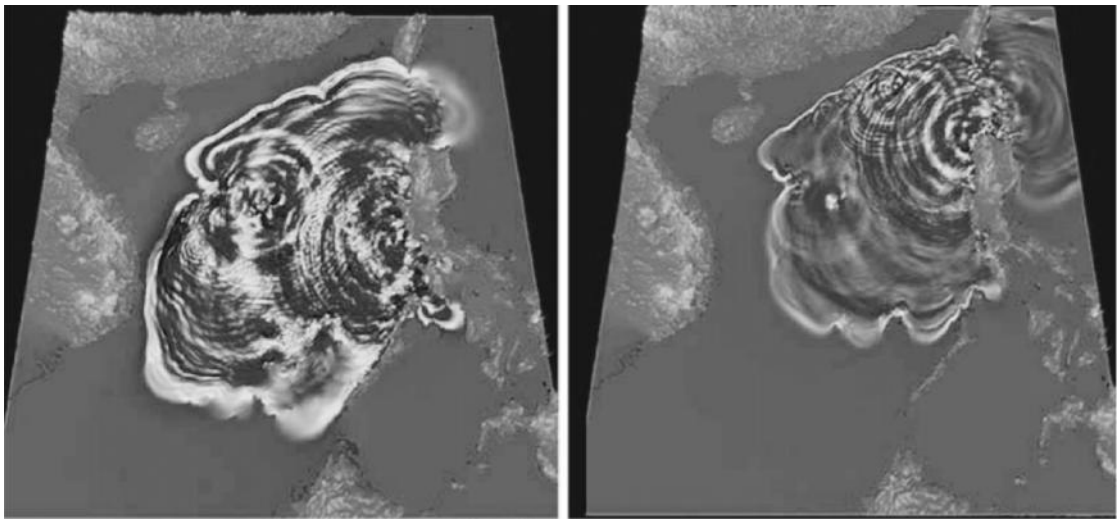

图 5-4　科学可视化示例图形

2. 信息可视化

信息可视化处理的是抽象数据结构，如树状结构或图结构。图 5-5 是信息可视化示例图形，研究美国整个国家的教育成效和收入中位数之间的相关性，左侧三张缩略图显示了美国县级教育成效和家庭收入中位数的数据，右边的地图是三组数据叠加的结果，色调和值的变化是由上面显示的数据产生的。一般来说，较暗的地区代表人群受教育程度、收入均较高，而较亮的地区代表毕业生较少、收入较低。

3. 可视分析学

可视分析学被定义为一门以可视交互为基础的分析推理科学，在交互可视界面的支持下进行分析、推理和决策，是科学可视化和信息可视化的新发展。

可视分析学尤其关注的是意会和推理。图 5-6 是可视分析示例图形，是对一个大型开放式网络课程(massive open online course，MOOC)视频的用户浏览操作情况的记录，上方的图形中，横轴是时间轴，代表视频的时长(上半部分表示前进操作、下半部分表示后退操作)；下方的图形中，用堆叠的折线图对用户的各种操作进行统计和展示，横轴是与上方的图形对应的时间轴，纵轴则是各种操作的次数，不同的亮度表示不同操作，如播放、暂停等。通过这些图表可对视频进行分析，如上述为授课视频，则视频中操作的高峰位置可能是讲授了某一关键的知识难点，引起多人重复回看。

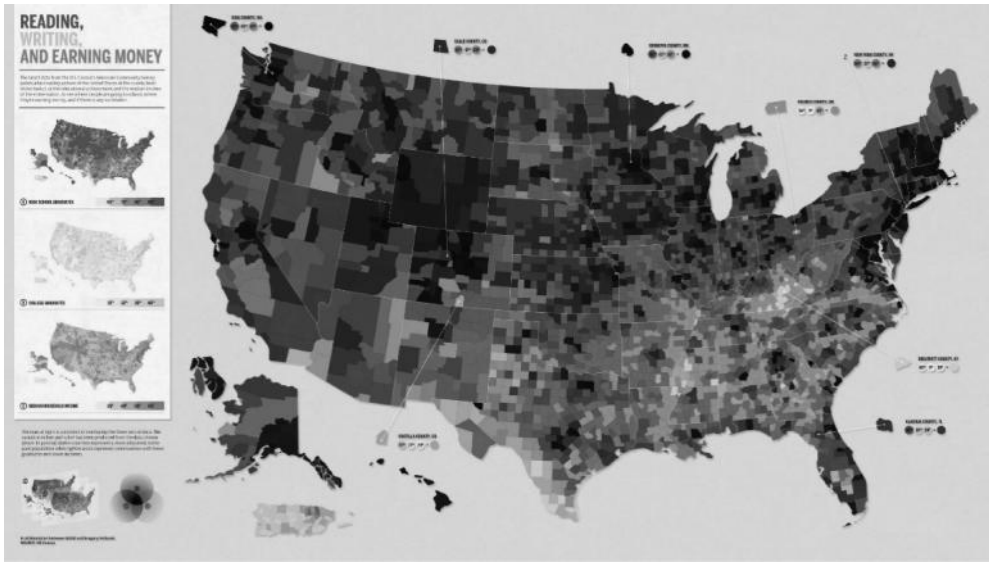

图 5-5　信息可视化示例图形

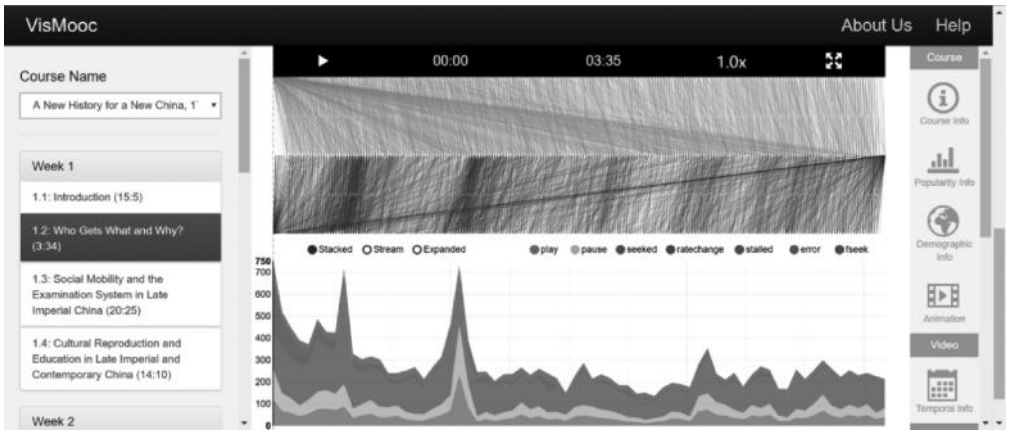

图 5-6　可视分析示例图形

5.1.3　数据可视化的基本流程

数据可视化的 3 类分别包含不同的流程。

1. 科学可视化的基本流程

图 5-7 为科学可视化的基本流程，包含串行数据处理的整个流程：原始数据经过数据分析、数据滤波、数据的可视映射和绘制，最终生成图形。

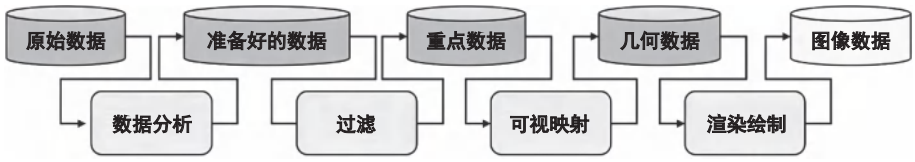

图 5-7　科学可视化的基本流程

2. 信息可视化的基本流程

图 5-8 为信息可视化的流程，与科学可视化的流水线相似，信息可视化也主要有类似的 3 个步骤：数据处理、视觉编码设计、视图生成与交互。

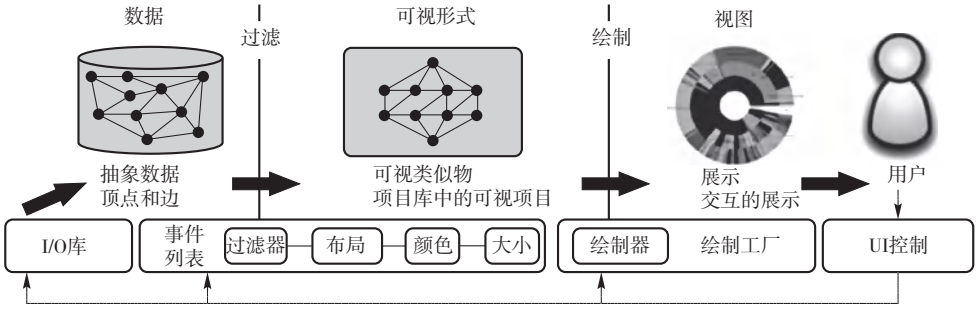

图 5-8　信息可视化的流程

数据处理包括数据清洗和数据分析等，视觉编码设计是指使用位置、尺寸、色彩、形状等视觉通道，映射要展示的每个数据维度。视图生成与科学可视化的流程不同的是，它将流水线改进成回路，并加入了用户交互的部分，且用户的交互可以出现在流程的任何阶段。

3. 可视分析学的基本流程

如图 5-9 所示，可视分析学的基本流程是，通过人机交互将自动分析和可视分析方法紧密结合。

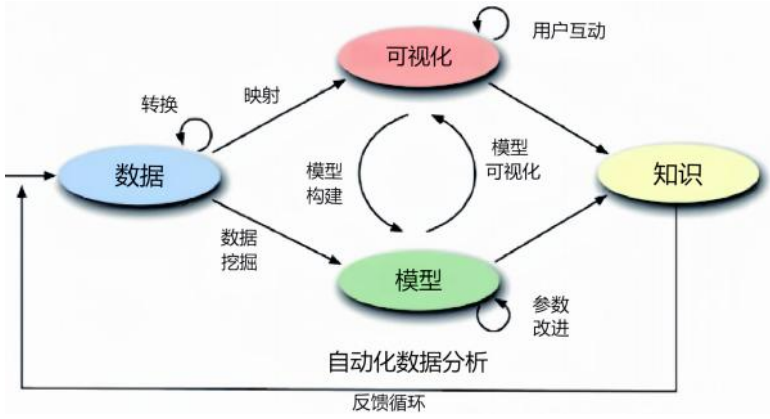

图 5-9　可视分析学的基本流程

(1)流水线的起点是输入的数据，终点是提炼的知识。

(2)从数据到知识有两个途径：交互的可视化方法和自动的数据挖掘方法。

两个途径的中间结果分别是对数据的交互可视化结果和从数据中提炼的数据模型，用户既可以交互地对可视化结果进行修正，也可以调节参数以修正模型。

5.1.4　常用工具与案例概览

大量繁杂的数据在经过可视化工具处理后，可以图形化的形式清晰直观地展现在用户

面前，甚至可与用户进行交互。数据可视化工具种类繁多，如基于不同的编程语言、适用于不同的数据、适用于不同行业的工具等。表 5-1 为数据可视化常用工具。

表 5-1　数据可视化常用工具

按编程语言分类	不需要编程语言	Excel、Tableau、PS、Power BI、RAWGraphs、Infogram、ChartBlocks、iCharts、Smartbi、Visualize Free、Visual. ly
	基于 JS 语言	D3、Chart、ECharts、Highcharts、FusionCharts、Flot、Gephi、ZingChart、JavaScript InfoVis Toolkit、jQuery Visualize、Google Charts
	基于 Python 语言	Matplotlib、seaborn、pyecharts、Bokeh、Chartify、Plotly、Cufflinks、Altair、Dash、NodeBox
	基于其他语言	jpGraph(基于 PHP 语言)、Processing(基于 Java 语言)、ggplot2(基于 R 语言)、ggvis(基于 R 语言)、AntV
按处理数据类型分类	地图数据	CartoDB、Polymaps、SandDance、InstantAtlas、OpenLayers、Kartograph、Exhibit、Modest Maps、Leaflet
	金融数据	dygraphs、Highcharts
	时间轴数据	Timeline、Dipity、Timeflow
	函数与公式数据	WolframAlpha、Tangle

下面介绍几种有代表性的工具，供了解概览。

案例 5-1　Excel 图表与 Excel 高级分析。

使用办公软件 Excel 即可快速制作出专业的仪表盘。图 5-10 为 Excel 可视化看板示例。

图 5-10　Excel 可视化看板示例

案例 5-2　D3。

D3 是目前流行的可视化工具库之一，它是基于数据操作文档的 JS 库，可以帮助用户使用 HTML、CSS、可缩放矢量图形(scalable vector graphics，SVG)、Canvas 展示数据，

D3 官网如图 5-11 所示，D3 提供的可视化图表如图 5-12 所示。

图 5-11　D3 官网

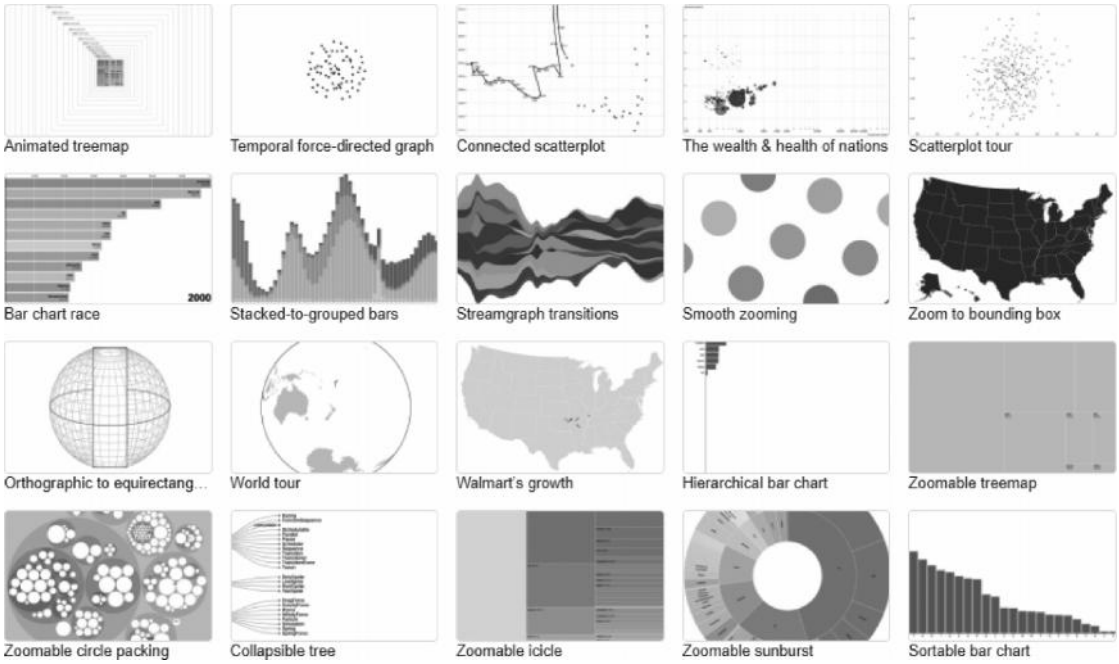

图 5-12　D3 提供的可视化图表

案例 5-3　ECharts 类库与网页数据看板。

ECharts 最初由百度团队开源，并于 2018 年初捐赠给 Apache 软件基金会(Apache Software foundation，ASF)，成为 ASF 孵化级项目，ECharts 官网如图 5-13 所示。2021 年初，ASF 官方宣布 ECharts 项目正式毕业并线上发布。ECharts 是一个基于 JS 语言的图表库，它可以流畅地运行在个人计算机(personal computer，PC)和移动设备上，且兼容当前绝大部分浏览器，如 Internet Explorer(IE)9/10/11、Microsoft Edge、Google Chrome、Firefox、Safari 等，底层依赖轻量级的 Canvas 类库 ZRender，提供直观、生动、可交互、可高度个性化定制的数据可视化图表。

ECharts 目前在国内使用者众多。ECharts 提供了常规的折线图、柱状图、散点图、饼图、K 线图，用于统计的盒形图，用于地理数据可视化的地图、热力图、线图，用于关系数据可视化的关系图、树图、旭日图，用于多维数据可视化的平行坐标系，还有用于 BI 的漏斗图、仪表盘，并且支持图与图之间的混搭，如图 5-14 所示。

图 5-13　ECharts 官网

图 5-14　ECharts 提供的可视化图表

5.1.5　数据可视化案例

以下对 3 类典型的数据可视化案例进行介绍。

1. R-Map：一种基于地图隐喻的社交媒体信息转发可视化方法

社交媒体信息转发地图(R-Map)，是北京大学可视化与可视分析研究小组提出的一种基于地图隐喻的信息转发可视化方法，R-Map 系统视图如图 5-15 所示。该方法利用地图上不同的元素编码转发信息的不同特征，能够直观地展示出一条社交媒体信息的转发结构、用户在转发过程中的角色，以及转发过程中语义的变化。

1)媒体信息转发

社交媒体已经成为人们分享、获取信息的重要平台。当用户在社交媒体上发出一条信息后，其他用户可以转发这条信息，在转发的信息中可以加上自己的评论，表达自己对原

信息的看法。转发信息又可以再次被转发，大量用户参与的多层次转发促进了原始信息在人群中的传播。针对这样的层次结构数据，存在多种不同的可视化形式，如节点-连接图、树图等，然而这类可视化形式存在空间利用率不足或者不够直观的问题。针对信息传播可视化，已有工作主要关注大量多源信息中事件、话题的传播演变分析，但是缺乏对单条信息的转发结构，以及转发过程中语义的探索。

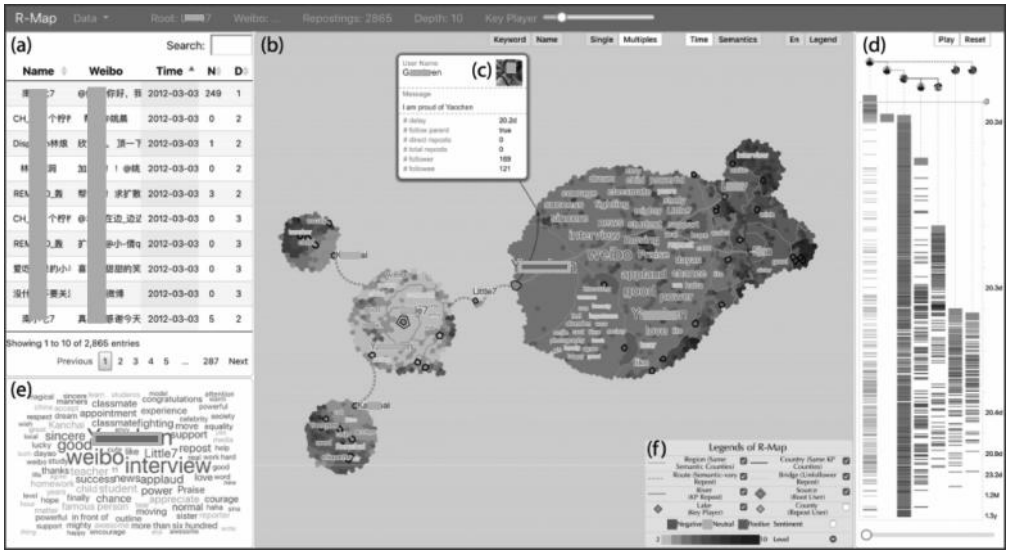

图 5-15　R-Map 系统视图

2)转发地图构建的具体步骤

针对现有技术中存在的缺陷，研究人员提出了 R-Map，一种基于地图隐喻的社交媒体信息转发的可视化方法，利用地图上不同的元素编码转发信息的不同特征，能够直观地展示出一条社交媒体信息的转发结构、用户在转发过程中的角色，以及转发过程中语义的变化。具体步骤如下。

(1)针对待分析的原始信息，获取其所有的转发信息。

(2)根据社交媒体信息的转发关系构建原始信息的转发树。

(3)从转发用户中提取关键人物，并构造关键人物之间的转发树。

(4)构造 R-Map 的布局。R-Map 构造流水线如图 5-16 所示。

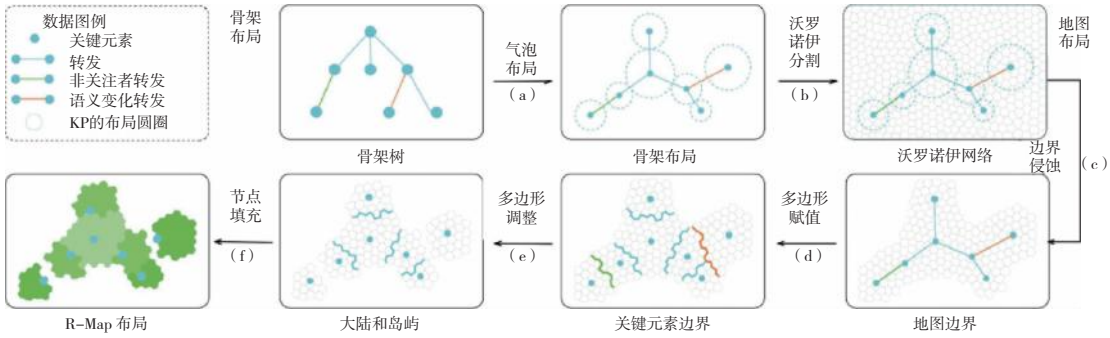

图 5-16　R-Map 构造流水线

(5)根据关键人物的不同转发关系，使用不同的方法进行连接。

(6)通过与所构建的社交媒体信息转发系统的交互，实现对原始信息转发的可视化分析。

3)转发关系与分析

图 5-17 为 R-Map 中的视觉编码方法。在地图上，对于转发的关键人物用湖泊表示。在信息转发过程中，关键人物之间存在不同类型的转发关系，这些关系对于信息的最终传播形态有着不同的影响。在 R-Map 中，对不同的转发关系进行了区分。

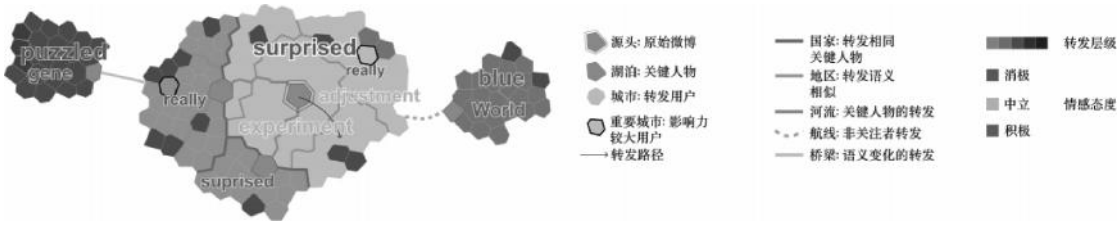

图 5-17　R-Map 中的视觉编码方法

(1)对于存在转发关系的关键人物，构建转发消息的特征向量，然后计算他们之间的余弦距离。如果距离小于设定阈值，表明二者在语义上差异较大，通过桥梁连接。

(2)关键人物在未关注的情况下转发其他关键人物，通过航线连接。

(3)对于存在转发关系的关键人物，不存在以上的转发情形，通过河流连接。

为了增强转发过程中的语义分析，一方面在 R-Map 的构造过程中，语义相似的转发会聚集在一起形成区域，另一方面通过在地图上直接嵌入关键词的方式表示该地区用户谈论的话题，同时关键词的颜色表示传播过程中社交媒体用户的情感态度。

2. EmoCo：视频中的情感一致性可视化分析

在人们的日常交流中，情感扮演了重要的角色。人们可以通过多种方式传递自己的情感，如表情、声音、文字、肢体动作等。然而有时这些方式所传递的信息并不是一致的。视频中的情感一致性可视化分析(EmoCo：Visual Analysis of Emotion Coherence in Presentation Videos)利用视频中演讲者的表情、文字、声音，设计了一套可视化分析系统，分析演讲者在这三个通道上的情感表达方式的特征，帮助演讲者提升演讲技巧。图 5-18 为 EmoCo 系统界面。

该方法关注演讲者在表情、声音、文字三个通道上的情感表达方式，对于公开的演讲视频(如 TED 分享)，提取演讲者的面部、文字及声音的情感特征。处理演讲者的说话内容可以得到文本情感，采集表达此内容过程中声音音调、强度、振幅的变化可以得到音频情感，使用演讲者的主导表情作为表情情感。情感主要分为 8 种，即愤怒(anger)、厌恶(disgust)、恐惧(fear)、快乐(happiness)、悲伤(sadness)、惊讶(surprise)、轻蔑(contempt)和中性(neutral)。在统一的力度下对三个通道开展分析。

为了分析这些情感在三个通道上的一致性，设计了 EmoCo 系统，从视频、句子、词语三个层级，提供自顶向下的分析流程。在图 5-18 的 a 区域中，顶部展现了视频中的情感颜色编码方式，中部视频列表展现了视频的名称、类别及总览信息，底部是原始视频的内容。

视频的总览设计采用了柱状图方式，如图 5-19 所示，横轴代表时间，每个条柱代表一句话在三个通道所表现出的情感态度，上方的折线图展示了三个通道的一致性。如果三个通道的情感态度一致，则值为 2；如果都不相同，则值为 0；只有一对相同，则值为 1。

图 5-18　EmoCo 系统界面

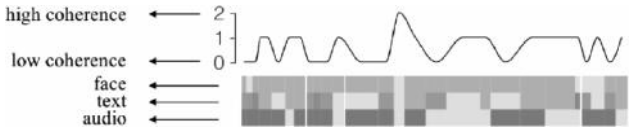

图 5-19　视频的总览设计

为了展现各个通道的具体信息，基于桑基图提出了一种新的设计方案，如图 5-20 所示。在桑基图中，每个点代表一个通道的情感类别，点与点之间的连线表示同一时间段两个通道的情感表现。在最左侧的表情通道上，添加一个树图用于表示每个点包含的不同面部表情；中间的词云展现了句子的重要关键词；右侧的直方图则显示句子的音频在音调、强度、振幅上的分布等特征。

图 5-20　基于桑基图的方式展现各个通道的具体信息

在桑基图中，用户可以选择一条边查看句子的详细信息，它在图 5-18 的 c 区域和 d 区域中高亮显示。c 区域是细节视图，用于展现每句话的详细特征，如图 5-21 所示，其中，顶部是与总体视图类似的柱状图，同时用户可以选择查看详细内容，并能显示前两句及后两句，选中的句子会在底部显示，折线图展现了句子中的音频特征，同时通过图标表现演讲者的表情变化。此外，用户可以刷选折线图，刷选的文本也将高亮显示。图 5-18 的 e 区域列出了视频中的常见词汇，以及演讲者演讲时表情的分布情况。

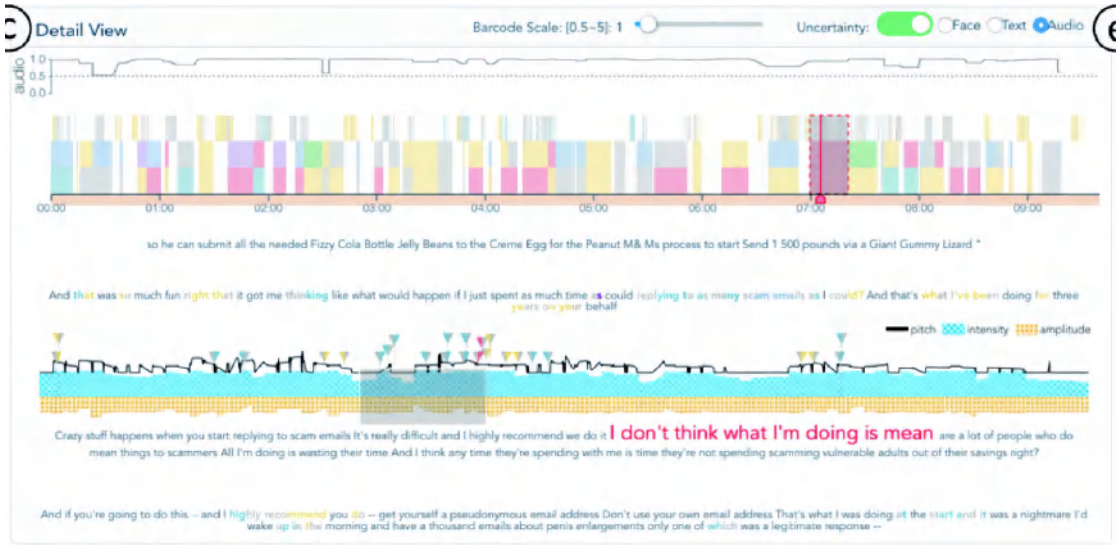

图 5-21　细节视图展现每句话的详细特征

3. 人才数据可视化综合案例

将某市人才网的人才简历、求职者登录记录等脱敏数据集作为原始数据集，开展人才数据可视化，借此了解热门职业、求职者自我评价及其分析、求职者学历及与收入间的关联、求职者近期求职意向与状态(登录频次)等信息。

(1)使用 Python 第三方库 wordcloud 制作热门职位词云图，如图 5-22 所示。

图 5-22　热门职位词云图

(2)使用 Python 第三方库 jieba 对自我评价文本进行分词，然后使用 Python 第三方库 wordcloud 制作自我评价高频词词云图，如图 5-23 所示。

图 5-23　自我评价高频词词云图

(3)将自我评价作为语料，使用 Python 第三方库 Gensim 的隐含狄利克雷分布(latent dirichlet allocation，LDA)文档主题生成模型，进行主题抽取，使用 Python 第三方库 pyLDAvis 对 LDA 模型进行可视化，如图 5-24 所示。

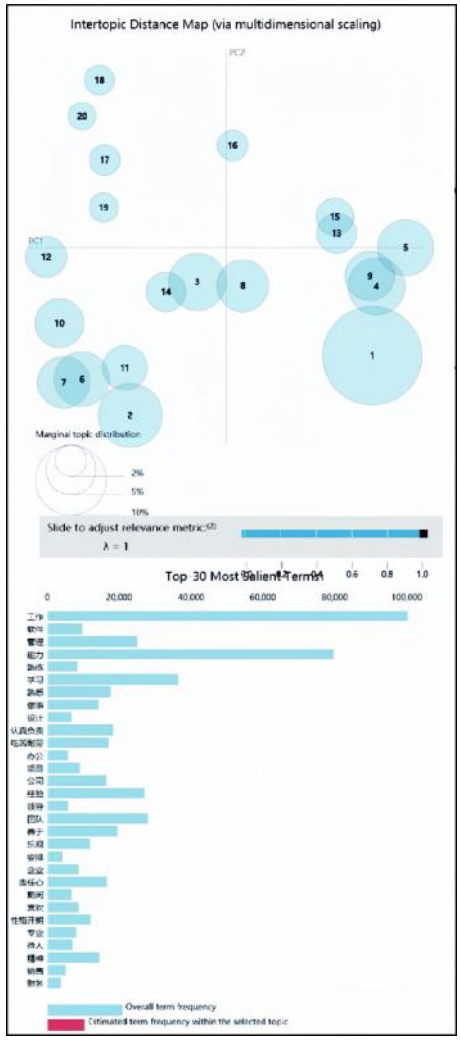

图 5-24　自我评价分析可视化图形

(4)使用 Tableau 制作求职者学历占比饼图，如图 5-25 所示。

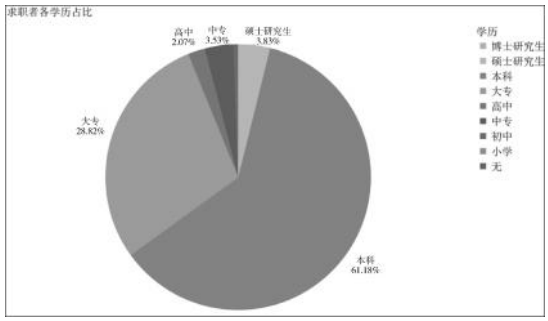

图 5-25　求职者学历占比饼图

(5)使用 Tableau 制作学历与收入的条形堆叠图，如图 5-26 所示。

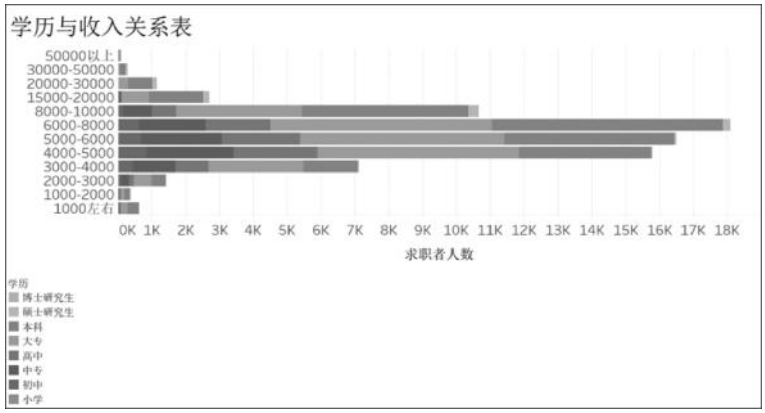

图 5-26　学历与收入的条形堆叠图

(6)使用 Tableau 制作求职者登录次数折线图(以小时为单位累积到每个月)，如图 5-27 所示。

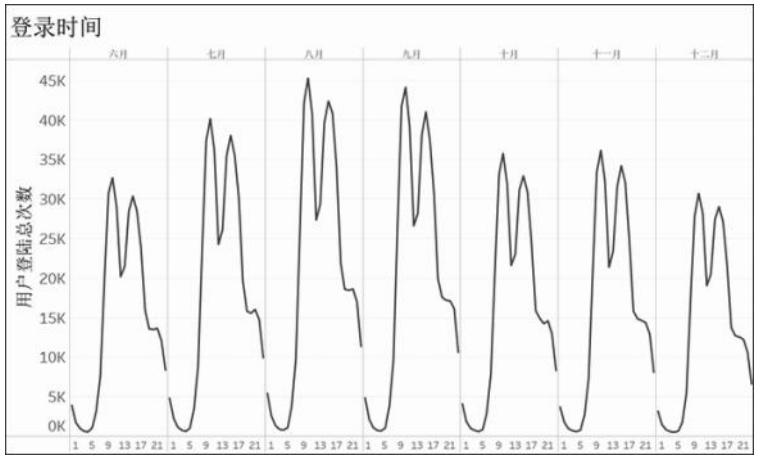

图 5-27　求职者登录次数折线图

5.2 用 Tableau 进行数据探索

Tableau 是一款功能强大的数据可视化软件，致力于帮助用户查看并理解数据。它将数据可视化为美观简洁的图表，帮助用户快速深入地探索、分析数据并分享信息。它采用拖放式界面，让数据的探索与分析变得轻松简便。Tableau 系列产品如表 5-2 所示。

Tableau 使用介绍

表 5-2　Tableau 系列产品

序号	产品	功用
1	Tableau Desktop	每个人都能使用的分析工具
2	Tableau Public	作品共享平台
3	Tableau Server	适合团队共享，管理本地解决方案
4	Tableau Cloud	适合团队共享，托管在云端
5	Tableau Reader	阅读 Tableau Desktop 文件
6	Tableau Mobile	使用平板计算机或手机进行访问和编辑

为了方便读者使用，本节主要介绍 Tableau Desktop。它的学生版可为经过认证的学术机构的学生提供免费许可证，非学生用户也可以学习，但内容无法保存到本地，不能导出图片和数据，只可上传至社区分享。

Tableau Desktop 可以制作的数据可视化结果有以下 3 种类型。

(1)工作表：编辑视图，支持计算、排序、突出显示、下钻查询、筛选等功能。

(2)仪表板：由多个相关联的视图组成。

(3)故事：汇编一系列视图，逐步引导用户探索。

其中，仪表板可以同时显示多个工作表；故事则可以给用户展示数据的发现过程，并且可通过与图表交互来浏览数据。

Tableau Desktop 制作图表的操作步骤如下。

(1)连接到数据。在“连接”窗格中提供如下选项。

①连接到文件型数据：例如连接到储存在 Excel 文件、文本文件、Access 文件、JSON 文件、PDF 文件、空间文件、统计文件等中的数据。

②连接到服务器型数据：例如连接到储存在 Tableau Server、SQL Server、MySQL、Oracle、Amazon Redshift 等或其他服务器上的数据。

(2)选择图表类型：如条形图、折线图、树图、地图等。

(3)编辑、调整图表并探索数据。

(4)图表生成与导出，例如生成与导出为图像、PDF 或 Tableau 文件工作簿。其中 Tableau 工作簿中包括多个工作表，其特点是可交互、包含底层数据、可编辑更新。

本节以重要火山喷发数据集为例，使用 Tableau 制作仪表板，如图 5-28 所示，并对 Tableau 的使用进行介绍。

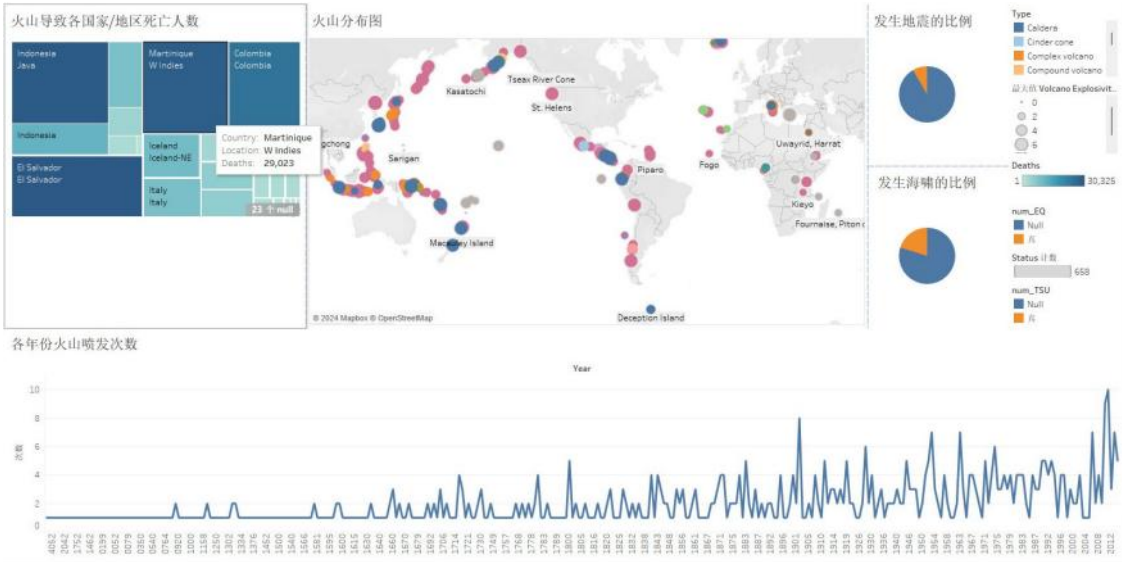

图 5-28　Tableau 仪表板

操作实现步骤如下。

步骤 1：连接数据源。

可以根据数据源类型的不同，在左侧菜单栏选择连接不同类型的文件/服务器，如图 5-29 所示。

图 5-29　连接数据源

这里选择连接到数据文件 significant_volcano_eruptions. xlsx，如图 5-30 所示。

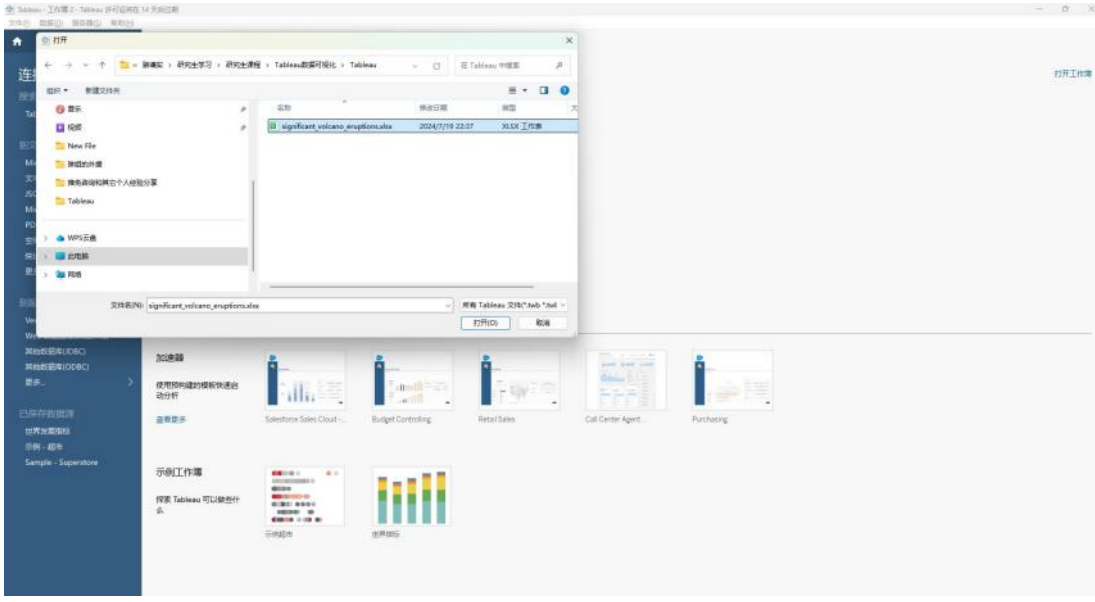

图 5-30　选择连接到数据文件

导入数据，如图 5-31 所示，将左侧的工作表 volerup 拖动至中间的工作区，如图 5-32 所示，加载数据。

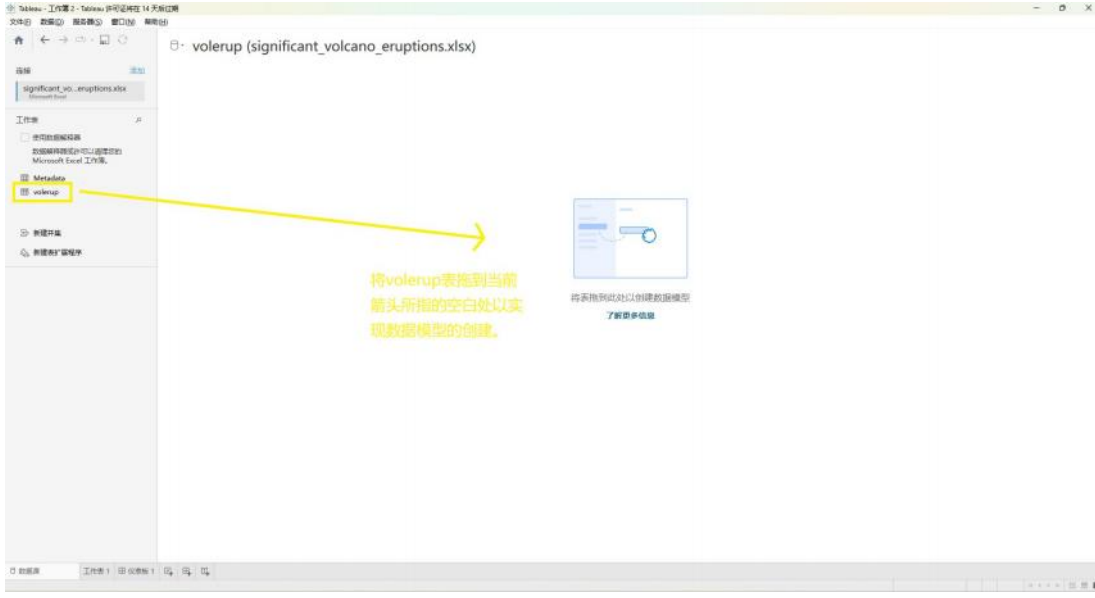

图 5-31　导入数据

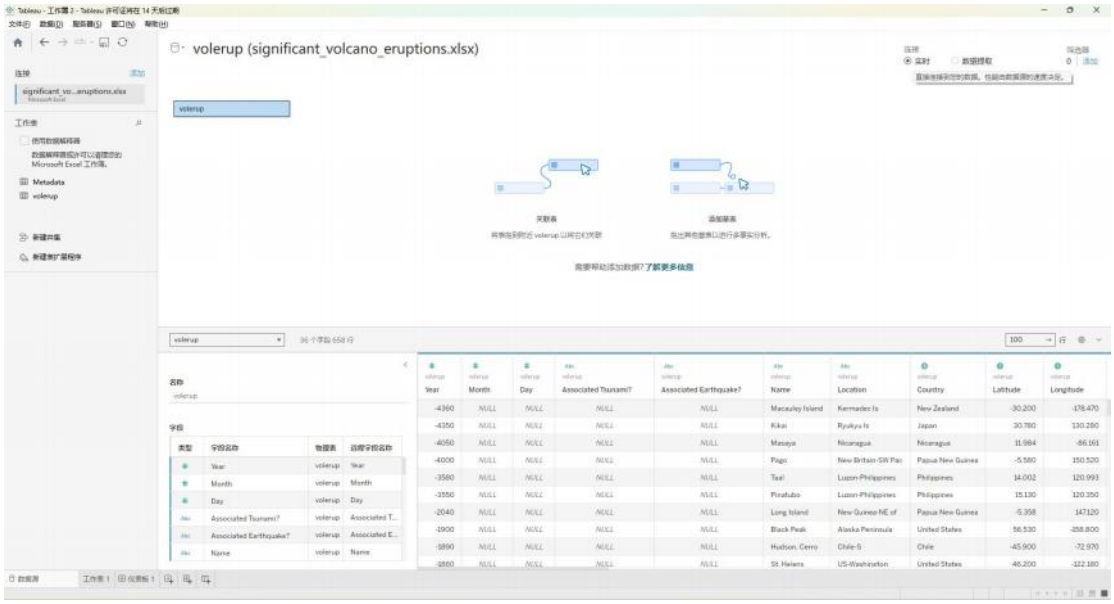

图 5-32　加载数据

在工作区即可查看数据的基本情况，如图 5-33 所示，此处连接方式可选择使用“实时”或者“数据提取”方式。如果存储在数据库中的数据有变动需求，且实际应用时对数据实时性的要求较高，建议选择“实时”方式；如果数据为离线数据，或者实际应用时需要综合考虑运算速度平衡等问题，则采用“数据提取”方式更合适。

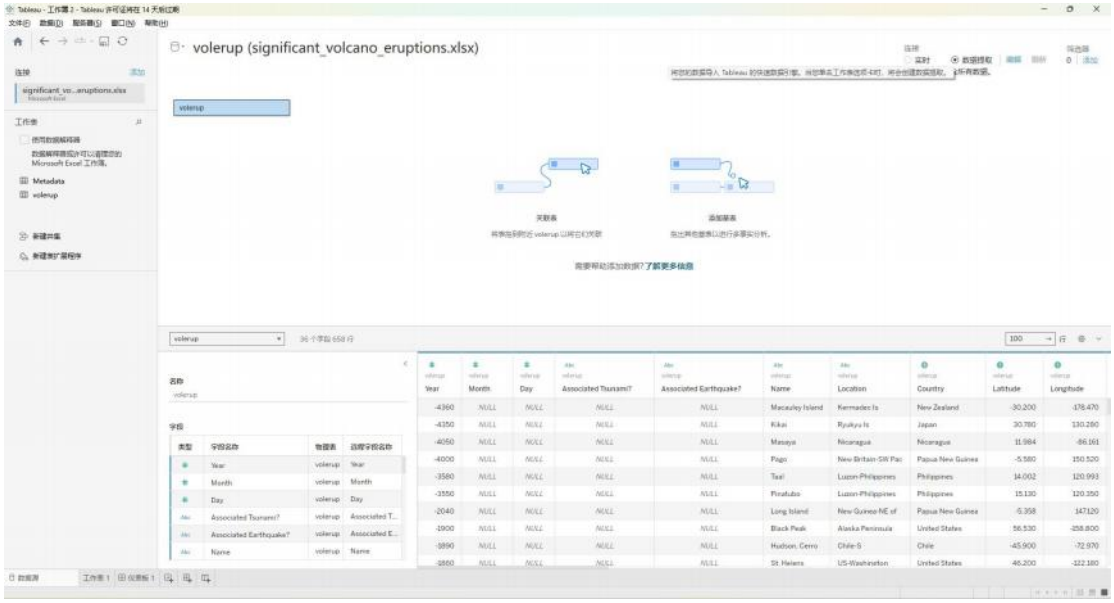

图 5-33　查看数据的基本情况

新建工作表，如图 5-34 所示，当前界面即为工作表制作界面。

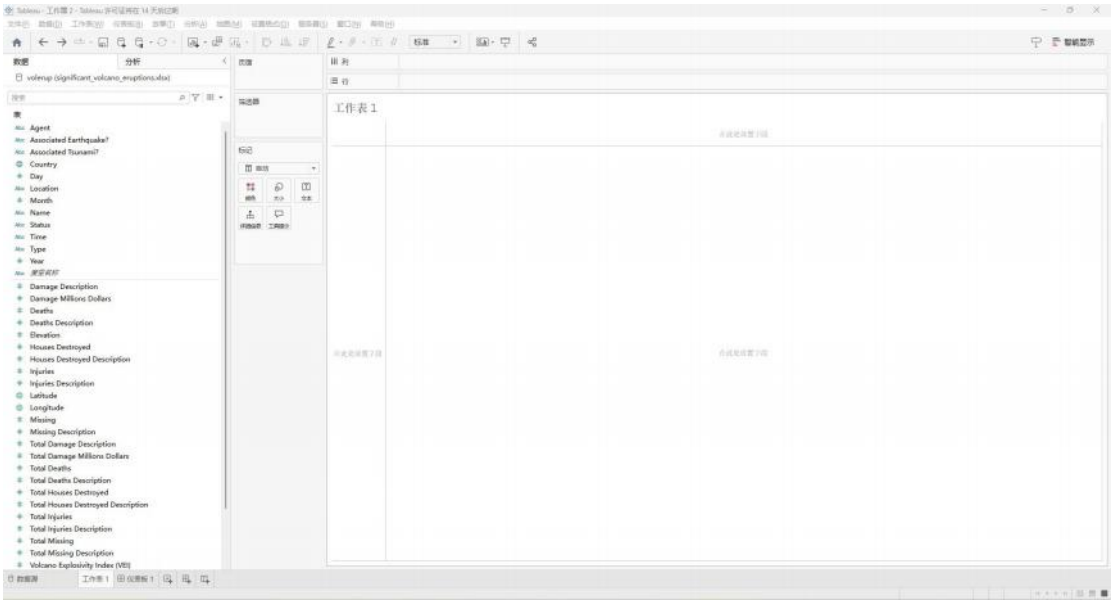

图 5-34　新建工作表

步骤 2：创建火山分布图工作表。

在左侧菜单中，数据主要分为维度、度量两种类型。维度是文本类型的离散值，例如，形容某人是本科生或研究生。度量是数值类型的数据，例如，某人身高 175 cm，体重 70 kg 等。

在此将经度、纬度数据分别设置成 Tableau 特有的地理角色的类型，如图 5-35 所示。将经度、纬度数据分别拖动至工作区的列和行，Tableau 将自动生成一张地图，如图 5-36 所示。

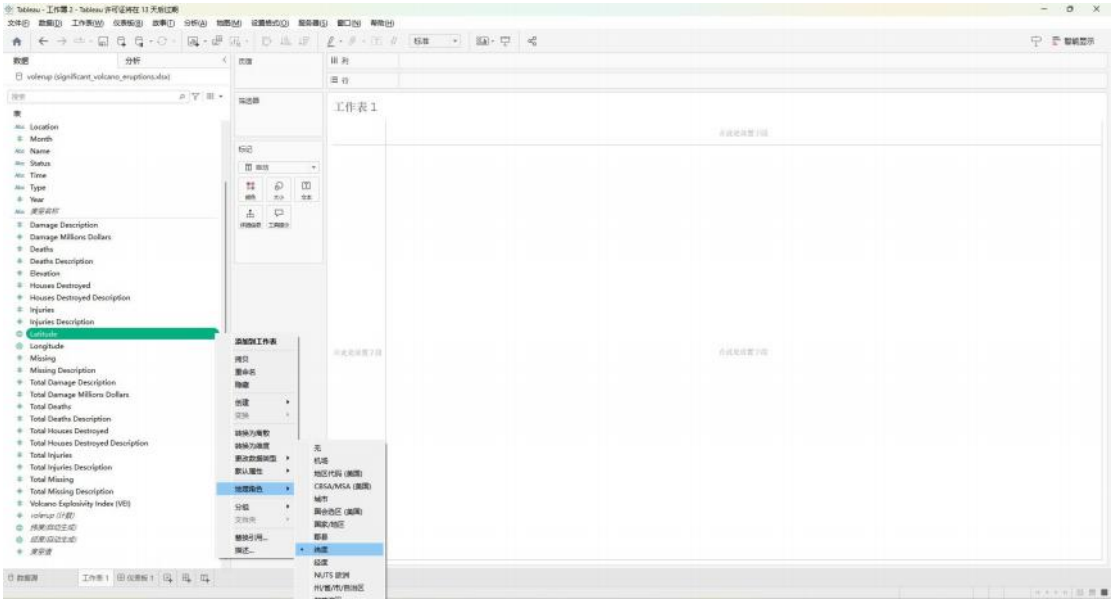

图 5-35　将数据设置成地理角色的类型

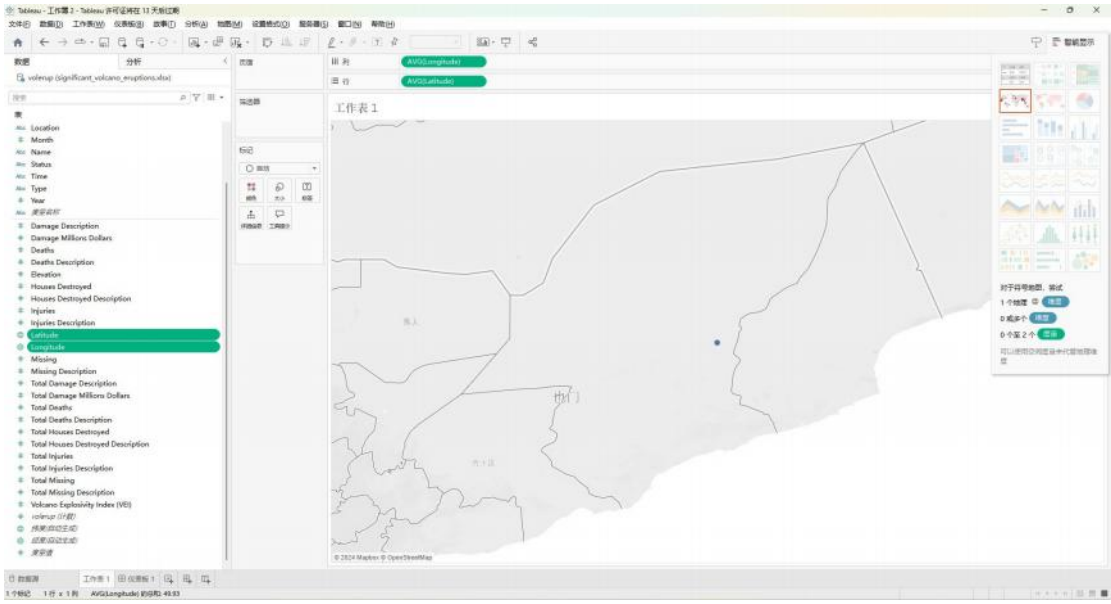

图 5-36　生成地图

将左侧维度中的 Type 拖动至标记中的“颜色”项。Tableau 将根据火山的类型，把不同的火山显示为不同颜色的点，如图 5-37 所示。

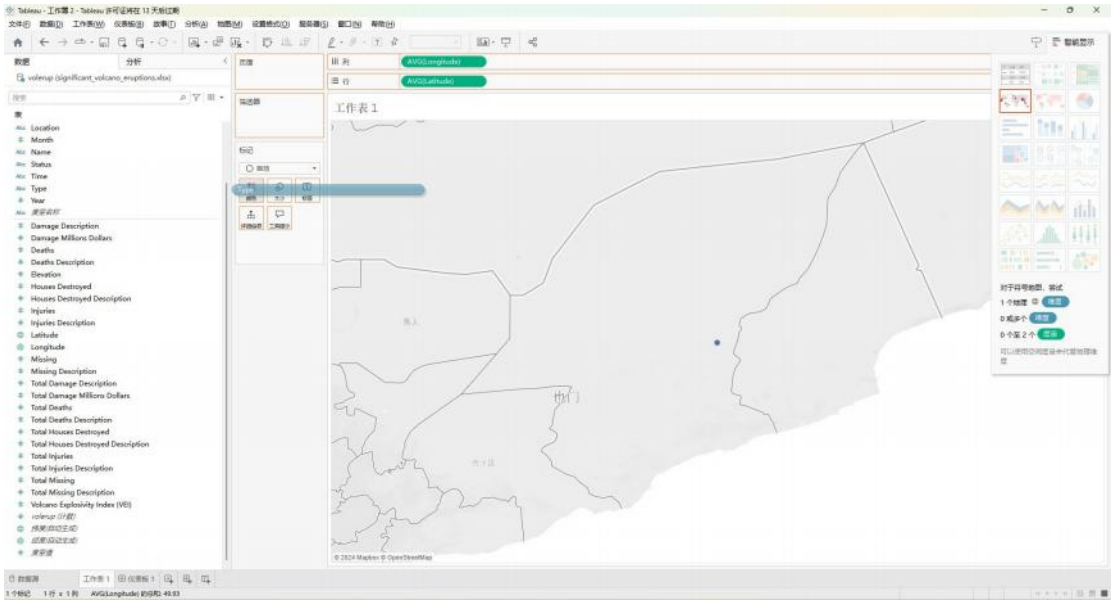

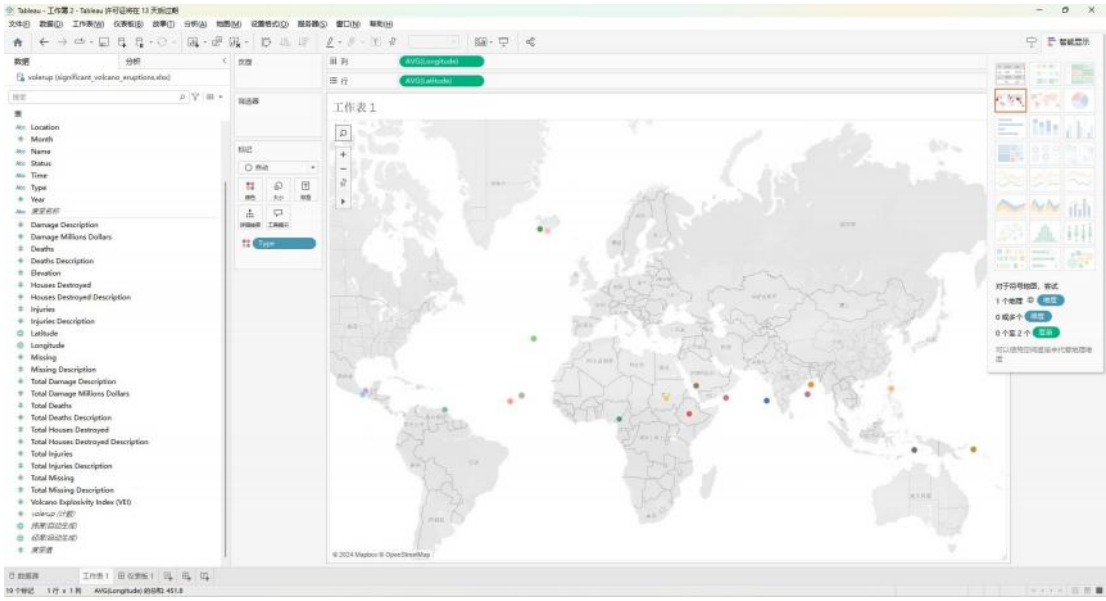

图 5-37　根据火山的类型设置不同颜色的点

同样地，将 Volcano Explosivity Index（火山爆发指数，VEI）拖动至标记中的“大小”项，将其度量类型从“总和”改为“最大值”，Tableau 即可显示不同大小、不同颜色的圆点标记，如图 5-38、图 5-39 和图 5-40 所示。

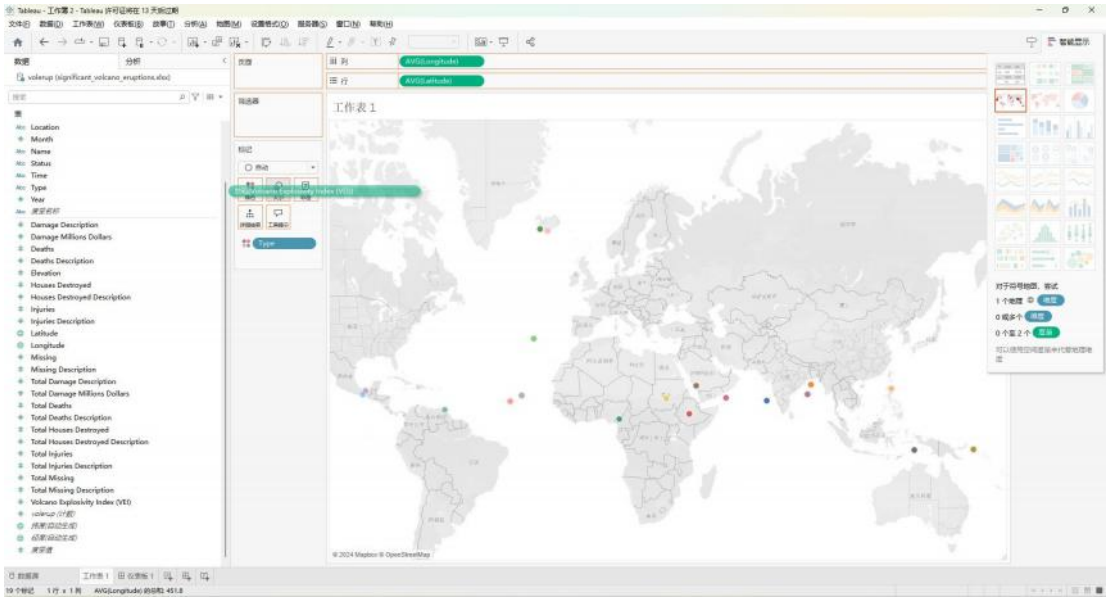

图 5-38　设置采用圆点标记

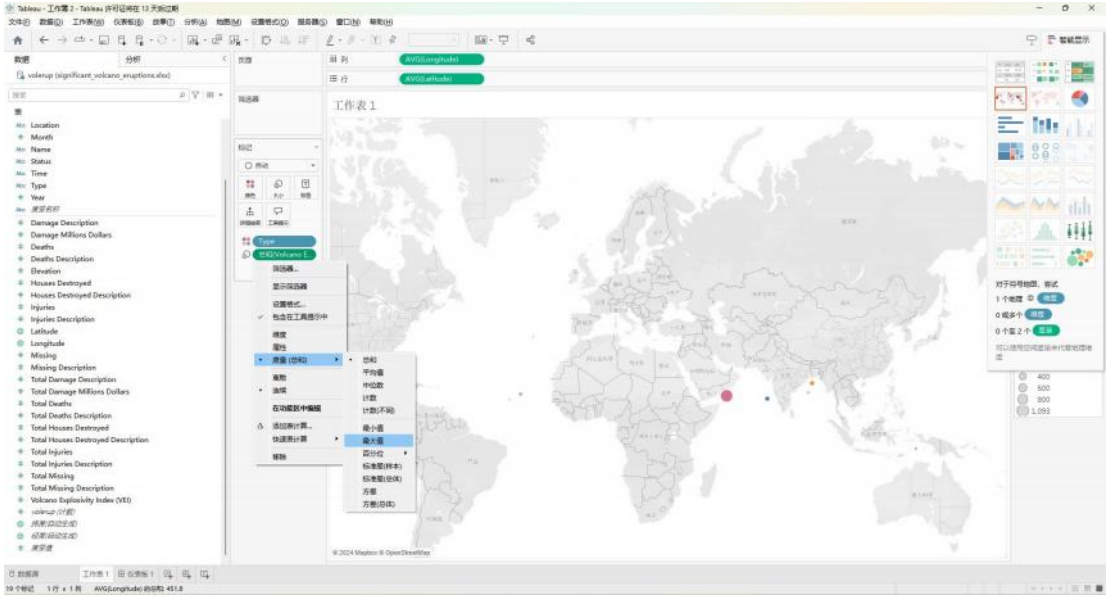

图 5-39　将度量类型从“总和”改为“最大值”

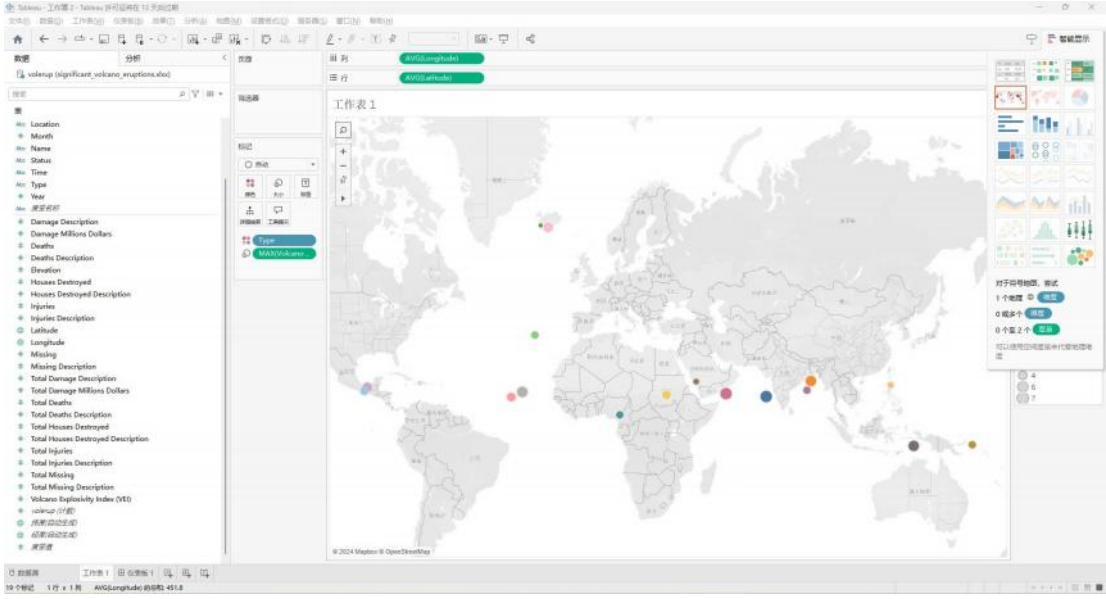

图 5-40　显示不同大小、不同颜色的圆点标记

将 Name 拖动至标记中的“标签”项，地图上即可显示火山名称，如图 5-41 所示。

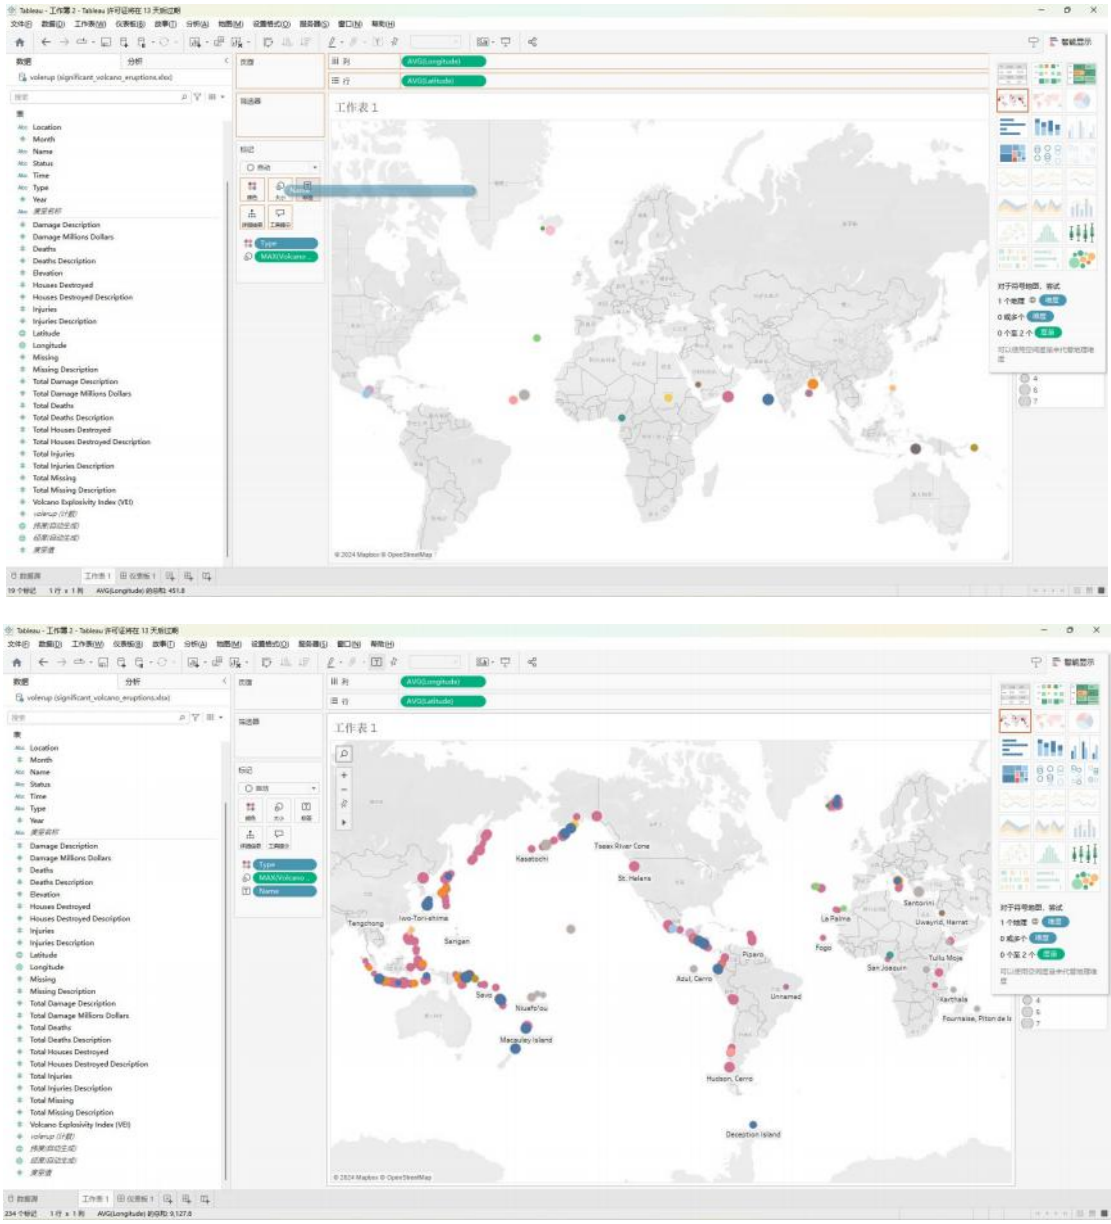

图 5-41　在地图上显示火山名称

再将 Country、Location 拖动至标记中的“详细信息”项，当鼠标指针悬停在这些点上时就能显示这些火山的详细信息，包括其所在国家、位置等，如图 5-42 所示。还可以对地图进行放大、缩小、平移等操作。

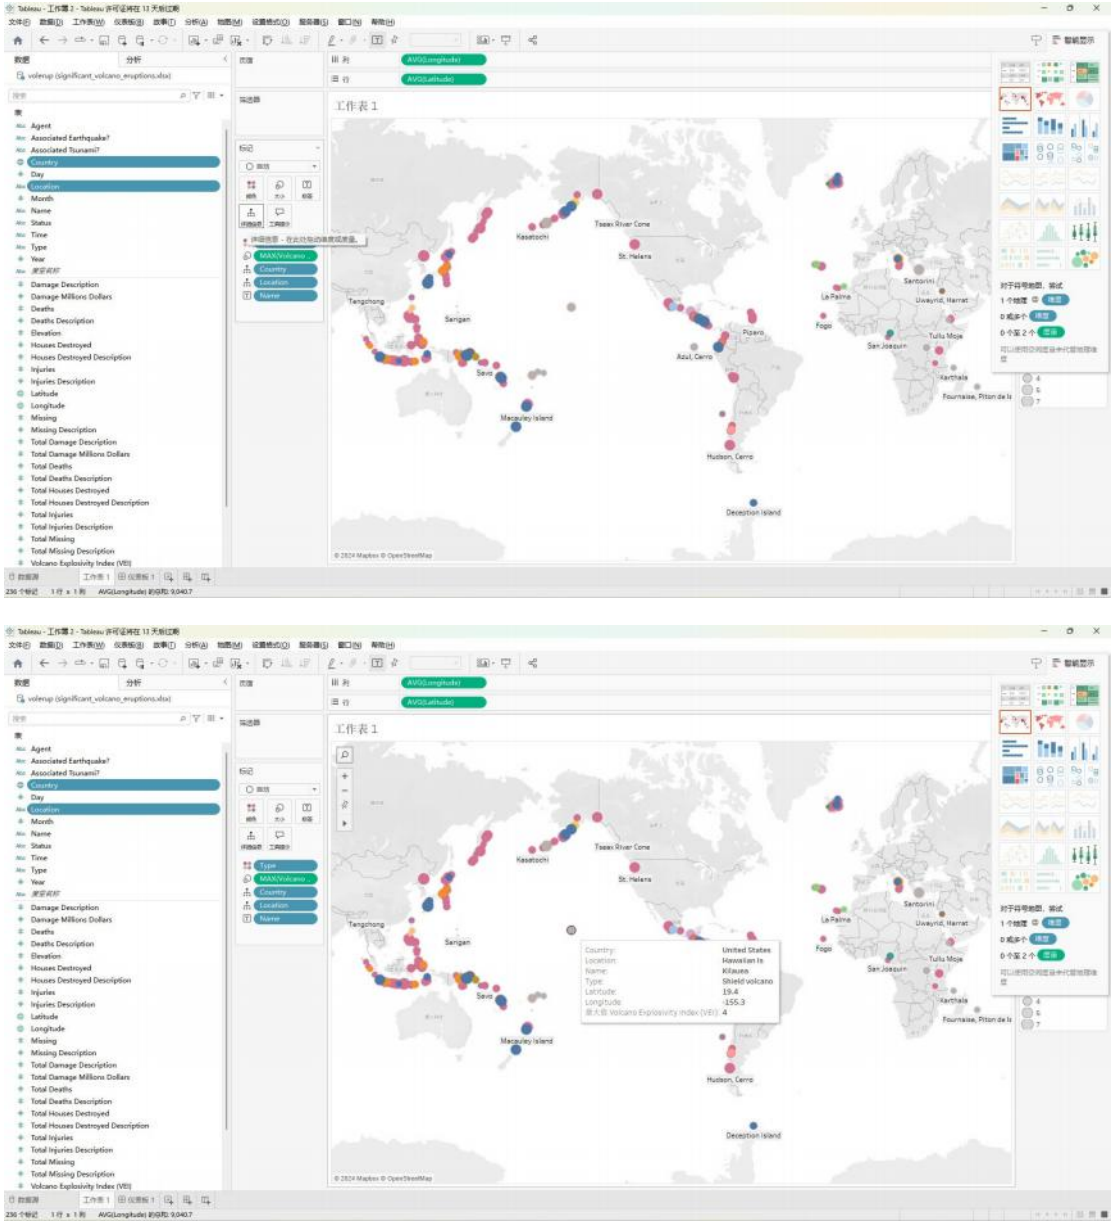

图 5-42　设置显示火山详细信息

双击工作表标题，可以修改工作表标题并设置其格式，如图 5-43 所示。

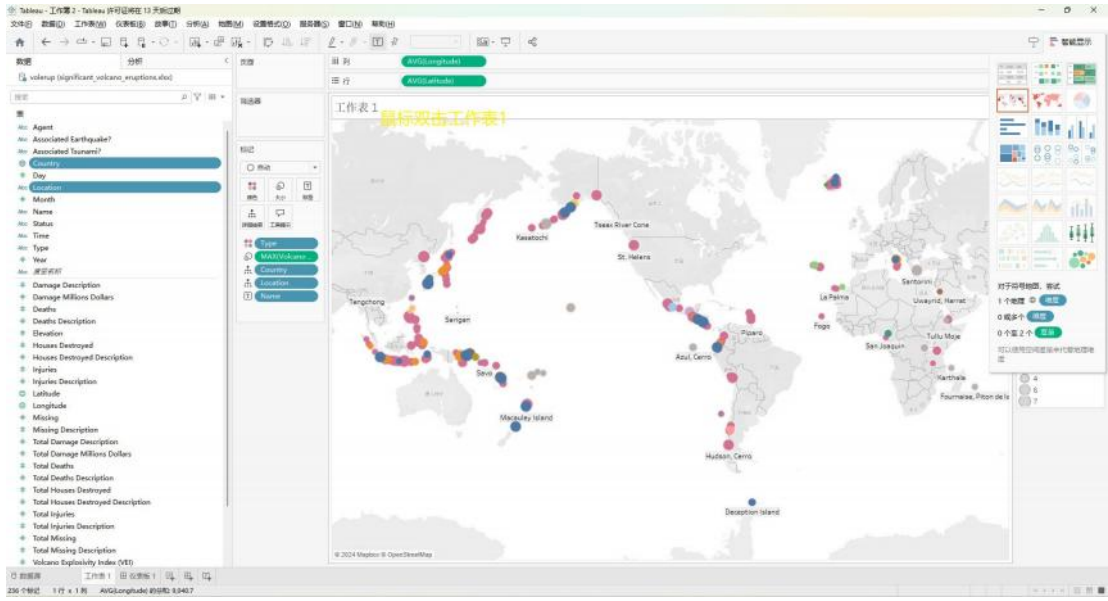

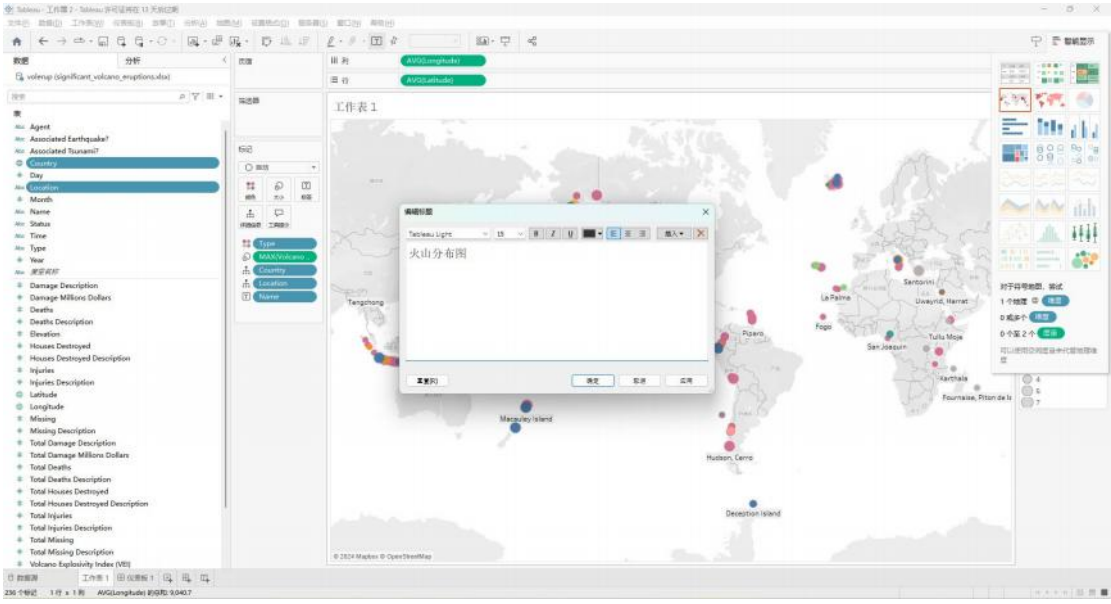

图 5-43　修改工作表标题并设置其格式

单击下方表的标签名也可修改工作表名称，如图 5-44 所示。

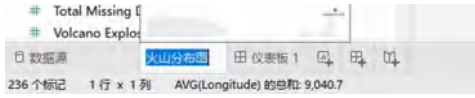

图 5-44　修改工作表名称

可仿照上述方法完成树图、折线图、地震比例、海啸比例等 4 张工作表。

步骤 3：创建仪表板。

创建多个工作表图表后，可以将这些图表整合为总的仪表板。已制作完成的工作表将显示在左侧工作表的菜单栏。

将任意工作表拖动至中央的工作区，并通过左侧菜单栏设置仪表板的大小，并创建仪表板，如图 5-45 所示。

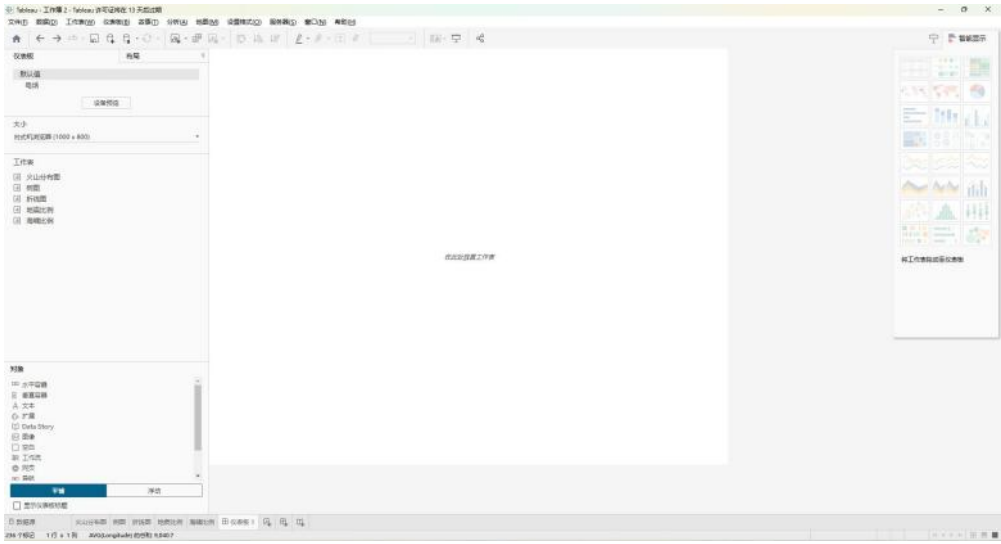

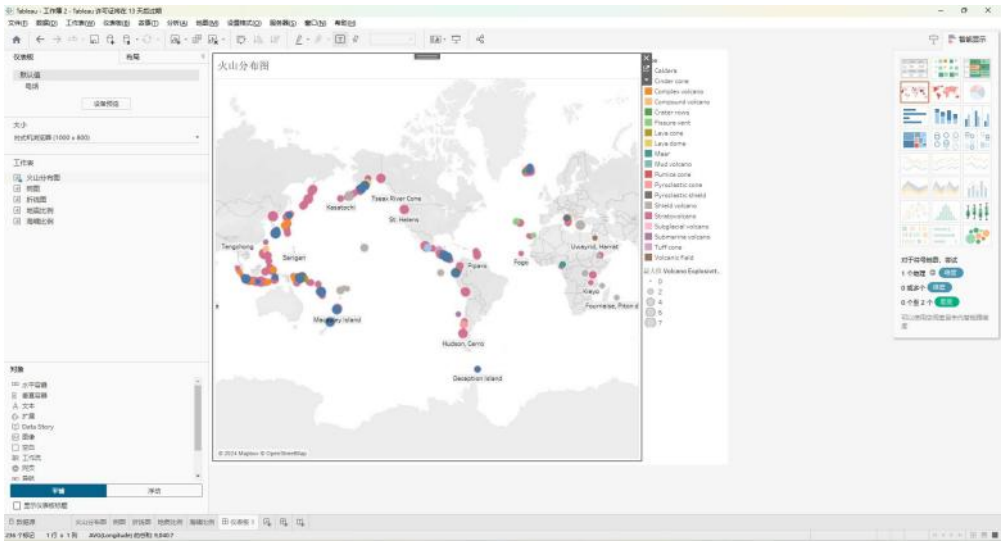

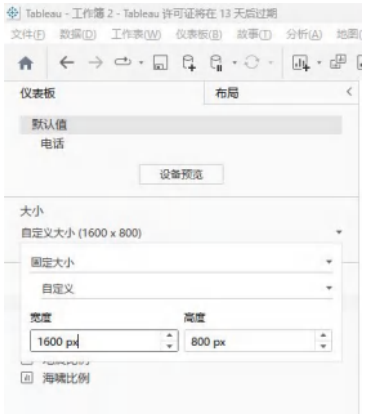

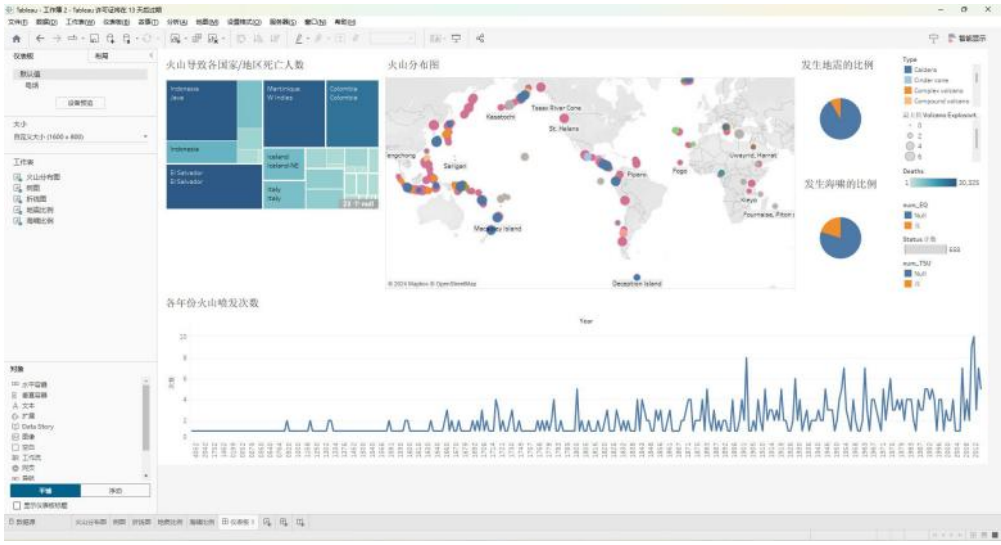

图 5-45　创建仪表板

还可以将仪表板中的工作表用作筛选器，如图 5-46 所示，选中其中部分数据块，仪表板中其他工作表的数据也会被筛选并发生变化。

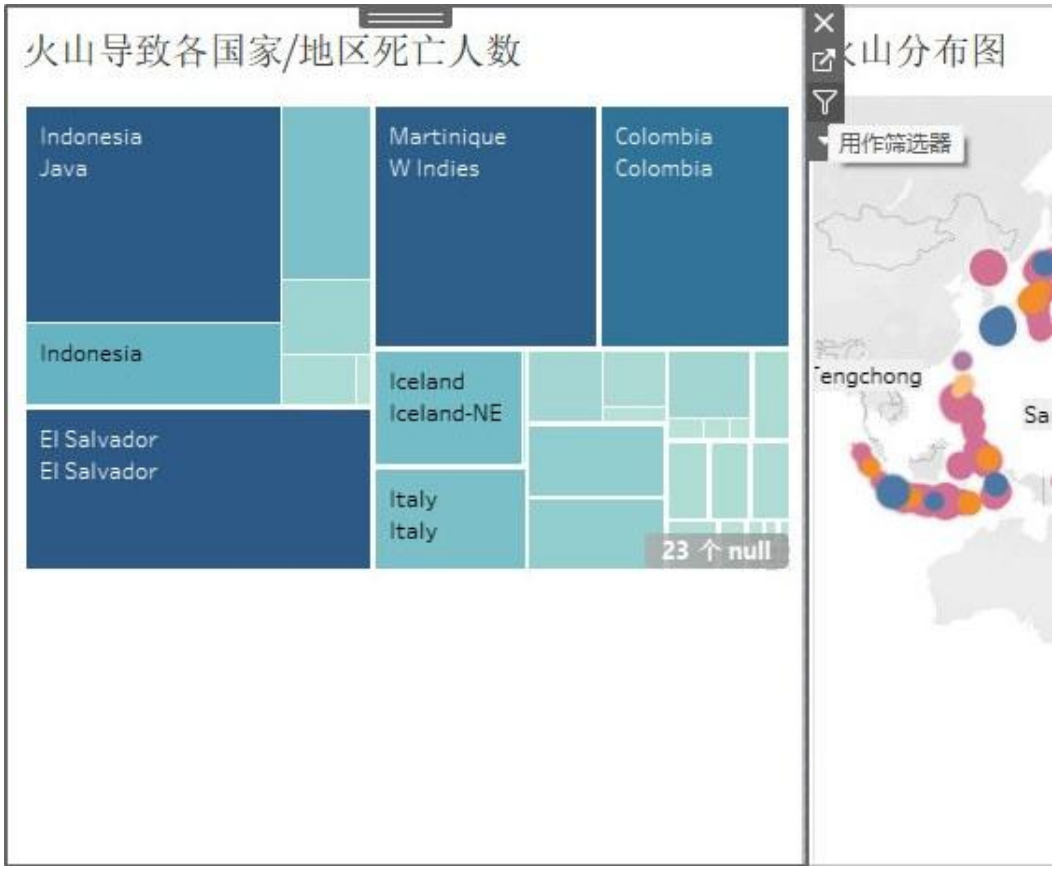

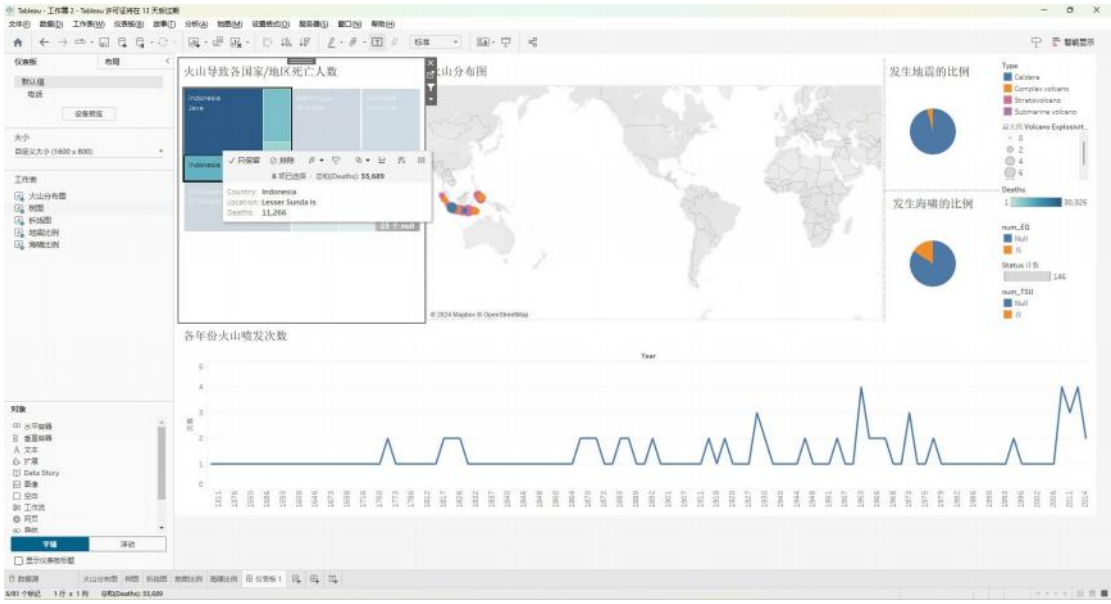
火山导致各国家/地区死亡人数
火山分布图
发生地震的比例
发生海啸的比例
各年份火山喷发次数
Year

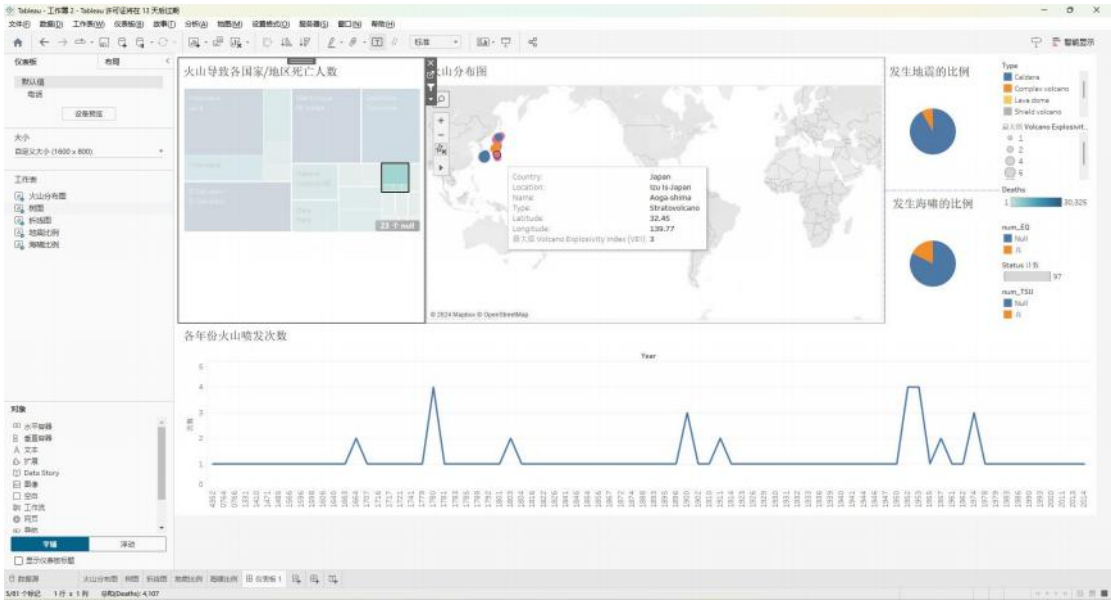
火山导致各国家/地区死亡人数
火山分布图
发生地震的比例
发生海啸的比例
各年份火山喷发次数
Year

发生地震的比例
发生海啸的比例
Caldera
Cinder cone
Deaths
num_EQ
Null
Status 计数
num_TSU
Null

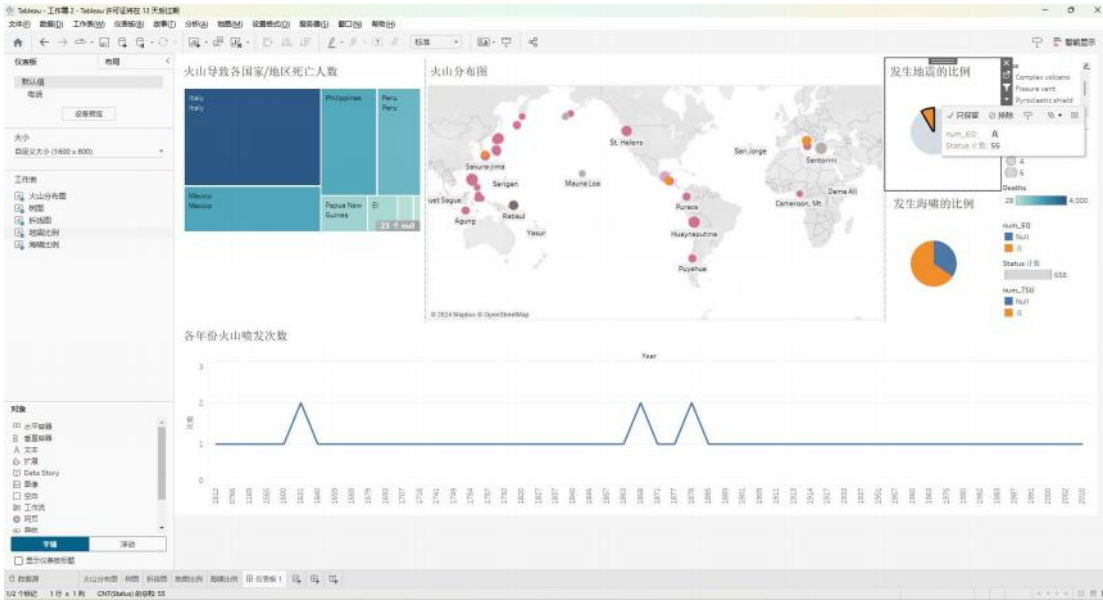

图 5-46　将工作表用作筛选器

至此，完成仪表板的制作，效果如图 5-47 所示。

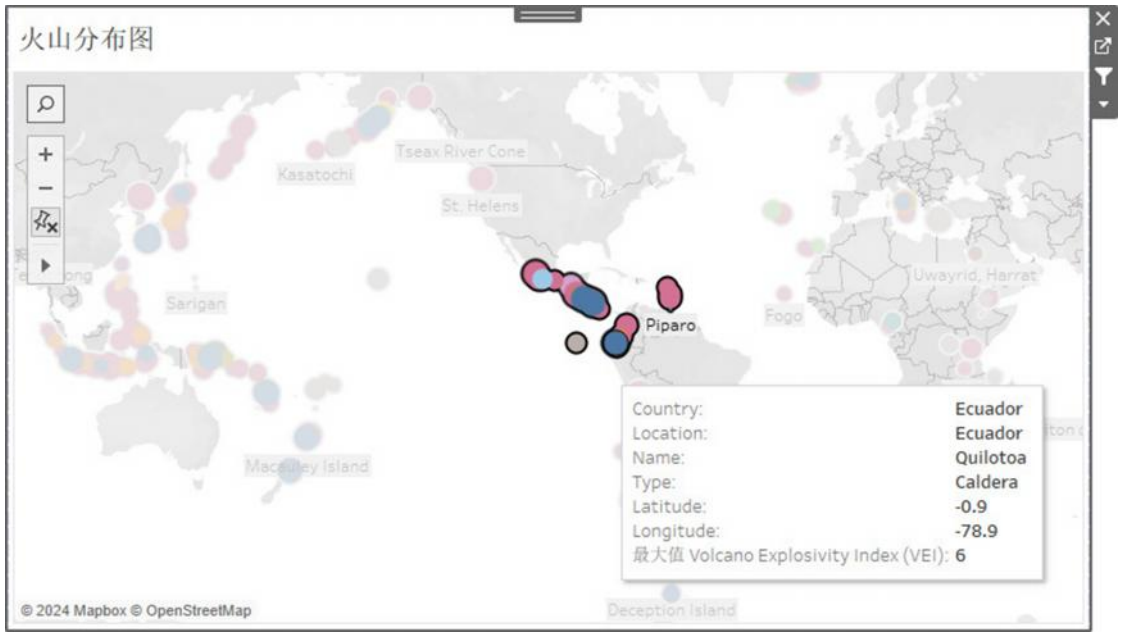

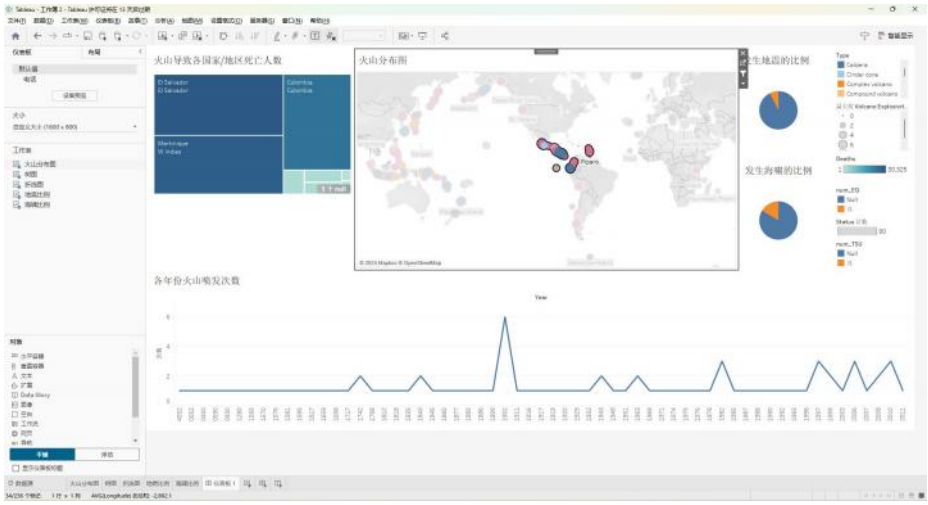

图 5-47　仪表板的最终效果

5.3 Python 数据可视化

5.3.1　Python 数据可视化简介

在 Python 语言中，有大量的数据可视化工具库供调用，常见的有 Matplotlib、seaborn 等库，在 Pandas 库中也内置了数据可视化的方法。

常见的数据可视化图表有散点图、饼图、折线图、直方图、箱线图等，绘制图表的目的是方便展示数据包含的信息，如绘制机器学习模型的性能随着学习次数的变化情况，可以使用折线图；绘制银行用户的受教育程度，可以使用直方图或饼图。图 5-48 为数据可视化示例。

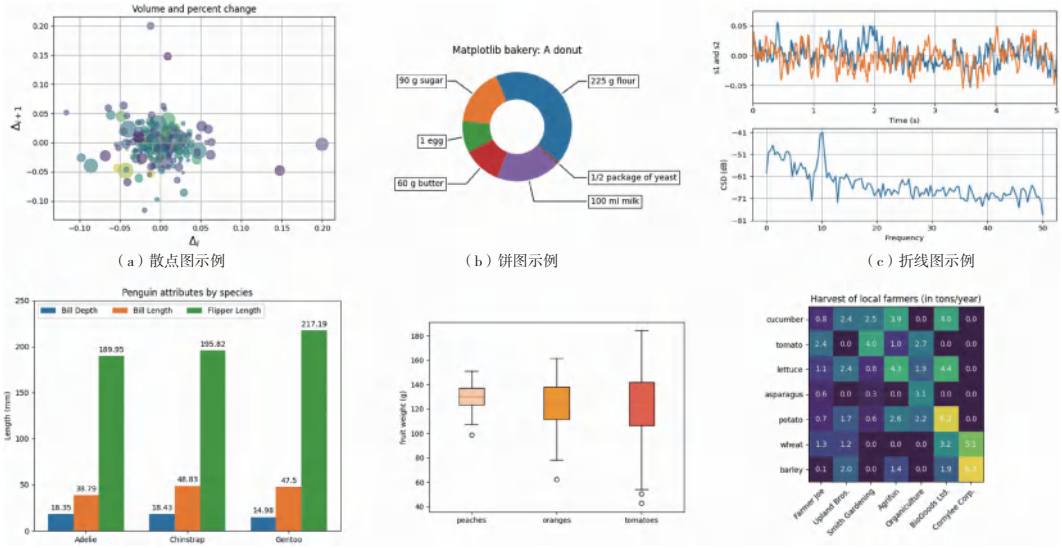

（a）散点图示例　（b）饼图示例　（c）折线图示例

（d）直方图示例　（e）箱线图示例　（f）热力图示例

图 5-48　数据可视化示例

5.3.2　常用的数据可视化工具库

本节介绍常用的数据可视化工具库，包括 Matplotlib、seaborn、Folium 等库。

Matplotlib 库绘图介绍

1. Matplotlib 库

Matplotlib 库是 Python 语言中非常受欢迎的数据可视化工具库之一，支持跨平台运行，它是 Python 语言常用的 2D 绘图库，同时它也提供了一部分 3D 绘图接口。Matplotlib 库通常与 NumPy、Pandas 库一起使用，是数据分析中不可或缺的重要工具之一。

如果用户使用过 MATLAB 这款数据科学分析工具，就可以轻松上手使用 Matplotlib 库。Matplotlib 库提供了一套面向对象绘图的应用程序接口(application program interface，API)，它可以轻松地配合 Python 语言的图形用户界面(graphical user interface，GUI)工具库(如 PyQt、wxPython、Tkinter)在应用程序中嵌入图形。

可以使用如下 pip 命令在命令行窗口中安装 Matplotlib 库：

```
pip install matplotlib
```

使用 Matplotlib 库绘制一个正弦曲线的代码如下，其输出结果如图 5-49 所示。

```
from matplotlib import pyplot as plt
import numpy as np
import math
x=np.arange(0, math.pi*2, 0.05)
y=np.sin(x)
plt.plot(x, y)
plt.xlabel("angle")
plt.ylabel("sine")
plt.title('sine wave')
plt.show()
```

代码首先导入了 Matplotlib、NumPy 和 math 库，其中 math 库是 Python 语言自带的数学计算工具库。plt.plot()函数是用于绘制折线图，plt.xlabel()和 plt.ylabel()函数分别用于在图像的 x 轴和 y 轴上添加标签，plt.title()函数用于添加标题，plt.show()函数用于展示图形。

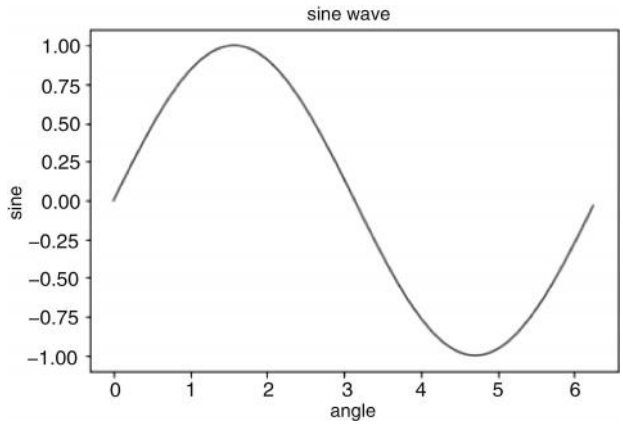

图 5-49　绘制一个正弦曲线

2. seaborn 库

seaborn 库是一个基于 Matplotlib 库的 Python 语言数据可视化库。它提供了一个高级界面，用于绘制有吸引

力且信息丰富的统计图形。seaborn 库是对 Matplotlib 库的封装，其绘图函数接收的参数更少，且绘制的图形更加美观。

seaborn 库帮助用户探索和理解数据。它的绘图函数在包含整个数据集的数据表和数组上运行，并在内部执行必要的语义映射和统计聚合，以生成信息丰富的图表。使用 seaborn 库让用户更关注绘图内容，而不是关注如何绘制图表的细节。

可以使用如下 pip 命令在命令行窗口中安装 seaborn 库：

```
pip install seaborn
```

seaborn 库的绘图方法将在 5.3.3 节做具体介绍。

3. Folium 库

Folium 是地理可视化工具库，可结合 Flask 库搭建地理可视化 Web 服务。Folium 库是地理信息可视化库 Leaflet.js 为 Python 语言提供的接口。可以通过在 Python 程序编辑器窗口中编写代码操纵数据，调用 Leaflet.js 的相关功能，基于内建的开放街道地图（open street map，OSM）或自行获取的 OSM 资源和地图元件进行地理信息内容的可视化，通过不断添加图层元素定义一个 Map 对象，最后以几种方式将 Map 对象展现出来。

可以使用如下 pip 命令在命令行窗口中安装 Folium 库：

```
pip install folium
```

通过 Folium 库可以导入在线地图，并在地图上绘制标记点，用于展示数据信息，如图 5-50 所示。

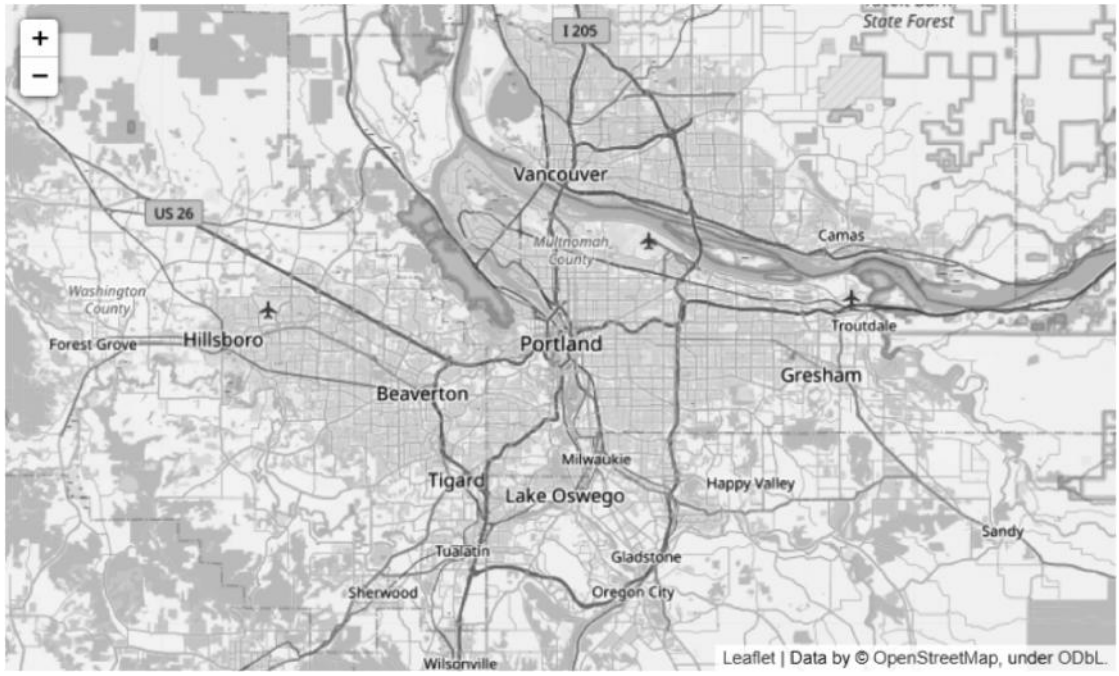

图 5-50　使用 Folium 库在地图上展示数据

4. NetworkX 库

NetworkX 是 Python 语言的一个库，用于构建和操作复杂的图结构，提供分析图的算法。图是由顶点、边和可选的属性构成的数据结构，顶点表示数据，边是由两个顶点唯一确定的，表示两个顶点之间的关系。顶点和边也可以拥有更多的属性，以存储更多的信息。利用 NetworkX 库可以用标准化和非标准化的数据格式存储网络、生成多种随机网络和经典网络、分析网络结构、建立网络模型、设计新的网络算法、进行网络绘制等。

可以使用如下 pip 命令在命令行窗口中安装 NetworkX 库：

```
pip install networkx
```

使用 NetworkX 库可视化图结构数据的代码如下：

```
import networkx as nx
import matplotlib.pyplot as plt
G=nx.petersen_graph()
subax1=plt.subplot(121)
nx.draw(G, with_labels=True, font_weight='bold')
subax2=plt.subplot(122)
nx.draw_shell(G, nlist=[range(5, 10), range(5)], with_labels=True, font_weight=
'bold')
plt.show()
```

其可视化结果如图 5-51 所示。

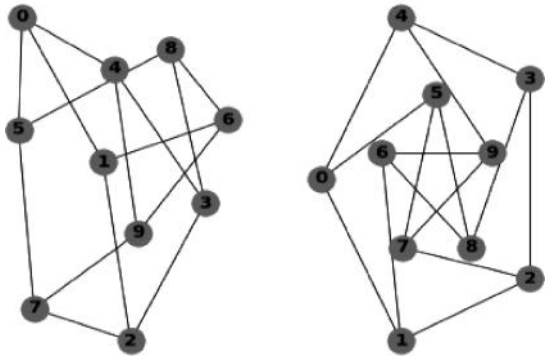

图 5-51　使用 NetworkX 库的可视化结果

5.3.3　统计数据可视化

1. 条形图

本节采用 seaborn 库实现统计数据信息的可视化，其中使用的是美国航空公司航班的延误数据。

```
import pandas as pd
import matplotlib.pyplot as plt
```

```
import seaborn as sns
# 设置文件地址
flight_filepath="flight_delays.csv"
# 读取文件
flight_data=pd.read_csv(flight_filepath, index_col="Month")
# 设置图形大小
plt.figure(figsize=(10, 6))
# 添加图题
plt.title("Average Arrival Delay for Spirit Airlines Flights, by Month")
# 使用条形图绘制各月份航班延误时间
sns.barplot(x=flight_data.index, y=flight_data['NK'])
# y 轴标签
plt.ylabel("Arrival delay(in minutes)")
```

首先导入 seaborn 库，并使用 Pandas 库读取数据，通过 plt 对象进一步设置绘图参数，plt.figure( )函数用于调整图形的大小，sns.barplot( )函数用于绘制条形图，结果如图 5-52 所示。

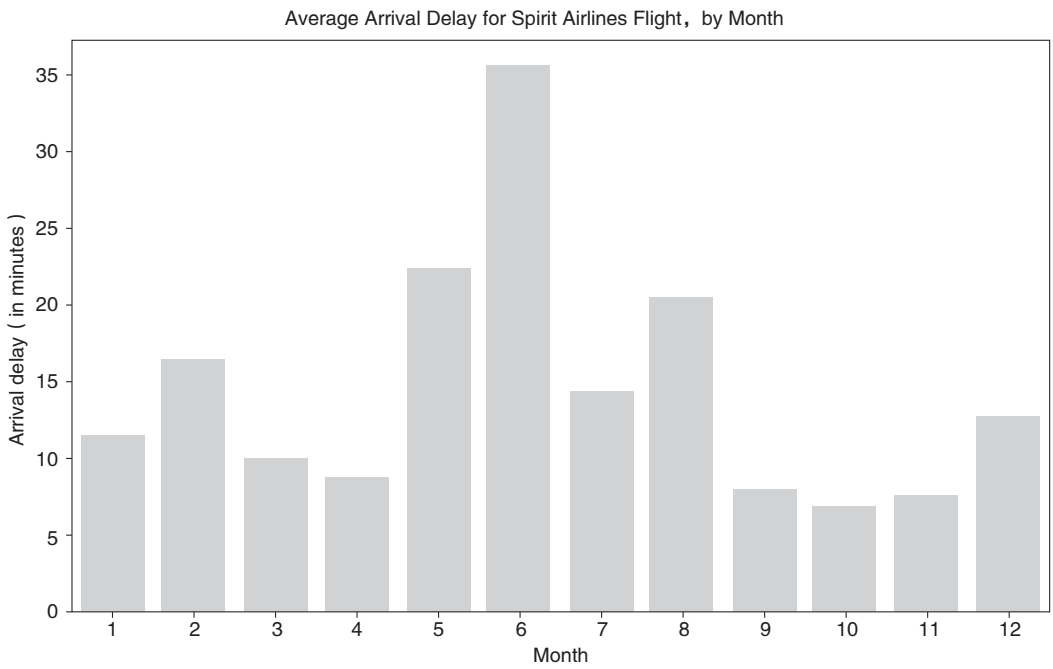

图 5-52　各月份航班延误时间的条形图

从如图 5-52 所示的条形图中可以发现，5—8 月是飞机延误的高峰期，而 9—11 月飞机延误的时间较短。想要到美国旅行可以考虑 9—11 月前往。

2. 热力图

sns.heatmap( )函数用于绘制热力图，通过热力图可以观察样本的分布情况。下面同样

使用美国航空公司航班延误数据来绘制热力图，代码如下：

```
plt.figure(figsize=(14, 7))
plt.title("Average Arrival Delay for Each Airline, by Month")

# 可视化每个航班公司延误时间的热力图
sns.heatmap(data=flight_data, annot=True)
# x 轴标签
plt.xlabel("Airline")
```

输出结果如图 5-53 所示。

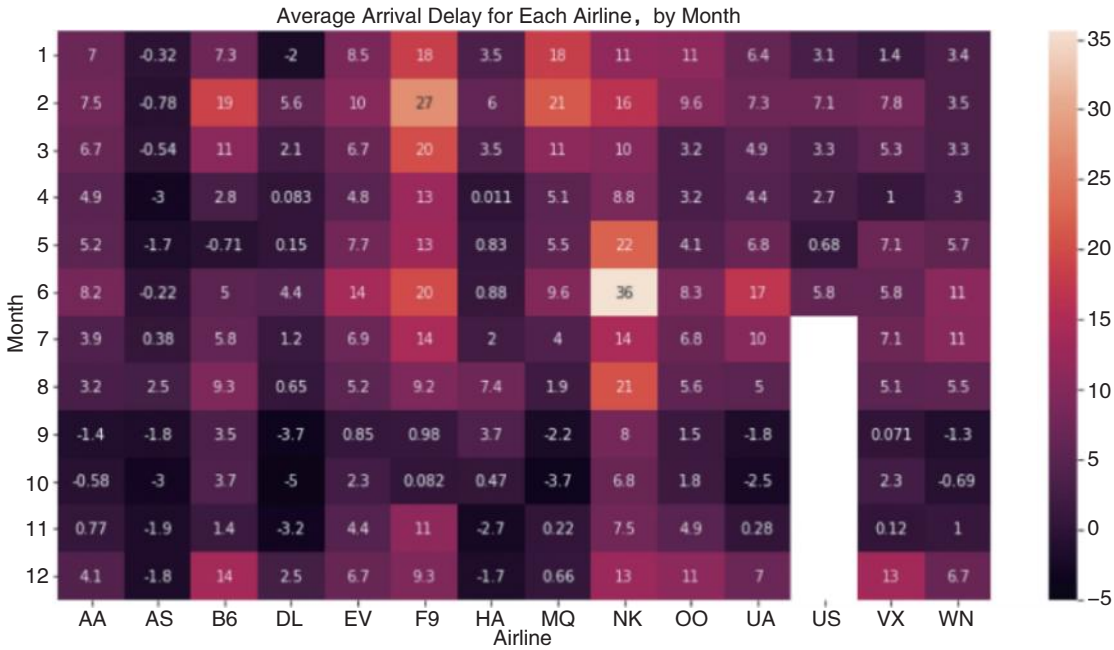

图 5-53　各月份航班延误时间的热力图

在图 5-53 中，热力图中的色块颜色越深，说明飞机提前到达的时间越早，色块的颜色越浅，说明飞机延误的时间越长。从热力图中可以发现，MQ、F9 型飞机的航班较容易延误，而 AS 型飞机航班延误的概率相对较低。

3. 散点图

散点图通常用于观察离散数据的分布情况，根据数据的分布情况，可以挖掘数据所属类别，进行启发式分类。例如，在聚类算法中，经典的二维与三维 k 均值聚类算法很适合使用散点图进行可视化展示。

本节使用购买保险的用户信息来绘制散点图，其中 bmi 字段表示身体质量指数(body mass index，BMI)，也称体重指数，它是一种常用的衡量人体体重与身高之间关系的指标，charges 字段表示用户的保险费用，代码如下：

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

insurance_filepath="insurance.csv"
insurance_data=pd.read_csv(insurance_fil epath)
sns.scatterplot(x=insurance_data['BMI'], y=insurance_data['charges'])
```

上述代码中，sns.scatterplot( )函数用于绘制散点图，输出结果如图 5-54 所示。

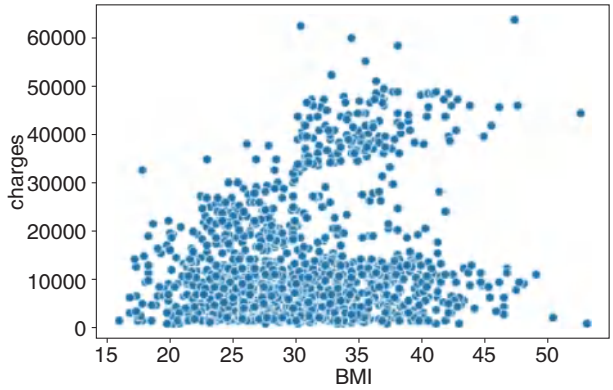

图 5-54　用户的 BMI 值与保险费用散点图

通过图 5-54 的结果不难发现，BMI 值越大的用户，保险费用越高，但数据的变化趋势并不明显。为此，进一步加入用户是否吸烟的特征来绘制散点图，代码如下：

```
sns.scatterplot(x=insurance_data['BMI'],
                y=insurance_data['charges'],
                hue=insurance_data['smoker'])
```

同样使用 sns.scatterplot( )函数图，通过设置参数 hue，巧妙地在二维坐标轴上绘制了三维信息，输出结果如图 5-55 所示。

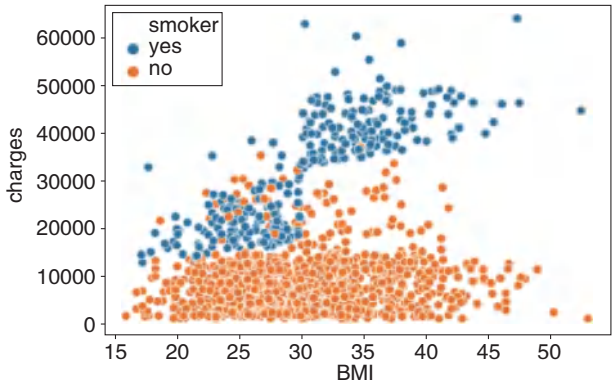

图 5-55　使用参数 hue 绘制包含三维信息的散点图

从图 5-55 中不难发现：如果用户吸烟，则保险费用会随着 BMI 值的增大而增多。

在此基础上，可以使用 seaborn 库内置的线性回归算法对已有数据做回归分析，代码如下：

```
sns.lmplot(x="bmi", y="charges", hue="smoker", data=insurance_data)
```

输出结果如图 5-56 所示。

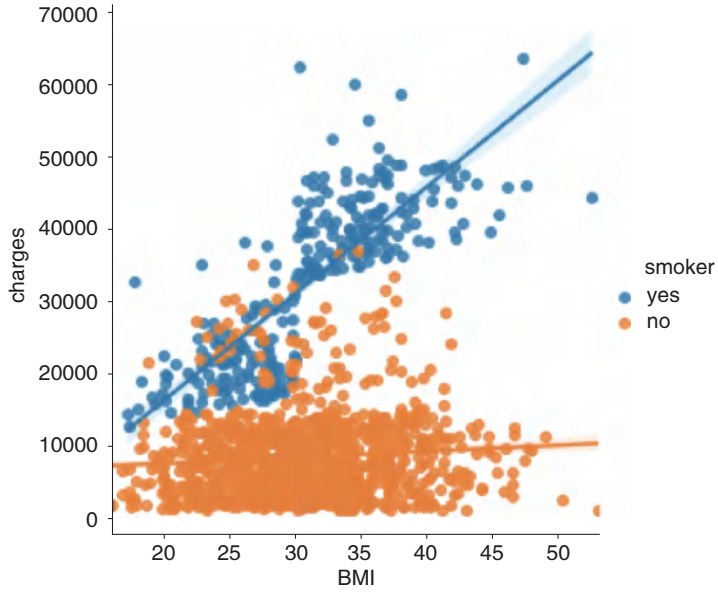

图 5-56　对数据进行回归分析并可视化

习　　题

1. 描述散点图、条形图、折线图分别适用于哪些场景。

2. 学习 Tableau 基础入门系列视频，使用 Tableau 和超市数据来制作工作表与仪表板，视频网址为 http://www.tableau.com/zh-cn/learn/training。

(1)下载 Tableau Desktop(在 https://www.tableau.com/下载免费试用版，在 https://www.tableau.com/zh-cn/academic 验证学生身份可免费使用一年)或 Tableau Public 软件。

(2)下载数据集(网址为 https://www.tableau.com/zh-cn/learn/tutorials/on-demand/getting-started)，如图 5-57 所示。

图 5-57　下载数据集

(3)按照培训视频的指导，制作工作表和仪表板。

3. 运用 Python 的 Seaborn 库和 Spotify 数据集，完成以下操作：

(1)使用折线图函数 lineplot( )绘制不同乐曲的浏览量。

(2)使用 set_style( )方法将图形的底图色彩修改为 dark。

(3)使用 plt. figure( )方法修改图形的大小为(14，6)，并添加图题为 Daily Popular Songs。

习题解析