第 6 章 监督学习常用算法

章节导航

- 了解经典机器学习及监督学习的基本概念。
- 掌握 k 近邻、支持向量机、朴素贝叶斯、决策树等算法的核心思想。
- 掌握常用线性回归算法的核心思想。
- 掌握分类模型和回归模型的常用评价方法。
- 能够使用相应算法解决实际问题。

本章知识导图

机器学习致力于研究如何通过计算手段和经验改善系统自身的性能。图 6-1 是机器学习的基本过程，机器学习算法可以从过去已知的数据(样本)中学习数据隐藏的规律(模型)，使用这些规律，当给定某些输入(新样本)时，可以给出预测结果。

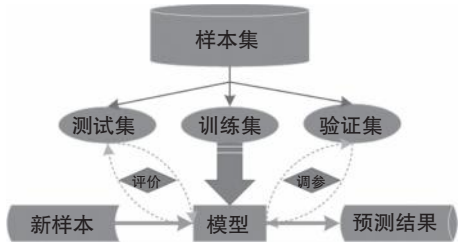

图 6-1　机器学习的基本过程

这里先给出一些机器学习中常用的概念和术语。那些过去已知的数据称为样本；用于学习数据隐藏规律的样本所组成的集合称为训练集；在学习过程中用于确定某些参数(调参)的样本集合称为验证集；在学习完成后，用于测试学习效果的样本集合称为测试集；学习到的规律在新数据上的表现称为泛化能力。具有一定的泛化能力是机器学习模型的基本要求。

有了这些概念，机器学习过程可以描述如下。

机器学习的终极目标是通过学习的方式得到模型，当有数据输入模型时，可以输出用户期望的结果，以解决实际问题。获得模型的过程也称为训练模型。

为了让机器拥有某项功能(如手写体识别功能、人脸识别功能)，首先要根据问题搜集尽可能多的数据(样本)。

得到的数据往往不能直接用于训练，需要提取合适的特征。为了使计算具有可行性，机器学习中的特征必须是用数字描述的向量。提取的特征往往会直接决定最终模型的预测效果，所以特征提取也是一项非常重要的工作。在学习过程中真正参与计算的是这些特征，如果没有特别说明，本章所提及的样本即样本的特征。

通常会将样本集分为训练集、验证集和测试集 3 部分。训练集、验证集用于模型训练

阶段，使用训练集训练模型，使用验证集判断当前模型是否满足要求，满足要求便停止训练模型，不满足要求则调整策略继续训练模型。测试集用于对最终模型进行测试，给出模型的评估结果。

模型通过测试后，便可以投入使用。此时，给模型输入新样本，就会输出预测结果。

在机器学习过程中，如果用到数据的标注信息，则这种学习方式称为监督学习。如果不需要标注信息，则这种学习方式称为无监督学习。监督学习中经典的两个问题是分类和回归。如果模型输出的是连续值，那么该问题是回归问题；如果模型输出的是离散值，那么该问题是分类问题。

本章主要介绍监督学习，第 7 章介绍无监督学习。

6.1 分类问题

分类是机器学习中最重要的一类任务，其利用有类别标签的数据训练一个模型，当输入新样本时，可以输出该样本的类别标签，该模型也称分类模型。此时，标签是离散值，训练得到的模型输出的是离散值，对应的问题常称为分类问题。

常用机器学习建模库介绍

在分类问题中，如果当前问题的类别总数是 2，这种问题称为二分类问题，如垃圾邮件分类就是二分类问题，此时对于给定的样本，模型只需输出“是”或者“否”；如果类别总数大于 2，则这种问题称为多类分类问题，如手写体数字识别，此时共有 10 类样本(0～9)，对于给定的样本，模型需要输出 10 个类别标签中的某一个。

通常将训练得到的分类模型称为分类器，针对二分类问题的模型称为二分类器。多类分类问题可以通过训练多个二分类器来解决，通常有两种方法：一对其余(one versus rest，OVR)法和一对一(one versus one，OVO)法。

一对其余法也称一对多法。假设有 N 类样本，该方法依次将一个类别的样本作为一类，将其余类别的样本作为另一类，训练一个二分类器，该二分类器可以预测样本是否属于该类。这样可以依次获得 N 个二分类器，最终组成多类分类器。在测试阶段，N 个二分类器同时预测，最终类别由预测结果为属于该类的分类器确定。

一对一法与一对其余法的思路类似，但方法不同。仍然假设有 N 类样本，每次从中选取两个类别的样本，训练一个二分类器，该二分类器可以预测样本属于这两类中的哪一类。这样可以得到 $C_N^2=\frac{N(N-1)}{2}$ 个二分类器，最终组成多类分类器。在测试阶段，所有二分类器同时工作，最终通过投票进行类别预测。

比较一对其余法和一对一法，可以看出它们各有优劣。一对其余法需要训练的分类器个数为类别个数 N，比一对一法的分类器个数 $\frac{N(N-1)}{2}$ 少很多，从而运算量较少。但是一对其余法存在训练集不均衡的问题，这会影响每个二分类器的分类效果。另一方面，虽然一对一法的运算量较大，但是只要各类样本数量相当，该方法便没有样本不均衡的问题。在实际使用时，如果样本数量不大，或者对运算速度要求不高，可以优先使用一对一法。

针对多类分类问题，总是可以将其转化为二分类问题。因此，本章主要针对二分类问题来介绍一些常用的经典分类算法。

6.1.1　k 近邻算法

分类的目标是预测新样本的类别。一种朴素的思想是在已知的训练集中，寻找一个与待预测样本最相似的训练样本，将该样本的类别作为预测的类别。相似性可以使用距离度量，距离越小，相似性越大。为此，在样本特征确定的情况下，可以在训练集中寻找与测试样本距离最近的训练样本，用该训练样本的类别作为测试样本类别的预测结果。这种朴素的分类方法是一个经典的机器学习算法——最近邻(nearest neighbor，NN)算法。该算法的基本思想是：为了预测未知样本的类别，以全部训练样本作为代表点，计算未知样本与所有训练样本的距离(特征之间的距离)，选出特征最接近的样本，输出这个样本的类别作为未知样本的预测结果。

特征之间的距离可以使用闵可夫斯基(Minkowski)距离度量，其公式为

$$\rho(\boldsymbol{x},\ \boldsymbol{y})=\sqrt{|x_1-y_1|^p+|x_2-y_2|^p+\cdots+|x_n-y_n|^p}$$

其中，$\boldsymbol{x}=(x_1,\ x_2,\ \cdots,\ x_n)$，$\boldsymbol{y}=(y_1,\ y_2,\ \cdots,\ y_n)$，$p\geqslant 1$。当 $p=1$ 时，该距离称为曼哈顿(Manhattan)距离。当 $p=2$ 时，该距离称为欧几里得(Euclidean)距离。当 $p\to\infty$时，$\rho(\boldsymbol{x},\ \boldsymbol{y})=\max\{|x_1-y_1|^p,\ |x_2-y_2|^p,\ \cdots,\ |x_n-y_n|^p\}$，称为切比雪夫(Chebyshev)距离。

最近邻算法的思想简单明了，易于实现，但是对噪声非常敏感。噪声对最近邻算法的影响如图 6-2 所示，假设三角形样本是一类，正方形样本是一类，其中箭头所指的正方形样本受噪声干扰，比较靠近三角形样本。现在有一个用圆形表示的新样本，如果用最近邻算法预测，由于圆形样本与箭头所指的正方形样本的距离最近，所以输出结果为正方形样本这一类。但从图 6-2 来看，圆形样本更应该属于三角形样本这一类。

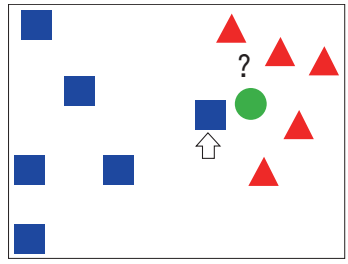

图 6-2　噪声对最近邻算法的影响

仔细分析上述问题，最近邻算法出错的根源在于其只选取一个距离最近的样本来决定输出结果。如果选择若干个接近的样本共同决定输出结果，那么算法就会更为稳健。这正是 k 近邻(k-nearest neighbor，kNN)分类算法的基本思想。k 近邻算法是最近邻算法的一种延伸，后面简称为 kNN 算法。

kNN 算法的基本步骤如下。

(1)计算待分类样本与各个训练样本之间的距离。

(2)按照距离的递增关系进行排序。

(3)选取距离最小的 k 个训练样本。

(4)确定前 k 个训练样本的类别的出现频率。

(5)返回前 k 个训练样本中出现频率最高的类别作为预测的分类结果。

kNN 算法的示意图如图 6-3 所示，当 $k=3$ 时，距离测试样本(圆形)最近的 3 个样本(圈起来的部分)中有 2 个三角形和 1 个正方形，三角形出现了 2 次，正方形出现了 1 次。依照 kNN 算法的第(4)步和第(5)步，此时测试样本的输出结果为三角形。这一结果与实际情况吻合。

kNN 算法可以有效避免最近邻算法对噪声敏感的问题，但是随即也会带来另外一个问题。如图 6-4 所示，当样本不均衡时，即一个类的样本数量很大，而其他类的样本数量很小时，很可能导致测试样本的 k 个接近的邻居中大数量类的样本占多数，但是这类样本并不接近目标样本，而数量小的这类样本更靠近目标样本。

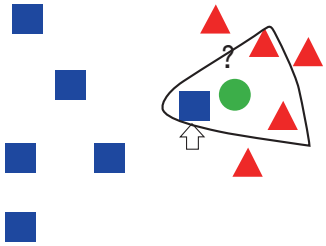

图 6-3　kNN 算法的示意图

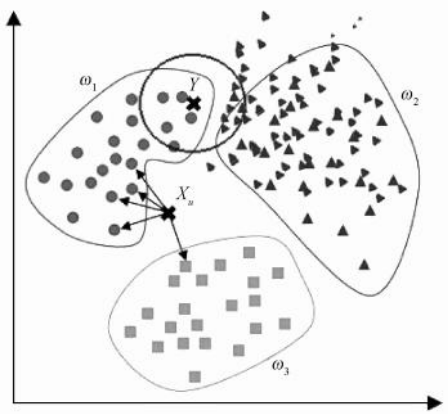

图 6-4　样本不均衡带来的问题

以上问题的根源在于在预测阶段没有考虑 k 个邻居与目标样本的距离差异，直接使用少数服从多数规则做了无差别投票。如果在投票时对 k 个邻居的话语权进行加权，让距离小的邻居权值变大，距离大的邻居权值变小，就可以在一定程度上解决样本不均衡带来的问题。

最后，考虑 k 值对结果的影响。k 值较小时，只有与测试样本较近或相似的训练实例才会对预测结果起作用，相当于用较少的训练样本进行预测，训练误差会减小。但是，与此同时，带来的问题是模型的泛化能力下降，模型容易受到噪声的干扰；k 值较大时，会有更多的训练样本参与预测，这时模型对噪声的抗干扰能力有所提升，但与测试样本较远的(不相似的)训练样本也会对预测起作用，使预测发生错误，导致训练误差增大。

考虑极端情况，当 $k=1$ 时，kNN 算法会变为最近邻算法；当 k 取所有训练样本数时，模型只有一个输出，即样本数最多的类。这两种情况都不是最优的，也就是说肯定存在另一个比较合适的 k 值。那么，在解决实际问题时如何选择 k 值呢？

在 kNN 算法中，k 值在训练之前就已确定，并不是通过学习得到的。这类参数称为超参数，确定超参数的过程称为调参，可以使用超参数搜索方法实现。超参数搜索方法通过调整 k 值，观察模型在验证集上的表现来获取最优 k 值。根据经验，一般情况下 k 值取 5～7 的整数值可以获得良好的效果。

此外，从 kNN 算法的描述中可以得知该算法没有明显的训练过程，不需要预先学习训练样本所蕴含的规律，这种学习方式常称为急切学习，也称积极学习。与之相对的另外一种学习方式，需要通过训练样本学习一个具体的模型，这种学习方式称为惰性学习，也称消极学习。本章后面介绍的学习方式均为惰性学习。

与惰性学习相比，急切学习方法来测试阶段往往需要消耗大量的计算资源。以 kNN 算

法为例，当需要预测新样本的输出时，需要计算测试样本与所有训练样本之间的距离，并对所得距离进行排序。计算距离并排序非常耗时，特别是当训练样本数量庞大时，计算成本非常高。改进这种暴力搜索方式以提升运行速度的策略是预先定义某种特殊的数据结构来存储训练样本，当搜索最近邻样本时，利用这种特殊结构，无须计算所有的距离也能预测出新样本的类别，从而节约时间。kd(k dimensional)树是这种算法的经典实例，在提升运行速度方面效果显著。

6.1.2　支持向量机算法

训练模型的第一步是要提取合适的特征。这里假设特征的维度为 2，即每个样本有 2 个属性，分别用 x_1 和 x_2 表示。如图 6-5 所示，用横轴表示 x_1，用纵轴表示 x_2，则每个样本绘制到坐标平面后就是一个点。这里用形状对类别加以区分：位于坐标系左下角的三角形是一类，位于坐标系右上角的圆形是另一类。

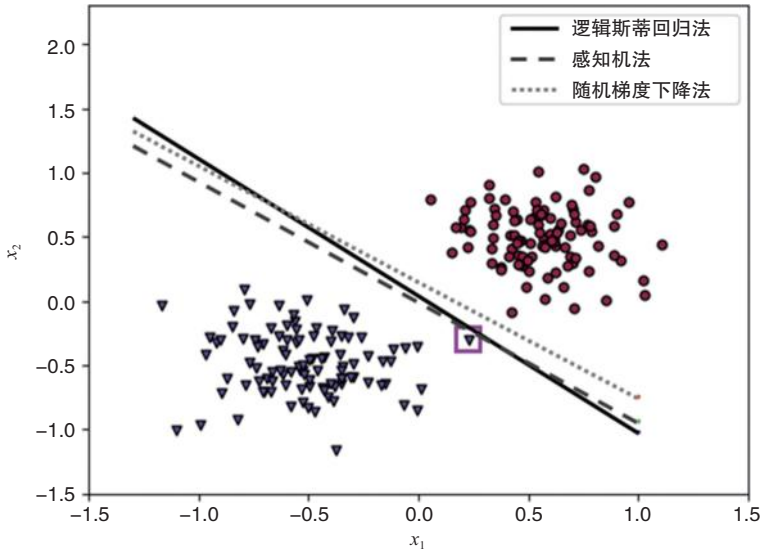

图 6-5　线性分类器示例

对于图 6-5 中的样本，只需求得一条直线，使得这两类样本位于该直线的两侧即可，预测时只要判断目标样本位于直线的哪一侧便可以得到其类别：样本位于直线下方，归到三角形一类；样本位于直线上方，归到圆形一类；样本正好在直线上，归到哪类均可。

这条直线便是要学习得到的分类模型，称为线性模型。图 6-5 中的两类样本可以完全被某条直线分开，这种情形的分类问题称为完全线性可分问题。

针对完全线性可分问题，可以使用逻辑斯蒂回归(logistic regression，LR)法、感知机(perceptron，Perc)法和随机梯度下降(stochastic gradient descent，SGD)法等经典方法进行求解，求解结果如图 6-5 所示，分别对应 3 条直线段。可以看出 3 条直线均能正确地将给定的两类样本完全分开，也就是说能够把这两类样本完全分开的直线并不唯一。

那么，这些直线有没有优劣之分？比较图 6-5 中的 3 条直线，正方形框起来的三角形

样本非常接近逻辑斯蒂回归法和感知机法对应的直线，这意味着如果对该样本做一个非常小的扰动，比如测量或统计带来的误差，那么该样本将跨过直线到达另一侧，从而导致分类错误，也就是说模型对误差非常敏感。相比而言，随机梯度下降法好一些，但是在圆形样本中也有距离该直线较近的样本点，这在一定程度上也会导致模型对误差较为敏感。

因此，针对完全线性可分问题，如何判定分类模型的优劣是首先要考虑的问题。直观来看，如果两类样本均尽可能地远离模型，也就是模型正好位于所有样本中间，那么模型就将两类样本分得最开，从而最大限度地降低噪声的影响。

支持向量机正是基于这一考虑，以间隔最大化作为目标函数，以此求出能将两类样本分得最开的直线模型。针对图 6-5 中的样本，训练的线性支持向量机模型如图 6-6 所示，其中位于样本边界的两条直线之间的间隔正是最大间隔，位于该间隔正中央的直线正是最佳分类直线模型。此外，位于边界直线上的样本称为支持向量，本例共有两个支持向量，分属于两类样本。直观上来看，支持向量是确定支持向量机模型的核心。

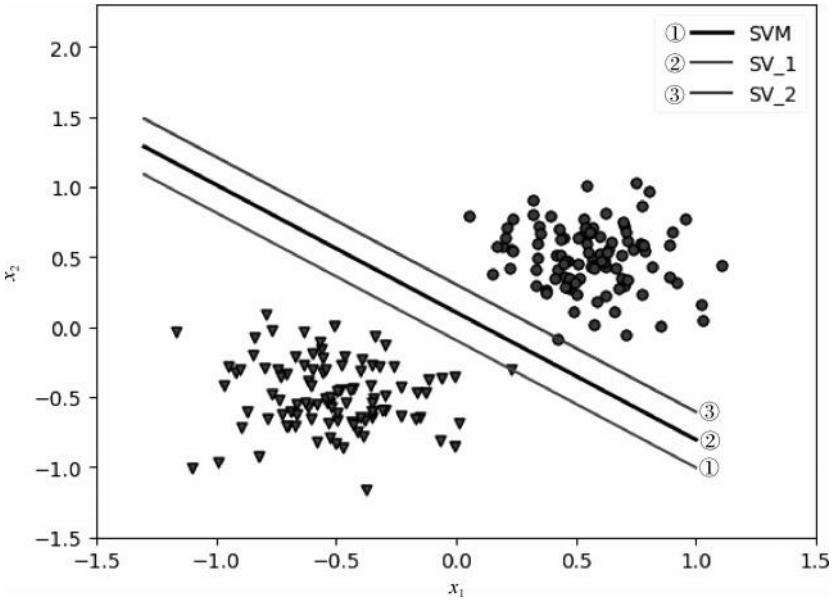

图 6-6　线性支持向量机模型的分类结果(硬间隔)

仔细分析以上间隔最大化模型，间隔中间没有样本，这种间隔称为硬间隔。这种硬间隔最大化方法可以较好地解决完全线性可分问题，但是也存在一定的缺陷：一方面，图 6-6 中的支持向量均远离各自的样本中心(直观来看就是两类样本各自较集中的位置)，如果严格以这两个样本作为支持向量，不够合理，因为它们本身可能带有测量或者统计等误差；另一方面，现实问题中这种完全线性可分的情形很少出现，大多数情况是非完全线性可分问题，即无法找到一条直线将两类样本完全分开，但是在允许一定误差的前提下，又可以近似地用直线来区分这两类样本。

针对以上缺陷，将硬间隔条件适当放宽，允许部分样本落入间隔，这样的间隔称为软间隔，如图 6-7 所示。最后将硬间隔最大化修改为软间隔最大化，即可得到更一般的线性

支持向量机模型。在该模型中含有大于零的参数 C（图 6-7 的结果中 C 取 1），称为惩罚系数，用来调节软间隔：C 越大，间隔中的样本越少，此时软间隔越趋于硬间隔；C 越小，间隔中允许存在越多的样本。参数 C 是超参数，可以通过经验指定，也可以通过超参数搜索方法确定。

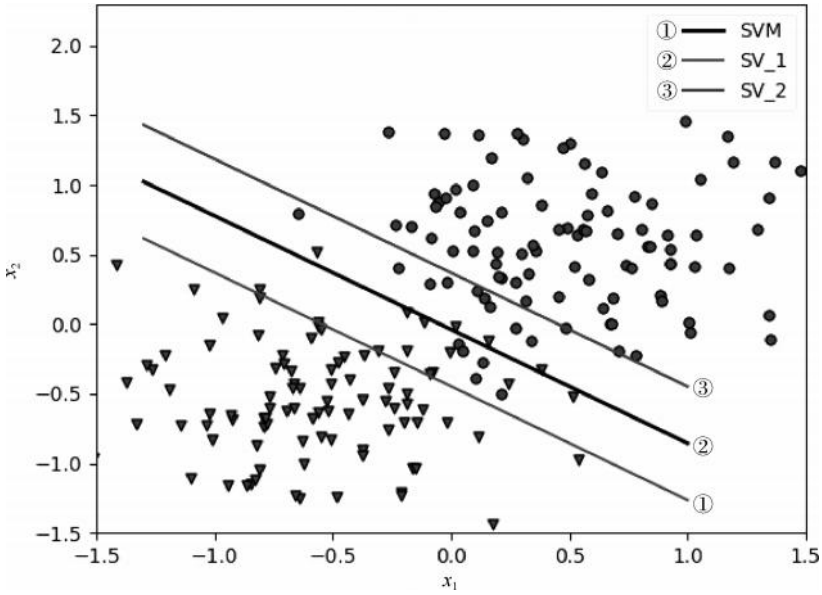

图 6-7　支持向量机的软间隔示意图

为了与硬间隔最大化的结果对比，图 6-8 是基于软间隔最大化的支持向量机模型的分类结果，其中惩罚系数 $C=1$。

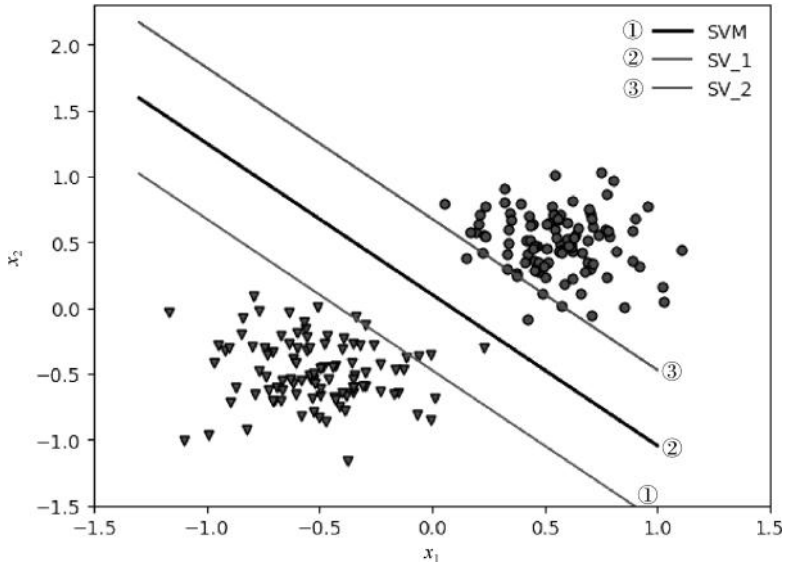

图 6-8　软间隔最大化的支持向量机模型的分类结果

分析图 6-8 的结果，可以发现当前的间隔中有很多样本，这与软间隔的定义一致。与图 6-6 的结果对比，可以发现，当前的结果有效地回避了图 6-6 中两个支持向量的问题，而且除去间隔中的那些样本，直观来看当前的直线模型更趋向于处在两类样本的正中位置。

以上讨论的问题中样本特征有两个维度，这时线性模型就是平面中的直线。当样本特征的维度为 3 时，线性模型是三维空间中的平面。当样本特征的维度超过 3 时，线性模型称为超平面。超平面是直线和平面的推广，直线和平面是超平面的特殊情形，以下统一用超平面进行描述。一般地，类似于图 6-6，如果样本能够被超平面完全分开，那么该问题称为完全线性可分，该问题可以使用线性支持向量机求解；类似于图 6-7，如果任意超平面均不能完全将样本分开，但是忽略个别样本后可以近似线性可分，这样的问题仍然可以使用线性支持向量机求解。

总之，针对完全线性可分或者近似线性可分问题，线性支持向量机是一种有效的分类算法。但是针对球形样本，如图 6-9 所示，线性支持向量机就无能为力了，因为根本无法找到一条直线将这两类样本分开或近似分开。

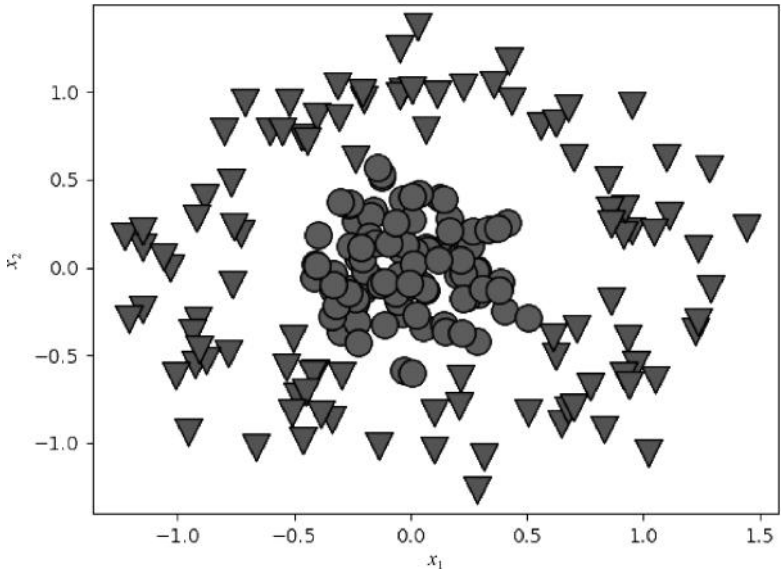

图 6-9　球形样本

球形样本在二维空间不是线性可分的，但是如果把它们映射到更高维的空间，则有可能变成线性可分的。这里将映射定义为

$$(x_1,\ x_2) \mapsto \left(x_1,\ x_2,\ \frac{1}{2\pi\sigma^2}\mathrm{e}^{-\frac{x_1^2+x_2^2}{2\sigma^2}}\right)$$

经过映射以后的样本分布如图 6-10(a)所示，原来在二维平面上位于球形样本周围的三角形样本，经过映射以后，在三维空间中主要分布于“山腰”，原来位于中间位置的球形样本在三维空间中主要分布于“山顶”。要将山顶部分和山腰部分隔开，一种最简单的方式就是“拦腰斩断”，如图 6-10(b)所示。也就是说，在三维空间可以找到一个平面将山顶的球形样本和山腰的三角形样本很好地分开，这个平面正是线性分类模型。

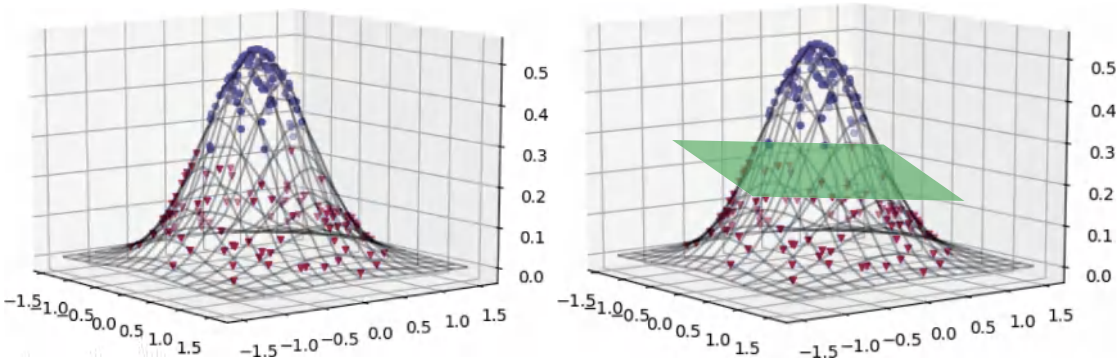

（a）将二维空间的球形样本映射到三维空间　　（b）三维空间的样本是线性可分的

图 6-10　低维空间的不可分样本在高维空间具有可分性

但是以上思路难以直接付诸实施，主要原因是：从低维空间到高维空间的映射众多，针对具体问题如何选取合适的映射是一个难题；即使碰巧找到合适的映射，在高维空间直接进行运算也会带来非常大的计算开销。一个行之有效的变通方法称为核技巧，基本思路是在支持向量机模型中使用核函数，这样便无须显式地给出低维空间到高维空间的映射，而且避免了在高维空间进行运算量较大的内积运算。这种方法常称为非线性支持向量机，其中常用的核函数有高斯核函数、多项式核函数、线性核函数等。特别地，当核函数取为线性核函数时，非线性支持向量机退化为线性支持向量机。

6.1.3　朴素贝叶斯算法

针对给定的测试样本 x，如果能够确定 x 出现的情况下类别标记 y 出现的概率，即后验概率 $P(Y=y \mid X=x)$，那么根据最大后验概率准则，选择后验概率最大的类别 y 作为样本 x 的类别即可。所以，核心问题是如何求出后验概率。

垃圾邮件分类案例

逻辑斯蒂回归法直接对后验概率建模，从而确定每个类别的后验概率。这种通过直接对后验概率建模得到的分类模型称为判别式模型。除此之外，如感知机和支持向量机，这种由数据直接学习得到的分类模型[判别函数 $f(x)$]，也属于判别式模型。

与判别式模型不同，还有一类模型是通过贝叶斯公式 $P(Y \mid X)=\dfrac{P(X, Y)}{P(X)}=\dfrac{P(X \mid Y)P(Y)}{P(X)}$，将问题转化为学习联合概率分布 $P(X, Y)$，即特征 X 和类别标记 Y 共同出现的概率。这类模型称为生成式模型，其优势是能够学习到数据生成的机制。以贝叶斯定理为基础的这类分类算法统称为贝叶斯分类算法，是典型的生成式模型。其中，尤以朴素贝叶斯分类算法最为简单，也是常见的一种分类方法。

重新考察贝叶斯公式，由于 $P(X)$ 与类别标记 Y 没有关系，所以后验概率正比于联合概率，即

$$P(Y \mid X) \propto P(X, Y)=P(X \mid Y)P(Y)$$

如此，问题转化为如何获得类先验概率 $P(Y)$ 和类条件概率 $P(X \mid Y)$。

类先验概率可以通过样本的类别分布使用频率近似得到。由于实际问题中特征的维度往往较大，训练样本的数量往往很难满足计算类条件概率的要求，所以直接计算类条件概率的难度很大。为此，可以通过假设对问题进行简化。朴素贝叶斯模型正是基于特征条件独立的假设：对已知类别，所有特征相互独立。在该假设下，类条件概率 $P(X \mid Y)$ 便可以通过如下方式获得：

$$P(X=x \mid Y=y)=P(X^{(1)}=x_1 \mid Y=y)\cdots P(X^{(n)}=x_n \mid Y=y)$$

其中，n 是特征的维度，$P(X^{(i)}=x_i \mid Y=y)$ 是在类别标记是 y 的情况下，第 i 个特征取值为 x_i 的概率，该概率往往容易求得。

朴素贝叶斯算法在垃圾邮件过滤等文本分类任务中表现出色，并得到广泛应用。此外，该算法有清晰的数学背景，逻辑简单，易于实现，在时间和存储方面的开销较小。但是，它也有一些明显的缺点。如特征条件独立的假设在实际应用中往往是不成立的，在特征个数比较多或者特征之间相关性较大时，分类效果会大打折扣。

6.1.4 决策树算法

有一位骑行爱好者，他的日程安排中每周六上午骑行。但是能否成行也要看当天的天气、温度、湿度和风力情况。他记录了连续 14 周是否骑行与环境相关的数据，如表 6-1 所示。

表 6-1 是否骑行与环境相关的数据

编号	天气	温度	湿度	风力	是否骑行
1	晴天	热	高	弱	否
2	晴天	热	高	强	否
3	阴天	热	高	弱	是
4	下雨	暖和	高	弱	是
5	下雨	凉爽	正常	弱	是
6	下雨	凉爽	正常	强	否
7	阴天	凉爽	正常	强	是
8	晴天	暖和	高	弱	否
9	晴天	凉爽	正常	弱	是
10	下雨	暖和	正常	弱	是
11	晴天	暖和	正常	强	是
12	阴天	暖和	高	强	是
13	阴天	热	正常	弱	是
14	下雨	暖和	高	强	否

表 6-1 中反映的客观事实本质上是一个分类问题，天气、温度、湿度和风力是属性(特征)，是否骑行可以看作类别。表 6-1 也可以用树形结构表示，如图 6-11 所示。其中图 6-11(a)和图 6-11(b)的树中，分支点表示属性(特征)，每个分支点根据其取值确定分支，叶子节点表示类别。通常将这种树称为决策树，它可以用众多 if-then 规则实现，具有简洁、易实现等优点。因为叶子节点均为类别，所以对于任意样本，总是能够从根节点依照该样本

各属性的值到达某个叶子节点，从而确定出类别。

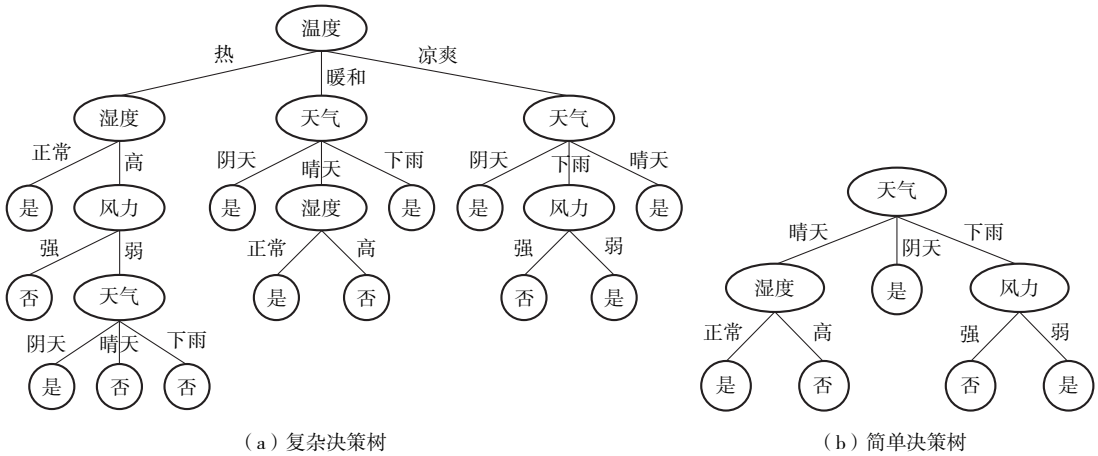

（a）复杂决策树　　（b）简单决策树

图 6-11　决策树

可以发现，图 6-11 中的两棵树均能够正确地描述表 6-1，但是两棵树明显地存在优劣之分。比较来看，显然图 6-11(b)中树的深度小，分支点少，整体更为简洁，从计算成本来说，具有明显的优势。显而易见，图 6-11(a)和图 6-11(b)的区别在于分支点的属性。因此，构建好的决策树的关键就是对每个分支点(从根节点开始)寻找最优属性，即寻找最优划分属性，使得树的深度尽可能小。

为了探究划分属性如何影响树的深度，不妨比较图 6-11(a)和图 6-11(b)中两棵树的根节点。对于图 6-11(b)来说，按照根节点天气的 3 个取值：晴天、阴天和下雨，可以将样本分为{1，2，8，9，11}、{3，7，12，13}和{4，5，6，10，14}。考察每个样本子集中样本的类别分布，它们分别为“否否否是是”、“是是是是”和“是是否是否”。对于图 6-11(a)来说，按照根节点温度的 3 个取值：热、暖和、凉爽，可以将样本分为{1，2，3，13}、{4，8，10，11，12，14}和{5，6，7，9}。它们的类别分布分别为“否否是是”、“是否是是是否”和“是否是是”。比较天气和温度作为划分属性所得样本子集的类别分布，不难发现，使用天气进行划分能够得到更“纯”的类别分布。

那么，划分后类别“纯度”高是不是图 6-11(b)优于图 6-11(a)的根本原因呢？不妨先考虑一种极端情况，现在新增一个属性——心情，假设心情好时风雨无阻去骑行，心情不好时无论如何都不去。那么使用心情作为划分属性，将会产生“纯度”最高的类别分布：心情取值为好的样本归为“是”这一类，心情取值为不好的样本归为“否”这一类。此时，使用心情已经可以将所有样本分开，无须继续分下去，所以树的深度只有 1。显然，现在心情是最好的划分属性。

因此，这里为选择划分属性提供了一个依据：在构建决策树时，针对每个节点，类别分布“纯度”提升最大的属性应该被优先选择为划分属性。

那么，如何定量地刻画“纯度”？一个基本的事实是显而易见的，即类别分布越趋于均匀，纯度越低；反之，类别分布越趋于失衡，纯度越高。类别分布的均衡性可以由信息熵反映出来，所以信息熵与“纯度”密切相关。经典的决策树算法 ID3 正是基于信息熵来确定

最优划分属性的。

为了叙述方便，引入一些记号。设 Y 表示类标记集合，第 k 类样本所占比例为 p_k，D 表示样本集，A 表示属性集合，属性 a 可能的取值记为 a^1，a^2，…，a^V，取值为 a^v 的样本集合记为 D^v。D 的信息熵为

$$H(D)=-\sum_{k=1}^{|Y|}p_k\log_2 p_k$$

其中，约定 $0\log_2 0=0$。由上述讨论可知，信息熵越小，纯度越高；反之，信息熵越大，纯度越低。

针对属性 a，定义属性 a 的条件熵为

$$H(D\mid a)=\sum_{v=1}^{V}\frac{|D^v|}{|D|}H(D^v)$$

由上式可知，属性 a 的条件熵是 a 的每个取值确定的类别分布的熵的加权平均，权重为该取值下样本数占所有样本数的比重，它描述了使用属性 a 进行划分而得到的类别分布的“不纯度”，值越小，“纯度”越高。条件熵的大小正好与“纯度”的高低相反，为了保持其与“纯度”的高低一致，这里引入属性 a 的信息增益，其定义为

$$G(D,a)=H(D)-H(D\mid a)$$

属性 a 的信息增益描述了使用属性 a 作为划分属性，划分之后的类别分布比划分之前的类别分布的“纯度”提升程度：信息增益 $G(D,a)$ 越大，使用属性 a 进行划分所获得的“纯度”提升越大。因此，在选择划分属性时，应该选择信息增益最大的属性。

图 6-11(b)中的决策树正是使用这一策略获得的。那么解决了如何选择划分属性的关键问题之后，怎样构建一棵完整的决策树呢？不难发现，使用递归方式逐层确定最优划分属性即可完成。

仔细分析可以发现，信息增益对可取值数目较多的属性有所偏好。在相同条件下，取值多的属性比取值少的属性的信息增益大。如果把编号也看成属性，那么很容易算得编号的条件熵 $H(D\mid 编号)=0$，从而信息增益 $G(D,编号)=0.940$，与其他属性相比，编号的信息增益最大。但是，编号作为属性显然没有任何区分度，对分类任务没有任何帮助。因此，需要对取值多的属性做必要的抑制，为此引入属性 a 的特征熵，即

$$H_a(D)=-\sum_{v=1}^{V}\frac{|D^v|}{|D|}\log_2\frac{|D^v|}{|D|}$$

显然，当属性的取值变多时，其特征熵具有增大的趋势。可以使用特征熵的倒数对信息增益进行抑制，解决信息增益对可取值数目较多的属性有所偏好的问题，即引入增益率

$$G_r(D,a)=\frac{G(D\mid a)}{H_a(D)}$$

这正是决策树算法 C4.5 的核心，它改进了 ID3 算法。C4.5 算法在选择划分属性时使用了启发式：先从候选划分属性中找出信息增益高于平均水平的属性，再从中选择增益率最高的属性作为最终划分属性。

在构建决策树的过程中，有可能出现所有属性的判别指标(信息增益或增益率)都很小的情况，这意味着每个属性作为划分属性均不会明显提升“纯度”。此时该节点不应该继续划分，应该作为叶子节点。为此可以引入阈值，如果某节点处最优划分属性的信息增益(或

增益率)小于该阈值，则该节点不再生成子节点，而将其作为叶子节点。

除了基于信息熵的信息增益和增益率，基尼(Gini)指数也可以用来划分属性。样本集 D 的基尼指数的定义为

$$\mathrm{Gini}(D)=1-\sum_{k=1}^{|Y|}p_k^2$$

基尼指数反映了从数据集 D 中随机抽取两个样本，其类别标记不一致的概率。因此，$\mathrm{Gini}(D)$越小，则数据集 D 的“纯度”越高，这一性质与数据集 D 的信息熵是一致的。这里给出理论方面的说明。为此，将 $-\log_2 x$ 在 $x=1$ 处一阶泰勒展开，忽略高阶无穷小项，可以得到如下关系：

$$-\log_2 p_k \approx \frac{1}{\ln 2}(1-p_k) \propto 1-p_k$$

此时，信息熵

$$H(D)=-\sum_{k=1}^{|Y|}p_k\log_2 p_k \approx \frac{1}{\ln 2}\sum_{k=1}^{|Y|}p_k(1-p_k) \propto \sum_{k=1}^{|Y|}p_k(1-p_k)=1-\sum_{k=1}^{|Y|}p_k^2$$

所以，数据集 D 的基尼指数与信息熵有一致的大小关系。这就解释了在衡量数据集 D 的“纯度”方面，基尼指数与信息熵为什么具有相似的性质。

既然如此，采用基尼指数也可以描述类别分布的“纯度”。类似于属性 a 的条件熵，定义属性 a 的基尼指数为

$$\mathrm{Gini}(D,a)=\sum_{v=1}^{V}\frac{|D^v|}{|D|}\mathrm{Gini}(D^v)$$

属性 a 的基尼指数与属性 a 的条件熵具有类似的性质：属性 a 的基尼指数越小，用属性 a 作为划分属性得到的类别分布的“纯度”越高。因此，如果使用基尼指数选择划分属性，应该选择基尼指数最小的属性。这也正是决策树算法 CART 采用的方法，与 ID3 算法和 C4.5 算法不同，CART 算法在构建决策树时，无论属性的取值个数是多少，每次只考虑二值情况，如针对属性天气，可以先考虑晴天和非晴天，然后针对非晴天，再考虑阴天和下雨。这样一来，CART 算法产生的决策树是二叉树，而不是像 ID3 和 C4.5 算法那样产生多叉树。与多叉树相比，二叉树在实现效率方面具有明显的优势。

6.1.5　分类模型的评价

在二分类问题中，通常根据实际情况将一类样本记为阳性(positive)，将另一类样本记为阴性(negative)。在衡量模型的预测能力时，通常关注两类错误：一是误检，即本来是阴性的样本，模型预测为阳性，常称为假阳性(false positive，FP)；二是漏检，即本来是阳性的样本，模型预测为阴性，常称为假阴性(false negative，FN)。正确结果也有两类：一是真阳性(true positive，TP)，即本来是阳性的样本，模型预测为阳性；二是真阴性(true negative，TN)，即本来是阴性的样本，模型预测为阴性。

常用评价指标

在评价二分类模型时，通常考虑阳性类别的精确率(precision)P、召回率(recall)R 和 F_1 值，计算方法为

$$P=\frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}},\ R=\frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}},\ F_1=\frac{2PR}{P+R}$$

其中，FP、FN、TP 和 TN 分别表示测试集中假阳性、假阴性、真阳性和真阴性的样本数量。当衡量模型在测试集上的综合性能时，可以考察准确率 A，其计算方法为

$$A=\frac{\mathrm{TP}+\mathrm{TN}}{\mathrm{TP}+\mathrm{TN}+\mathrm{FP}+\mathrm{FN}}$$

针对多类分类问题，当关注某个类别的评价时，可以将该类看作阳性，将其余的类别都视为阴性，单独计算模型在该类的精确率 P、召回率 R 和 F_1 值。此时 TP 表示正确预测为该类别的样本数，FP 表示预测为该类别但不是该类别的样本数，FN 表示是该类别但预测为其他类别的样本数，TN 表示不是该类别且预测结果也不是该类别的样本数。

准确率描述了模型预测正确的比例，所以多类分类模型的准确率 A 定义为

$$A=\frac{T}{N}$$

其中，N 为测试样本总数，T 为预测正确的样本总数，即每个类别正确预测的样本量的总和。

6.2 回归问题

作为监督学习的代表，分类问题和回归问题在现实生活中随处可见。分类问题中的标注信息是离散的，从而模型输出的是离散值；回归问题中的标注信息是连续的，从而模型输出的是连续值。6.1 节介绍的分类算法中，除了朴素贝叶斯算法，其他算法稍加改造均可解决回归任务，算法原理基本一致，这里不再赘述。本节将重点介绍基本的线性回归模型。

分类与回归的关系

6.2.1 线性回归模型

1. 最小二乘回归模型

假设经过特征提取后样本共有 n 个特征，特征向量 $\boldsymbol{x}$ 的维度为 n。在提取特征的方式确定后，每个样本的特征具有唯一性，所以对样本和特征不做区分，提到样本即指其特征向量。设共有 m 个样本，表示为向量 $\boldsymbol{x}_i$，$i=1, 2, \cdots, m$，第 i 个样本的标注信息（真实输出值）为 y_i。

如果回归问题中的标注信息和特征向量之间存在线性关系，就可以学习一个线性回归模型，用以对新出现的数据进行预测。为了便于理解，这里考虑一维特征的情况。如图 6-12 所示，横坐标是特征，纵坐标是标注，每个圆点对应一个样本。直观来看，这些点基本呈线性关系，如果能够找到一个一元线性函数（一条直线）将这种关系描述出来，就能够预测新样本的输出。这就是线性回归的本质：在训练数据基

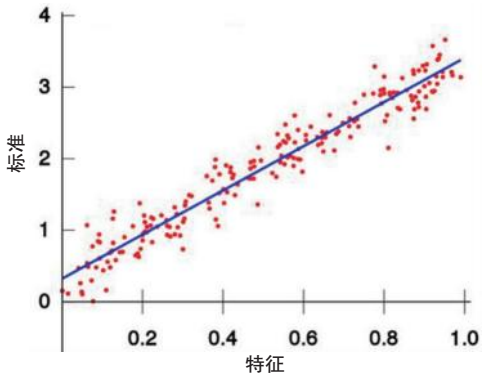

图 6-12　线性回归示意图

本呈线性关系的前提下，寻找一个线性函数，最大限度地描述训练数据所蕴含的规律。

为此，设所求线性函数为

$$f(\boldsymbol{x})=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b$$

其中，$\boldsymbol{w}=(w_1, w_2, \cdots, w_n)^{\mathrm{T}}$ 是系数，b 是截距，也称为偏置。线性回归的任务便是通过训练样本求解系数 $\boldsymbol{w}$ 和截距 b。

在最小二乘准则下，可以通过求解以下优化问题获得最优参数：

$$(\boldsymbol{w}^*, b^*)=\arg\min_{(\boldsymbol{w}, b)}\sum_{i=1}^{m}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i+b-y_i)^2$$

其中，$\sum_{i=1}^{m}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i+b-y_i)^2$ 称为平方损失，描述了训练样本的模型输出值和实际值之间的总误差。

将平方损失分别对系数 $\boldsymbol{w}$ 和截距 b 求偏导，并令偏导数等于零，可以求得上述优化问题的解析解为

$$(\boldsymbol{w}^*; b^*)=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{y}$$

其中，$\boldsymbol{X}=\begin{pmatrix}\boldsymbol{x}_1 & \boldsymbol{x}_2 & \cdots & \boldsymbol{x}_m\\ 1 & 1 & \cdots & 1\end{pmatrix}^{\mathrm{T}}$。注意到解析解中包含矩阵求逆的运算，需要 $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$ 是满秩矩阵，这就要求样本个数远大于特征的维度，才能保证解的稳定性。当样本个数不足，接近特征维度时，$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$ 即使满秩也容易形成病态矩阵(例如在数据存在多重共线性的情况下)，此时最小二乘法对输入变量中的噪声非常敏感，其解会很不稳定。

解决解不稳定问题可以从两个方面入手：增加样本个数和减少属性个数。在实际问题中，样本往往相对固定，在样本无法增加的情况下只能探索减少属性个数的思路。减少属性个数可以从两个方面入手：降低某些属性的影响和剔除某些属性。岭回归(ridge regression)和 LASSO(least absolute shrinkage and selection operator)回归是这两种方式的代表。

2. 岭回归模型

岭回归模型在最小二乘回归模型中增加正规项来抑制权重系数，从而降低某些属性的影响。岭回归模型表述如下：

$$(\boldsymbol{w}^*, b^*)=\arg\min_{\boldsymbol{W}}(\|\boldsymbol{X}\boldsymbol{W}-\boldsymbol{y}\|_2^2+\alpha\|\boldsymbol{W}\|_2^2)$$

其中，$\boldsymbol{W}=(\boldsymbol{w}; b)$表示将 b 拼接到列向量 $\boldsymbol{w}$ 后得到的 $n+1$ 维向量，$\|\cdot\|_2$ 是向量的 L2 范数，等于向量每个元素平方和的开方。不难推导：$\|\boldsymbol{X}\boldsymbol{W}-\boldsymbol{y}\|_2^2$ 是平方损失；$\|\boldsymbol{W}\|_2^2$ 是正规项，通常称为 L2 正规项；α 是正规项系数，用来调节平方损失和正规项之间的权重。

上述岭回归模型也有解析解，即

$$(\boldsymbol{w}^*; b^*)=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}+\alpha\boldsymbol{I})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{y}$$

其中，$\boldsymbol{I}$ 是单位矩阵。与最小二乘回归模型的解相比，可以找到合适的 α 使得$(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}+\alpha\boldsymbol{I})^{-1}$ 比$(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}$ 更稳定。即使样本数量不足或数据存在的多重共线性导致 $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$ 是病态矩阵，岭回归模型的解通过补偿一定比例的单位矩阵，可以使得岭回归模型对输入变量中噪声的鲁棒性更好。

显然当 $\alpha=0$ 时，岭回归模型退化为最小二乘回归模型。为了考察 α 对系数 $\boldsymbol{W}$ 的影响，这里设计了一个实验。设 $\boldsymbol{H}$ 是 10 阶希尔伯特矩阵，即第 i 行第 j 列元素 $a_{ij}=\dfrac{1}{i+j-1}$。取

$\boldsymbol{H}$ 的前 5 列作为样本数据 $\boldsymbol{X}$，表示有 10 个样本，5 个属性，且每个样本的标注均为 1。实验中不考虑偏置，即线性回归模型中 $b=0$。在区间$[10^{-10}, 10^{-2}]$内等间隔地取 200 个数值分别作为正规项系数 α。α 取不同的数值，使用岭回归模型可以得到不同的系数 $\boldsymbol{w}^*$。如图 6-13 所示，以 $\boldsymbol{w}^*$ 中每个分量的大小作为纵坐标，以正规项系数 α 作为横坐标，可得 5 条曲线，每条曲线对应 $\boldsymbol{w}^*$ 中的一个分量。这种曲线常称为正规化路径，它描述了回归系数的估计值随正规项系数增大而变化的趋势。

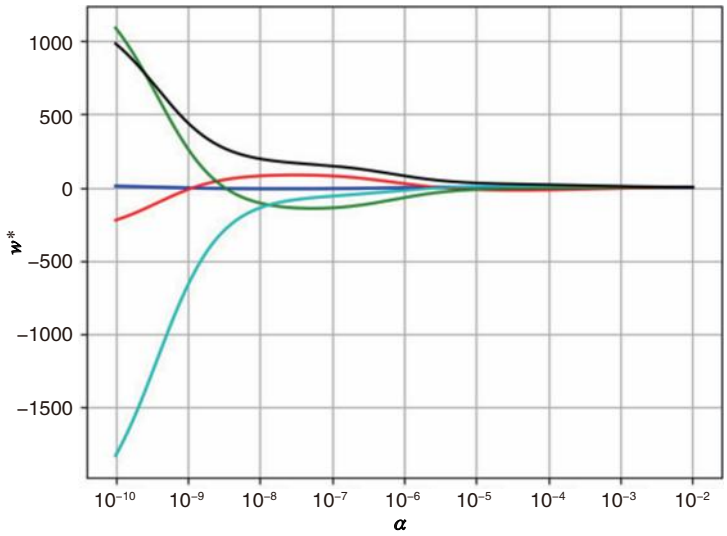

图 6-13　正规项系数对岭回归模型的影响

分析图 6-13 的曲线可知，当 α 逐渐变小时，$\boldsymbol{w}^*$ 中各分量越来越分散，分量的绝对值越来越大，这会使模型对噪声越来越敏感，效果越来越趋近最小二乘回归模型。反之，当 α 逐渐变大时，$\boldsymbol{w}^*$ 中各分量越来越集中，分量的绝对值越来越小，这时模型对噪声变得越来越鲁棒。由此可以看出正规项对系数 $\boldsymbol{w}^*$ 有一定的抑制作用，通过抑制系数降低了对应属性的影响。当然，α 不能太大，否则正规项将起主导作用，导致系数 $\boldsymbol{w}^*$ 趋于零向量。在解决实际问题时，需要根据实际情况进行调参，确定最佳正规项系数。

3. LASSO 回归模型

如果说将 L2 范数作为正规项可以抑制系数 $\boldsymbol{W}$，以减小属性的影响，那么将 L1 范数作为正规项可以优先筛选掉一些不太重要的属性(与输出的相关性不高，或者与其他属性存在多重共线性)，LASSO 回归模型正是使用了 L1 范数，该模型表达如下：

$$(\boldsymbol{w}^*, b^*)=\arg\min_{\boldsymbol{w}}(\|\boldsymbol{XW}-\boldsymbol{y}\|_2^2+\alpha\|\boldsymbol{W}\|_1)$$

其中：$\|\cdot\|_1$ 是向量的 L1 范数，等于向量每个元素绝对值的和；$\|\boldsymbol{W}\|_1$ 常称为 L1 正规项；与岭回归模型一样，α 是正规项系数，用来调节平方损失和正规项之间的权重。

与岭回归模型不同，LASSO 回归模型没有解析解，可以使用坐标下降法、最小角回归法等求解。受篇幅所限，这里对模型求解算法不做详细介绍。

使用与岭回归模型的正规化路径一样的数据，正规项系数对 LASSO 回归模型的影响如图 6-14 所示。

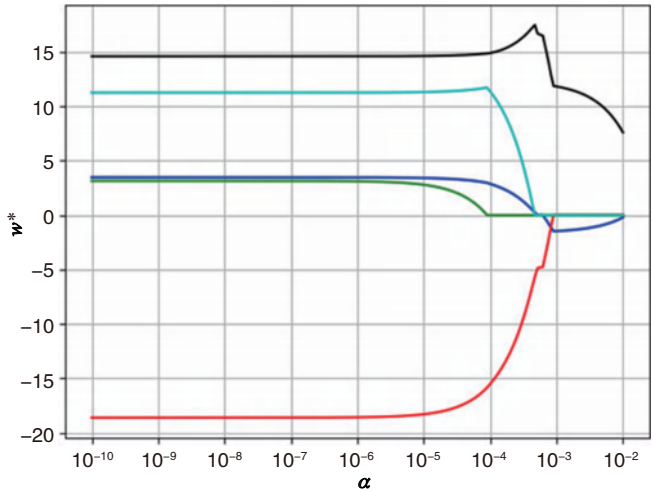

图 6-14　正规项系数对 LASSO 回归模型的影响

分析图 6-14 的曲线可知，当 α 小于 10^{-5} 时，$\boldsymbol{w}^*$ 中各分量几乎不受 α 的影响，此时正规项几乎不起作用，整个模型由平方损失主导。当 α 大于 10^{-5} 时，有 3 个分量开始明显变化，直到 α 接近 10^{-4} 时，有一个分量快速变为 0。随着 α 继续增大，有更多的分量变为 0，α 接近 10^{-2} 时，只有一个分量不为 0。这种有多个分量为 0 或者非常接近 0 的向量，称为稀疏向量，也称该向量具有稀疏性。通常可以选择合适的正规项系数，使 LASSO 回归模型的解具有稀疏性。$\boldsymbol{w}^*$ 分量为 0 的系数使得模型中对应属性不起作用，相当于筛选掉该属性。因此，一定大小的正规项系数 α 可以使部分回归系数为 0，或者非常接近 0，从而达到自动筛选掉某些属性的目的。

4. 模型正规化

回顾前文，样本量不足和多重共线性可能导致最小二乘回归模型对噪声非常敏感。事实上，样本量不足更多地影响模型对新数据的预测能力。这种对未知数据的预测能力称为模型的泛化能力。如何提升模型的泛化能力是机器学习中需要考虑的重要问题。

模型的泛化能力差主要表现在两个方面：欠拟合和过拟合。如图 6-15 所示，针对 5 个散点数据，直线模型不能很好地描述数据背后隐藏的规律，这是模型欠拟合的表现。4 次多项式曲线模型尽管与给定的数据完全吻合，但是却出现非常大的振荡，导致模型对噪声非常敏感，如输入小于 5 或大于 20 时，微小的扰动就会导致输出发生巨大的变化，这是模型过拟合的表现。对比来看，二次多项式曲线模型尽管没有和所有数据都吻合，但是与数据的整体变化趋势基本一致，可以说该模型比较好地学习到了数据背后隐藏的规律。

欠拟合是指模型在训练集上无法获得足够小的误差，表现为模型在训练集上的效果不好，根本无法用来预测新数据。根源在于模型的复杂度低，无法驾驭相应的训练样本。解决欠拟合的措施主要是提升模型的复杂度。可以挖掘更多的特征以增加模型的参数个数，从而达到提升模型的复杂度的目的，也可以尝试更换更复杂的模型。

过拟合是指模型的训练误差较小，而测试误差很大，表现为模型在训练集上的效果很好，但在测试集上的效果却很差。主要根源是模型复杂，而训练样本不足，导致模型学习

到个别训练样本的特性，而不是学习到数据背后普遍的规律。增加样本数量可以解决过拟合的问题，但是实际问题中往往很难做到。为此，在训练样本确定的情况下，如何降低模型的过拟合风险是一个重要的研究课题。

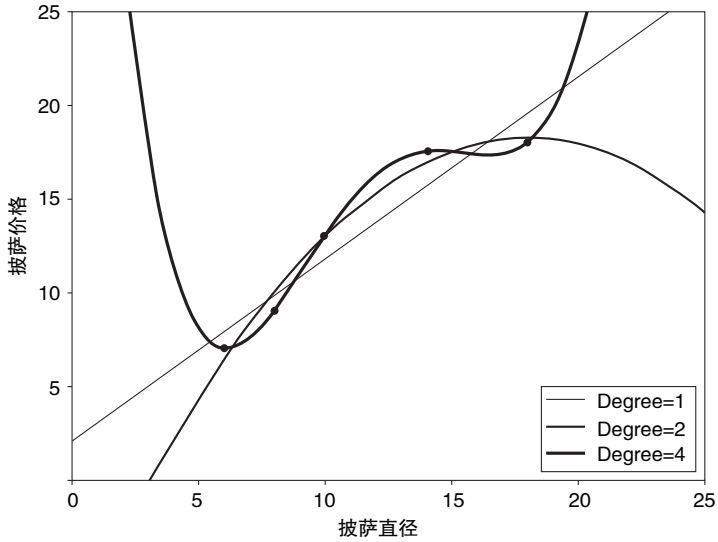

图 6-15　模型过拟合与欠拟合

类似于岭回归模型和 LASSO 回归模型的做法，在模型中加入正规项是解决过拟合问题的重要手段，这一过程称为正规化，即在已有模型中加入人工设计的经验模型，对决策变量加以约束，以减小模型的过拟合。形如岭回归模型，在模型中加入 L2 范数作为正规项，称为 L2 正规化；形如 LASSO 回归模型，在模型中加入 L1 范数作为正规项，称为 L1 正规化。

如前所述，图 6-15 中的 4 次多项式曲线有明显的过拟合，对该模型做 L2 正规化和 L1 正规化，正规项系数均为 1，结果分别如图 6-16(a)和图 6-16(b)所示。从结果来看，这两种正规化方法均有效地降低了模型的过拟合程度。

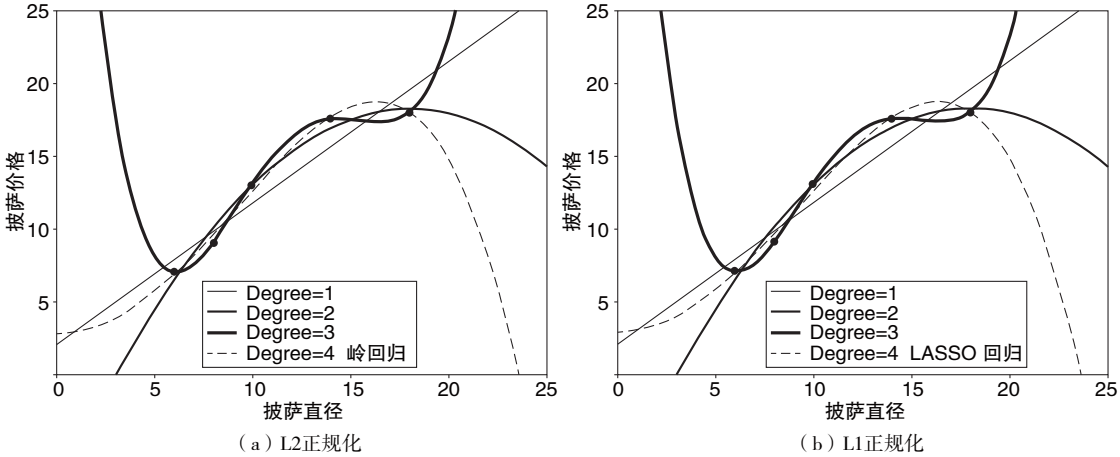

（a）L2正规化　　（b）L1正规化

图 6-16　正规化的效果

对比图 6-13 和图 6-14，可以发现相比于岭回归模型，LASSO 回归模型的解往往具有稀疏性。注意到岭回归模型使用 L2 正规化、LASSO 回归模型使用 L1 正规化的事实，可以得到一个基本结论：相比于 L2 正规化，L1 正规化更倾向于使模型的解具有稀疏性。这里通过一个实例进一步说明该结论。

设目标函数为

$$f(w_1, w_2)=(w_1-w_2)^2+10(w_1-1.2)^2$$

考虑两个约束优化问题，L1 范数约束

$$\min_{w_1,w_2} f(w_1, w_2),\ |w_1|+|w_2|\leqslant C$$

和 L2 范数约束

$$\min_{w_1,w_2} f(w_1, w_2),\ w_1^2+w_2^2\leqslant C$$

注意到使用拉格朗日乘子法，总是可以将上述约束优化问题等价转化为 L1 正规化和 L2 正规化的无约束优化问题

$$\min_{w_1,w_2}[f(w_1, w_2)+\alpha(|w_1|+|w_2|)]$$

和

$$\min_{w_1,w_2}[f(w_1, w_2)+\alpha(w_1^2+w_2^2)]$$

这里正规项系数 α 依赖于约束条件中的 C。因此，只要考虑上述约束优化问题，便可理解 L1 正规化和 L2 正规化分别如何影响最优解。为此取 $C=1$，为了便于理解，画出上述约束优化的可行域边界以及 $f(w_1, w_2)$的等高线，结果如图 6-17 所示。

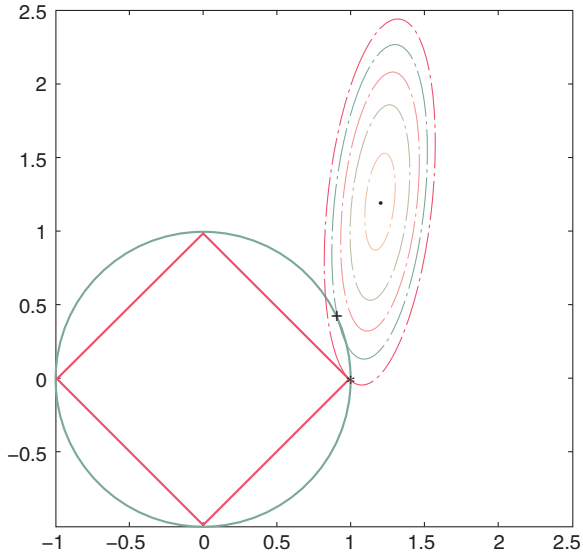

图 6-17　正规化方式对解的影响

显然，如果没有约束条件，最优解是$(w_1, w_2)=(1.2, 1.2)$，即在$(w_1, w_2)=(1.2, 1.2)$处取得最小值。约束条件 $w_1^2+w_2^2\leqslant 1$ 描述了一个圆面，在此约束下最优解偏离$(1.2, 1.2)$，在圆面内取得最优解。结合 $f(w_1, w_2)$的等高线，可以确定此时的最优解位于等高线和圆面相切的位置，正是图中“+”所在位置。此外，正是该约束条件迫使(w_1, w_2)的两个分量向 0 靠拢，这与岭回归模型减弱属性的影响是一致的。

约束条件$|w_1|+|w_2|\leqslant 1$ 描述了一个顶点在坐标轴上的正方形，在此约束下最优解位于等高线和正方形区域相切的位置，对应图中“*”所在位置，正是正方形的一个顶点，其坐标为$(1, 0)$。这其实不是偶然现象，从图 6-17 来看，在 L1 范数确定的正方形区域中，4 个角更容易与目标函数的等高线相切，而这些角正好位于坐标轴上。如果是在高维空间

中，与等高线相切的点会倾向于落在坐标轴附近或者落在坐标轴上，这就形成了稀疏解。相比而言，L2 范数确定的圆形区域中，与等高线相切的位置没有倾向性，所以 L2 正规化模型的解一般没有明显的稀疏性。

5. Huber 回归模型

数据是机器学习的基石，但是在实际问题中现有数据不一定都是正常的。测量、统计等失误及客体的异常行为等均可能导致数据异常，出现离群点。如图 6-18 所示，坐标系左上角和右下角分别存在两个离群点。如果不考虑这 4 个离群点，剩下的数据具有较为一致的趋势。但是离群点的存在使最小二乘回归模型和岭回归模型大幅偏离这一趋势，可见离群点对模型的影响非常大。

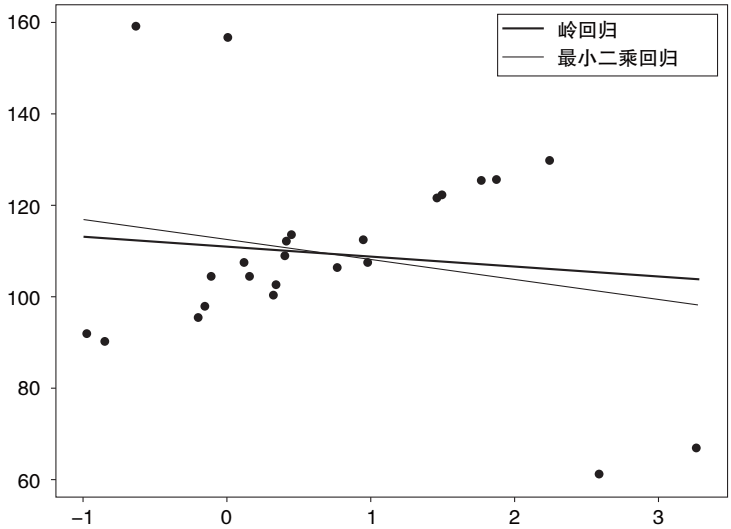

图 6-18　离群点对回归模型的影响

离群点的检测及处理是一项专门的研究任务，这里主要关注如何从模型本身入手降低离群点对模型的影响。

考虑图 6-18 的最小二乘回归模型和岭回归模型，离群点的存在迫使模型向离群点靠近。为了探究其背后的原理，考察这两个模型的损失函数。它们均使用平方损失，即 $\sum_{i=1}^{m}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i+b-y_i)^2$，描述了每个样本与模型输出之间的综合差距。先抛开离群点不考虑，将得到与正常点趋势一致的模型，即向右上方倾斜的直线。此时再将 4 个离群点考虑进来，显然它们的损失非常大，这将迫使极小化算法优先降低离群点的损失，从而使模型偏向离群点。因此，减小离群点的影响可以从降低离群点的损失入手。注意到平方损失会使较大的损失(大于 1)变得更大，所以在保持较小损失的前提下，可以通过降低大损失的幂次来抑制离群点的影响。Huber 损失函数正是基于这一思想，其表达式为

$$H_\varepsilon(z)=\begin{cases} z^2, & |z|<\varepsilon \\ 2\varepsilon|z|-\varepsilon^2, & \text{其他} \end{cases}$$

其中，ε 是大于 0 的参数，用来调节保持平方损失的范围。图 6-19 展示了 ε 取不同值的效

果，以及其与平方损失函数的比较。可以看出，ε 越来越大时，Huber 损失函数接近平方损失函数，当 ε 越来越小，甚至接近 0 时，Huber 损失函数越来越趋于绝对值损失函数。

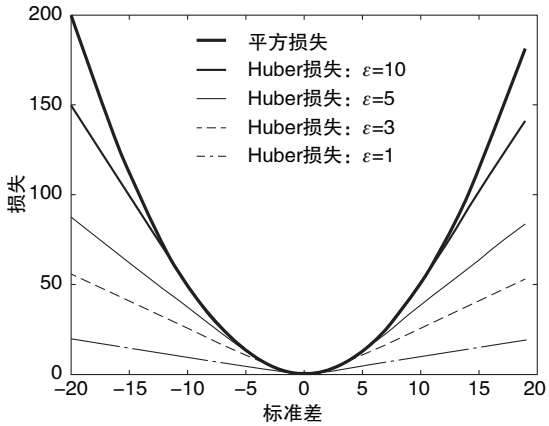

图 6-19　ε 取不同值的 Huber 损失函数

可以看出 Huber 损失函数在损失较小时沿用平方损失函数，在较大损失的情况下，使用线性函数。这种策略可以在保持正常数据使用平方损失函数的前提下，针对离群点使用绝对值损失函数，从而降低离群点的影响。

将岭回归模型中的平方损失函数替换为 Huber 损失函数，可以得到 Huber 回归模型为

$$\min_{\boldsymbol{W},\,\sigma}\left[\sum_{i=1}^{m}\left(\sigma+H_{\varepsilon}\left(\frac{\boldsymbol{X}_i\boldsymbol{W}-y_i}{\sigma}\right)\sigma\right)+\alpha\,\|\boldsymbol{W}\|_2^2\right]$$

其中：$\boldsymbol{X}_i=(\boldsymbol{x}_i;\ 1)^{\mathrm{T}}$ 表示第 i 个样本的末尾添加 1 后再转置所得的行向量；σ 是尺度化因子，随回归系数 $\boldsymbol{W}$ 一起优化。

重新考虑图 6-18 中具有离群点的数据，使用不同参数 ε 得到的 Huber 回归模型如图 6-20 所示。

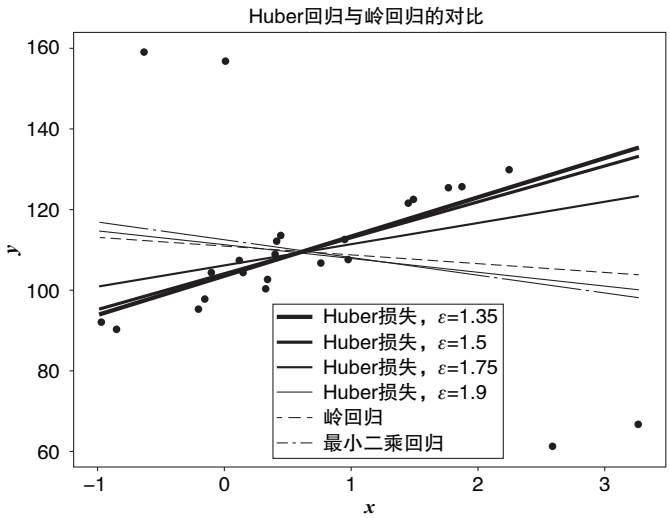

图 6-20　不同参数 ε 的 Huber 回归模型在具有离群点的数据上的表现

可以看出，Huber 回归模型确实可以降低离群点的影响，在 ε 取值为 1.75、1.5 和 1.35 的情况下，Huber 回归模型明显优于最小二乘回归模型和岭回归模型。但是当 ε 取到 1.9 时，Huber 回归模型的效果很差，接近最小二乘回归模型和岭回归模型。这是因为较大的 ε 使得 Huber 损失函数在很大的范围内沿用了平方损失函数，而当前离群点正好落在

这个范围内，使用了平方损失函数。作为超参数，可以通过调参的方法确定最佳 ε。根据经验，$\varepsilon=1.35$ 在大多数应用场景中能够取得较好的效果。

6.2.2 回归模型的评价

与分类模型一样，回归模型也是在测试集上评价的。设有 s 个测试样本，第 i 个测试样本的真实值(标注信息)是 y_i，模型预测值是 $\hat{y}_i$。训练模型的目标是每个测试样本的预测值等于真实值，即预测值与真实值没有差异。所以可以通过考察所有样本预测值和真实值之间的综合差异来评价模型：这种差异越小，模型的预测效果越好。差异通常使用误差 $y_i-\hat{y}_i$ 的平方或绝对值描述，“综合”采用平均即可实现。对应的评价方法称为均方误差(mean square error，MSE)和平均绝对误差(mean absolute error，MAE)，其值分别为

$$\mathrm{MSE}=\frac{\sum_{i=1}^{s}(y_i-\hat{y}_i)^2}{s}$$

$$\mathrm{MAE}=\frac{\sum_{i=1}^{s}|y_i-\hat{y}_i|}{s}$$

显然，MSE 和 MAE 越小，模型在测试集上的表现越好，特别地，当 MSE=0 或者 MAE=0 时，模型在测试样本上没有丝毫错误，表现完美。针对同一个测试集，在比较不同的回归模型时，MSE 和 MAE 均能很好地给出一致性的结论。但是当只评价一个模型时，这两个指标存在共同的问题：值的大小没有参考性。如一个问题中的输出值在 0～1 范围内，某个样本误差是 1；而另一个问题的输出值在 1 000 左右，某个样本的误差也是 1。尽管误差的值相同，但是显然这两个问题的模型表现是不同的。所以脱离输出值，只看 MSE 或者 MAE 的数值是没有参考性的。为了回避这个问题，可以使用决定系数来评价模型，即

$$R^2=1-\frac{\sum_{i=1}^{s}(y_i-\hat{y}_i)^2}{\sum_{i=1}^{s}(y_i-\overline{y})^2}=1-\frac{\frac{\sum_{i=1}^{s}(y_i-\hat{y}_i)^2}{s}}{\frac{\sum_{i=1}^{s}(y_i-\overline{y})^2}{s}}$$

其中，$\overline{y}=\frac{\sum_{i=1}^{s}y_i}{s}$ 是真实值的平均值。

(1)$R^2=1$。只有当 MSE=0 时，决定系数取到最大值 1，此时模型在测试集上没有任何错误，表现完美。

(2)$R^2=0$。当模型将所有测试样本预测为均值 $\overline{y}$ 时，$\mathrm{MSE}=\frac{\sum_{i=1}^{s}(y_i-\overline{y})^2}{s}$，此时 $R^2=0$。当模型随机地给出预测值时，决定系数接近 0。所以，当决定系数等于 0 或者很接近 0 时，模型的预测能力与随机猜测差不多，此时模型已经没有意义。

(3)$R^2<0$。当模型的预测能力不如随机猜测时，决定系数小于 0，此时模型已经没有任何必要。所以，通常不考虑决定系数小于 0 的情况。

(4)$0<R^2<1$。决定系数没有量纲，其值越大，说明模型在测试集上的预测效果越好。可以通过接近 1 的程度来衡量模型的优异程度。

6.3 其他算法

6.3.1　集成学习：随机森林和梯度提升树

集成学习(ensemble learning)是一种学习策略，而不是一种新的机器学习模型。它通过构建多个学习器并将它们结合起来完成学习任务。通常先生成一组个体学习器，再用某种策略将它们结合起来。根据个体学习器的类型可以将集成学习分为同质集成和异质集成：同质集成的个体学习器是同种类型，这些个体学习器也称基学习器，相应的算法称为基学习算法；异质集成的个体学习器是不同类型的，这些个体学习器也称组件学习器。

同质集成中比较常用的基学习器是决策树，对应的两种代表性算法是随机森林(random forest)和梯度提升树(gradient boosting decision tree，GBDT)，它们各自代表了两种不同的集成策略。以随机森林为代表的策略中，个体学习器之间不存在强依赖关系，它们可以同时并行地生成。以梯度提升树为代表的策略中，个体学习器之间存在强依赖关系，它们必须串行地序列化生成。

1. 随机森林

要获得好的集成，个体学习器应“好而不同”，即个体学习器要有一定的准确性，不能太坏，并且要有多样性，个体学习器之间具有差异。

随机森林通过样本扰动和属性扰动来实现各决策树之间的差异性，保证各基学习器的多样性。在预测阶段对每棵树的结果进行汇总，最终通过投票的方式做出决策。

随机森林的构建过程描述如下。

(1)样本扰动。针对容量是 m 的训练集，有放回地随机选择 m 个样本作为新的训练集，该训练集中可能有重复的样本。

(2)基于随机选择的训练集，构建一棵决策树。构建决策树时，当节点需要分裂时，先从 d 个属性中随机选择 k 个，然后从选择出来的属性中根据信息增益或者基尼指数确定最优划分属性。

(3)按照步骤(1)～(2)构建更多的决策树。

上述过程中，如果 k 减小，树之间的相关性会降低，这有助于提升树之间的差异性，从而提升整个森林的性能；但是单棵树的分类能力同时也会降低，这又影响整个森林的分类能力。反之，如果 k 增大，单棵树的分类能力会增加，从而提升整个森林的性能；但是属性扰动会随之减弱，从而导致树之间的相关性增大，这也影响整个森林的分类能力。

因此，存在一个合适的 k，从经验来看，$k=\log_2 d$ 通常可以达到理想的效果。

2. 梯度提升树

梯度提升树是集成学习中提升方法的代表，它的基学习器也是决策树。与随机森林不

同的是，梯度提升树使用了迭代方法，逐步训练众多弱学习器，最后组合弱学习器，得到最终的强学习器。

用于分类的梯度提升树使用对数损失函数，在每一次迭代中，假设前一轮迭代得到的强学习器是 $f_{t-1}(x)$，损失函数是 $L(y, f_{t-1}(x))$，那么本轮迭代就是寻找一棵决策树 $h_t(x)$，使得本轮的损失函数 $L(y, f_t(x)) = L(y, f_{t-1}(x)+h_t(x))$最小。这个损失一般不易确定，所以使用损失函数的负梯度近似本轮损失。

6.3.2 非线性回归

回归问题与分类问题的主要区别在于模型的输出值是否离散，大多数用于解决分类问题的模型稍加改造便可用于解决回归问题。这里以 kNN 算法为例，给出用于解决回归问题的 kNN 模型。支持向量机、决策树、随机森林和梯度提升树均可以解决回归问题。

用于解决分类问题的 kNN 算法的核心思想是：目标样本(待分类样本)的类别信息由与其最近的 k 个训练样本的类别决定。对该思想稍加拓展，便可得到用于解决回归问题的思路：目标样本(待预测样本)的预测值将由与其最近的 k 个训练样本的值共同决定。至于决定方式，可以选择简单平均，也可使用加权平均。kNN 回归算法的具体步骤如下：

(1)计算待预测样本与各训练样本之间的距离；

(2)按照距离的递增关系进行排序；

(3)选取距离最小的 k 个训练样本；

(4)对 k 个近邻的数值进行平均，作为待预测样本的输出值。

在上述步骤中，最后一步可以考虑使用加权平均，k 个训练样本的权重与其到待测样本之间的距离相关，距离越大，权重越小。

习　题

1. 简述惰性学习和急切学习的区别。已学过的算法中，哪些是惰性学习方法？哪些是急切学习方法？

2. 简述支持向量机的惩罚系数 C 对分类结果的影响。

3. 简述判别式模型和生成式模型的区别。已学过的模型中，哪些是判别式模型？哪些是生成式模型？

4. 阐述不同的决策树属性划分指标的异同及优缺点。

5. 召回率和精确率之间有必然的大小关系吗？是否存在召回率大但精确率小的情况？是否存在精确率大但召回率小的情况？

6. 阐述岭回归、LASSO 回归和 Huber 回归的区别及各自的特点。

习题解析