# 第 9 章 大语言模型及其应用

## 章节导航

- 了解自然语言处理、文本挖掘等概念。
- 掌握大语言模型的概念、实例、研究热点。
- 熟悉大语言模型在相关领域的应用。

本章知识导图

## 9.1 自然语言处理

自然语言处理就是用计算机处理、理解及应用人类语言(如中文、英文等)，它属于人工智能的一个分支，是计算机科学领域与语言学的交叉学科，又称计算语言学。

### 9.1.1 自然语言处理方法

常用的自然语言处理方法包括分句、分词、词性标注、浅层语法分析。此外，自然语言处理社区有许多开源工具包，这些开源工具包能够帮助研究者和相关从业人员更加便捷地完成自然语言处理任务。常用的开源工具包包括 NLTK、jieba、spaCy、TextBlob、Gensim 等。

(1)分句。分句是指把一篇文本文档分解为句子的集合。许多文本处理的应用是以句子为单位的(如自动文摘，挑选文档集中有代表性的句子)。利用句号、问号、叹号等表示句子的间隔的标点符号对文档进行切分。

(2)分词。分词是指把一个句子表示成最基本的单词序列。英文的单词由空格隔开，分词比较简单，而中文分词存在某些难点，如歧义切分问题、新词发现问题、句法歧义等。其中新词是指从前的分词词典中没有收录，后来出现并被大家公认的词语。新词难以发现的原因在于新词的覆盖面广，词语构成没有普遍规律，低频新词数据稀疏，识别难度大。

(3)词性标注。词性是词汇基本的语法属性，通常也称词类。词性标注是在给定句子中判定每个词的语法范畴，确定其词性并加以标注的过程。其中研究难点包括中文词的类别难以像英文一样直接从词的形态变化判别；常用词兼类现象严重；研究者主观原因等。研究热点包括标注科学论文、新闻报道，以及对微博等非正式文本的词性标注。

(4)浅层句法分析。浅层句法分析是指识别句子中的某些结构相对简单的独立成分，如非递归的名词短语(noun phrase，NP)、动词短语(verb phrase，VP)等，这些被识别出来的结构通常称为语块(chunk)。浅层句法分析的两个子任务包括语块的识别和分析，以及语

块之间的依附关系分析。完全句法分析要确定句子所包含的全部句法信息，并确定句子中各成分之间的关系，浅层句法分析使句法分析的任务得到了简化。

### 9.1.2 文本挖掘模型

文本挖掘模型包括以下几个重要模型，分别是词袋(bag-of-words，BOW)模型；统计特征模型，如数据项频率-反文档频率(term frequency-inverse document frequency，TF-IDF)模型；主题模型，如隐狄利克雷分布(latent Dirichlet allocation，LDA)模型。它们在文本挖掘和自然语言处理领域都有广泛的应用，可以根据具体任务的需求选择合适的模型来处理文本数据。

jieba 分词简介

1. 词袋模型

BOW 是最基础的文本表示模型。BOW 模型将文本中的每个单词视为独立的特征，不关注单词的顺序或语法关系。它通过创建一个单词的集合(袋子)来表示文本，每个单词在袋子中的出现次数(词频)作为该单词对文本的贡献度。BOW 模型可以简单地对文本进行分类和聚类，但无法捕捉到文本中的语义信息。

2. TF-IDF 与 BM25 模型

TF-IDF 和 BM25(best matching 25)模型都是文本检索和信息检索领域中常用的权重模型，用于衡量文档中词语的重要性，以便排序和检索相关文档。它们在搜索引擎、文本分类和信息检索系统中得到广泛应用。

TF-IDF 模型是一个用于评估文档中词语重要性的经典模型。它的计算基于两个主要因素：项频率(term frequency，TF)和反文档频率(inverse document frequency，IDF)。TF 衡量一个词在文档中出现的频率。通常可以使用标准的词频计算公式，如 TF＝(词语在文档中出现的次数)/(文档中总词语数)。IDF 衡量一个词在整个文档集合中的重要性。IDF 越高，表示词语在文档集合中越不常见，从而其重要性越高。通常 IDF 计算公式如下：IDF＝lg(文档总数 / 包含该词的文档数)。计算实例如下。

词语“母牛”在某一篇总词语数为 100 个的文件中出现了 3 次，该文件所在的语料库的文件总数为 10 000 000 份，并且“母牛”在其中的 1 000 份文件中出现过，求 TF-IDF 的值 。

计算过程如下：

TF(“母牛”)＝3/100＝0.03；

IDF(“母牛”)＝lg(10 000 000 / 1 000)＝4；

TF-IDF 的值为 0.03×4＝0.12。

BM25 模型是一种改进的信息检索模型，特别适用于大规模文本检索任务。它相对于 TF-IDF 模型具有更好的性能和可调节的参数。BM25 模型的计算基于以下关键因素。

(1)与 TF-IDF 模型中的定义相同，TF 衡量词语在文档中出现的频率。

(2)与 TF-IDF 模型中的定义相同，IDF 衡量词语在整个文档集合中的重要性。

(3)文档长度(document length)衡量文档的长度，可以是词语数或字符数。

(4)文档平均长度(average document length)衡量整个文档集合中的平均文档长度。

(5)参数 $k_1$ 和 $b$ 是用于调整模型行为的超参数。$k_1$ 控制 TF 的饱和程度，$b$ 控制文档长度对得分的影响。BM25 模型的得分的计算公式如下：

$$\text{BM25}=\text{IDF}\times[\text{TF}\times(k_1+1)]/\{\text{TF}+k_1\times[1-b+b\times(\text{文档长度}/\text{文档平均长度})]\}$$

BM25 模型具有一些优点，例如，能够处理较短文档和较长文档，以及具有可调节参数，可以根据特定任务进行参数调整。它在实践中常用于大规模文本检索系统，如搜索引擎。

3. 主题模型

常见的主题模型如 LDA，它常用于从大量文本中挖掘隐藏的主题信息。LDA 模型通过概率图模型将文本表示为一个主题分布，每个主题是由一组单词组成的概率分布。在 LDA 模型中，每个文档是由多个主题组成的概率分布，而每个单词则根据其所在的文档和主题具有不同的概率分布。LDA 模型可以捕捉到文本中的隐含主题，例如一篇新闻报道可能包含政治、经济、体育等主题。通过 LDA 模型，可以将大量文本划分为不同的主题类别，从而完成分类和聚类等任务。一篇文章的每个词都可以视作“以一定概率选择了某个主题，并从这个主题中以一定概率选择了某个词语”。

要生成一篇文档，每个词的出现概率如下：

$$p(\text{词语}\mid\text{文档})=\sum_{\text{主题}}p(\text{词语}\mid\text{主题})\times p(\text{主题}\mid\text{文档})$$

对大量文档进行分词处理，每篇文档表示为词语的集合。对于任意文档 $C$，已知“词语-文档”矩阵，通过一系列训练推理出“词语-主题”矩阵和“主题-文档”矩阵，LDA 模型示例如图 9-1 所示。

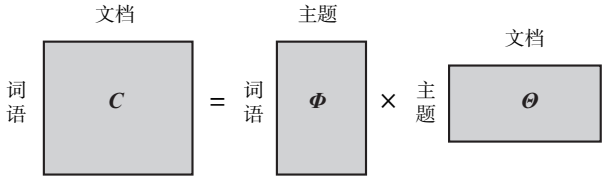


**图 9-1　LDA 模型示例**

### 9.1.3　智能问答

智能问答系统以问答形式，精确地定位用户所提问的知识，通过与用户进行交互，为用户提供个性化的信息服务。智能问答系统涉及的方法包括爬虫(爬取问答对)、问句处理(分词、去停用词等)、相似文本(问句之间的相似度匹配)，如图 9-2 所示。

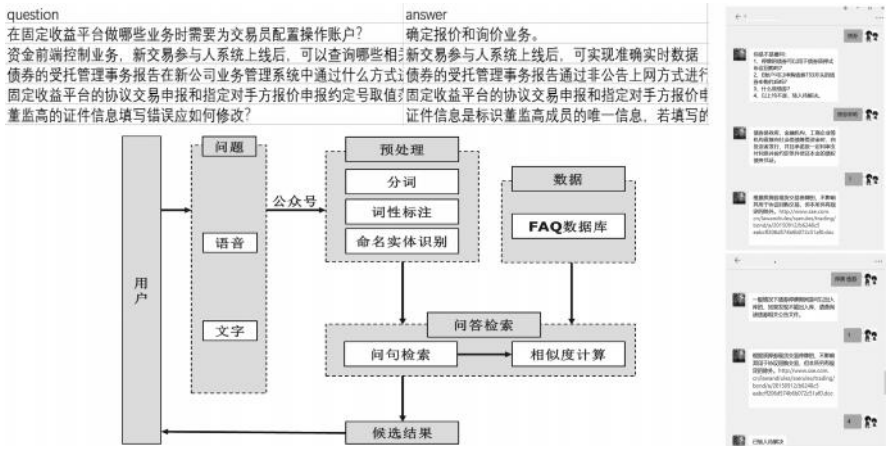


**图 9-2　智能问答系统**

智能问答系统和传统信息检索系统的主要区别如下。

(1)输入：传统信息检索系统的输入是查询关键词；智能问答系统的输入是自然日常语言的问句。

(2)输出：传统信息检索系统的输出是关键词相关文档，需要用户自己查找有用信息；智能问答系统的输出是直接返回针对用户提问的答案。

## 9.2 大语言模型的概念、实例与提示工程

### 9.2.1 大语言模型的概念

大语言模型(large language model，LLM)是指参数数量庞大、在预训练过程中使用大规模语料库进行自监督学习的自然语言处理模型，如 GPT-3 和 T5 等模型。这些模型已经在语言理解、文本生成、对话系统等多个任务中取得了重大突破，具有巨大的发展前景。

这些模型的应用场景多种多样。例如，它们可以作为聊天机器人，响应用户的问题、提供信息或进行对话。同时，它们也可以应用于文本生成，如自动写作、自动摘要、自动翻译等领域。此外，大语言模型还可以应用于语音识别、情感分析、智能客服、舆情分析、法律文本分析等领域，帮助人们更好地理解和处理自然语言。图 9-3 是近年火热的 ChatGPT 大语言模型的使用示意图。

**图 9-3　ChatGPT 大语言模型的使用示意图**

大语言模型的基本原理主要是通过大规模的预训练和自监督学习，提高模型的语言理解和生成能力。在预训练过程中，模型会根据大量的无标签文本数据进行训练，通过学习大量的语料库中的语言模式，提高其对语言的理解能力。而自监督学习则是通过大规模的

监督信号进行训练，使模型能够自动发现输入序列中的规律和模式，从而在不需要人工标注的情况下完成对文本数据的理解和生成。具体而言，这些模型运用了深度学习的技术，如神经网络、注意力机制、Transformer 等，以实现对大规模文本数据的处理和分析。

大语言模型与传统的分词和自然语言处理模型之间的关系是相辅相成的。传统的分词和自然语言处理模型通常是针对特定的任务进行训练和优化，如词性标注、命名实体识别、依存句法分析等，而大语言模型则更加注重对大规模语料库的自监督学习和预训练，以获得更广泛的应用场景和更好的泛化能力。

在具体的应用过程中，大语言模型通常需要与传统的分词和自然语言处理技术相结合。例如，在机器翻译任务中，首先需要对输入的文本进行分词处理，然后将分词后的单词送入大语言模型中进行翻译，最后将翻译结果进行整理和输出。

同时，大语言模型的预训练过程也离不开传统的自然语言处理技术。例如，在预训练过程中，需要对文本进行清洗和处理，去除噪声和无关信息，并进行规范化和标准化处理，以保证预训练的质量和效果。

### 9.2.2　大语言模型的实例

大语言模型目前在各个领域都有广泛的应用，并可以构建各种自然语言处理应用，如聊天机器人、语音助手、机器翻译等。例如，百度的文心一言，能够与人对话互动、回答问题、协助创作，高效便捷地帮助人们获取信息、知识和灵感。图 9-4 是文心一言的初始界面，读者可以通过链接 https://yiyan.baidu.com/进入并使用它。

文心一言使用简介

图 9-4　文心一言的初始页面

目前市面上与百度的文心一言、OpenAI 的 ChatGPT 相似的大语言模型主要包括以下几种。

(1)GPT-3：由 OpenAI 开发，它是目前先进的自然语言处理模型之一，可以生成高质量的自然语言文本，并且在多个自然语言处理任务中取得了很好的效果。

(2)360 智脑：360 智脑是 360 自研的认知型通用大模型，集成 360 GPT 大模型、360 CV 大模型等技术推出的 AI 内容生产与创作工具，提供智能创作、智能办公、智能学习等多种功能。

(3)ELMo：由 Allen Institute for AI 开发，它是一种基于 LSTM 的自然语言处理模型，它可以学习上下文敏感的词向量表示，并且可以用于多种自然语言处理任务，如情感分析、文本分类等。

(4)RoBERTa：由 Facebook(现名 Meta)AI 开发，它是基于 RoBERTa 的自然语言处理模型，它在 BERT 的基础上进行了一些改进，使得它能够在更短的时间内进行训练，并且具有更高的性能。

(5)ALBERT：由谷歌开发，是一种基于 Transformer 的自然语言处理模型，它通过共享参数和跨层参数共享等方式进行优化，可以应用于多种自然语言处理任务，如文本分类、命名实体识别等。

(6)XLNet：由卡耐基梅隆大学和麻省理工学院等机构联合开发，它是一种基于 Transformer 的自然语言处理模型，它通过采用自回归和自编码相结合的方式进行训练，可以生成高质量的自然语言文本。

### 9.2.3 提示工程

提示工程是在自然语言处理和机器学习模型中，通过精心设计和优化输入文本(提示)来提高模型输出质量的一种技术。模型接收到的输入格式或内容的微小变化，都可能导致模型产生完全不同的输出。提示工程的典型工作方式是将一个或多个任务转换为基于提示的数据集，并通过基于提示的学习来训练语言模型。提示工程可以从一个大型的“冻结”预训练语言模型开始工作，其中只学习了提示的表示方法，即前缀调整(prefix-tuning)或提示调整(prompt tuning)。这种技术的灵感来自人与人之间的现实交流。例如，当向他人解释一个复杂的概念时，人们会选择适当的语言和方式来引导他人理解，以提高沟通效果。以下是一些提示工程的案例。

1. 问答系统

(1)提示可以用来训练模型提供具体的答案，如“对这个问题的直接答案是_____”。

(2)提示可以用来训练模型提供理由或解释，如“这个答案的解释是_____”。

2. 对话系统

(1)提示可以用来训练模型生成更自然的回复，如“一个人可能会这样回答：_____”。

(2)提示可以用来训练模型遵循一定的对话规则，如“在正式场合，你应该这样回答：_____”。

3. 翻译系统

(1)提示可以用来引导模型进行语言翻译，如“这段文本用英语来表达应该是_____”。

(2)提示可以用来引导模型理解文化背景，并在翻译时考虑到，如“考虑到文化差异，这段文本用英语来表达应该是_____”。

以上是一些简单的例子，提示工程的实际应用是多种多样的，不仅限于上述情况。实际上，提示工程可以被应用于任何自然语言理解任务中，关键在于如何设计出能够有效引导模型的提示。

此外，还可以使用大语言模型生成一些考核用的文本，例如，要让大语言模型生成 Python 语言相关的试题，以“请给我 3 道 Python 相关的单选题 ”进行提问时，结果如图 9-5 所示。

**图 9-5　使用大语言模型进行简单提问**

用户也可以提出更多的要求让大语言模型生成更加符合需要的内容，例如，以“请按照难度为低级、中级、高级，给我 3 道 Python 相关的单选题 ”进行提问时，结果如图 9-6 所示。可以发现，大语言模型按照低级、中级、高级的难度分别生成了 3 道试题，试题的难度逐步提升。此外，还可以按照想考察的领域、试题类型，再逐步向大语言模型提问，从而获取更加准确的结果。

**图 9-6　使用大语言模型进行追问**

## 9.3 大语言模型的应用

大语言模型目前已经广泛应用到人们的生产生活中，目前涌现出的智能化大语言模型的应用主要包括以下几类。

(1)文本生成与分类。大语言模型可以用于生成各种类型的文本，包括自动摘要、机器翻译、对话系统、写作助手和创意文本生成等。同时，它也可以用于将文本分为不同的类别或标签，如情感分析、垃圾邮件检测、主题分类和情感识别等。

(2)信息检索和搜索引擎。大语言模型可以理解用户的查询意图，提供更准确的搜索结果。它可以帮助搜索引擎进行相关性排序、语义匹配和搜索推荐。

(3)语音识别和语音合成。在语音识别任务中，大语言模型可以将语音转化为文本。同时，它也可以与语音合成技术结合，将文本转化为自然流畅的语音。

(4)对话系统。大语言模型用于对话系统中的自然语言理解和生成。它可以帮助系统理解用户的意图，并生成连贯的回复，实现智能对话。

(5)智能文本分析。大语言模型可以分析和理解文本中的语义、情感与主题。它可以应用于舆情分析、社交媒体挖掘、信息提取和知识图谱构建等领域。

(6)计算机视觉。计算机视觉领域基于大语言模型的研究主要体现在扩散生成模型方法，这种方法基于大量文本提示词与图像的训练技术能够实现一种生成式模型，它通过模拟数据的扩散过程来生成新的样本。这种模型最近在提高图像的分辨率、图像和音频生成方面显示出了巨大的潜力。

(7)金融领域。大语言模型能够处理和分析大规模文本数据，辅助进行宏观经济分析、市场趋势预测等。在投资场景中，大语言模型可用于投资决策、风险评估、市场分析等，例如分析央行对货币政策的态度。

这些大语言模型的应用通常需要大量的数据进行训练，以获取足够的模型表现。同时，它们也通常需要高级别的硬件支持，以实现模型的快速训练和推理。本节将介绍基于大语言模型的辅助写作助手 Notion AI 与文本阅读理解工具 ChatDOC。

### 9.3.1 基于大语言模型的辅助写作助手

Notion AI 是 Notion 应用程序中内置的 AI 功能，主要使用机器学习技术来帮助用户更高效地组织和管理内容。

具体来说，Notion AI 可以自动识别和分类文本、图像、文件等内容，以便用户更轻松地查找和使用它们。它还可以自动补全用户输入，提供相关建议和预测，以及将用户的语音转换为文本，从而帮助用户更快地完成他们的工作。另外，Notion AI 还有一些预设指令，如提供选题、写作博客、大纲和演讲稿等帮助。

使用 Notion AI 需要先注册 Notion 账号，可以通过该应用程序的网站进行注册，注册流程与其他网站类似。完成注册后，用户可以通过应用程序或网站使用 Notion AI 提供的功能。

图 9-7 是使用 Notion AI 进行自动写作的方法。Notion AI 通过 NLP 技术来自动补全用户

输入。具体来说，Notion AI 使用预训练的模型和算法来分析用户输入的文本，根据上下文和语境等信息，推荐接下来用户可能输入的文本内容。

**图 9-7　使用 Notion AI 转写文本**

比如，如果用户在 Notion 中创建一个新的页面，并输入了一些文字，Notion AI 会自动分析这些文字，并根据用户的输入推荐接下来用户可能输入的文本内容。这些推荐内容会以建议列表的形式展示在页面下方，用户可以从建议列表中选择自己需要的内容，并将其添加到页面中。同时，Notion AI 还支持语音输入功能，用户可以通过语音来输入文本内容，这个功能是基于语音识别技术实现的。以图 9-7 为例，用户想要输入一些关于“数字孪生技术介绍”的相关文本，可以选中该段文本，并选择 Make longer 选项，系统会将更多相关的文本添加到页面中。

### 9.3.2　基于大语言模型的文献辅助阅读工具

在初步接触和阅读某一领域的文献时，大语言模型可以帮助读者很好地理解这一领域的知识，可以提高读者获取知识的效率，从而读者能够更有效地处理和理解文档内容。在这一领域，发展较为成熟的工具有 ChatPDF、ChatDOC、Notion AI 等，它们都是以 LLM 为基础构建的文献理解工具，链接如下。

**ChatDOC 使用简介**

ChatDOC：https://chatdoc.com/

ChatPDF：https://www.chatpdf.com/

Notion AI：https://www.notion.so/

以 ChatDOC 为例，该工具有文本智能分析功能，可以准确高效地处理文本和表格数据，如图 9-8 所示。基于大语言模型的强大能力，该工具可以对文献内容进行总结、摘要、翻译、知识点查询等，并能在 AI 的辅助下快速完成。同时，ChatDOC 还支持追问功能，允许用户针对某一特定问答，以新的子窗口持续进行多轮问答。读者可以前往 ChatDOC 网站上传文档，使用该工具辅助文献阅读。

图 9-8　文献辅助阅读工具 ChatDOC

ChatPDF 的使示例用如图 9-9 所示，这类文献辅助工具均提供了问题示例，可以通过系统提供的简单问题对文章进行总结或分析。

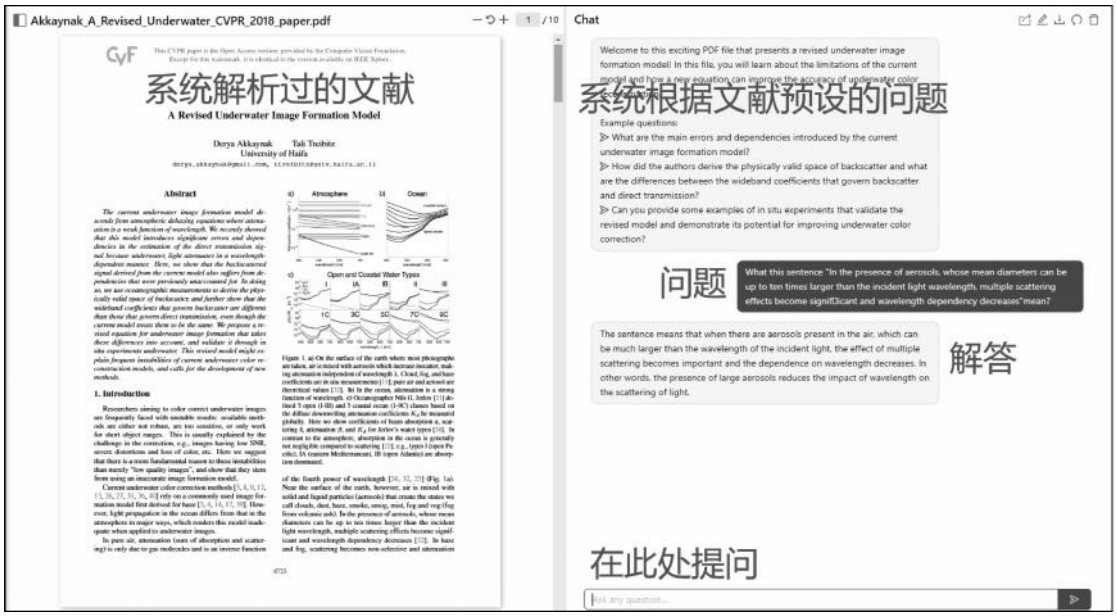


图 9-9　文献辅助阅读工具 ChatPDF 的使用示例

### 9.3.3　基于大语言模型的金融服务助手

金融业作为数据密集型行业，是大模型应用落地的优选场景之一。大语言模型在模型

性能及能力上的跨越式提升，更好地满足了众多金融场景，如智能投顾、智能投研、智能风控、智能交互等对人工智能技术有需求场景，加快了金融行业的技术升级进程。

2023 年 9 月 8 日，在上海举行的外滩大会上，蚂蚁集团正式发布了蚂蚁金融大模型。聚焦金融场景的“研判观点提取”“金融意图理解”“金融事件推理”能力在两款产品上得到应用，分别是面向消费者的智能金融助理“支小宝 2.0”和服务金融产业专家的智能业务助手“支小助”，这也展示了蚂蚁集团在大模型领域从技术到产业应用的全面进展。做出理想的金融小助手，是近些年来金融科技圈想要攻克的难题。接入了蚂蚁金融大模型技术的智能金融助理“支小宝 2.0”，率先实现了从检索式 AI 到生成式 AI 的跃升。

据统计，“支小宝 2.0”的金融意图识别准确率达到 95%，金融资讯总结和事件推理水平已经达到了行业专家平均水平。无论是产品评测、收益分析、要不要加减仓、解读行情，或者是咨询资产配置方案，选择保险，都可以通过向“支小宝 2.0”提问来获得参考答案。

另一个智能业务助理“支小助”，则是一个真人专家一样的“打工人”，被认为可能引发金融机构从业人员生产模式和生产力的变革。“支小助 1.0”包含“服务专家版”“投研专家版”“理赔专家版”“保险研究专家版”等 6 个版本，可以在投研分析、信息提取、专业创作、商机洞察、金融工具使用等环节，为理财师、保险代理人等从业人员提供深度智能服务。

以医疗险理赔为例，用户平均要提交 11 张医疗单据，基于海量图文预训练的多模态大模型可将复杂单据的整案提取准确率由 80%提升至 98%。“理赔支小助”让门诊险理赔和 30%以上的住院医疗险理赔能够完全自动化完成，而且这个比例还在快速提高，为保险公司降本增效。

## 习　　题

1. 相似文本匹配。

有一个搜索引擎资源库，里面包含 sentence1、sentence2、sentence3 三个句子，现在要进行查询并按相似度排序后返回结果。使用 Python 语言的 Gensim 库完成文本相似度的匹配。参考代码如图 9-10 所示。

```
from gensim import corpora, models, similarities
import jieba
from collections import defaultdict
# 1.导入句子
sentence1 = "我喜欢吃番薯"
sentence2 = "番薯是个好东西"
sentence3 = "利用python进行文本挖掘"
# 2.分词
data1 = " ".join(jieba.cut(sentence1))
data2 = " ".join(jieba.cut(sentence2))
data3 = " ".join(jieba.cut(sentence3))
# 3.转换格式："词语1 词语2 词语3 … 词语n"
texts = [list(data1), list(data2), list(data3)]
# 4.基于文本建立词典
dictionary = corpora.Dictionary(texts)
featureNum=len(dictionary.token2id.keys())#提取词典特征数
dictionary.save("./dictionary.txt")#保存语料库
# 5.基于词典建立新的语料库
corpus = [dictionary.doc2bow(text) for text in texts]
# 6.TF-IDF处理
tfidf = models.TfidfModel(corpus)
```

```
# 7.加载对比句子并整理其格式
query = "吃东西"
data4 = jieba.cut(query)
data41 = ""
for item in data4:
    data41 += item+" "
new_doc = data41
# 8.将对比句子转换为稀疏向量
new_vec = dictionary.doc2bow(new_doc.split())
# 9.计算相似性
index = similarities.SparseMatrixSimilarity(tfidf[corpus],num_features=featureNum)
sim = index[tfidf[new_vec]]
for i in range(len(sim)):
    print("查询与第"+str(i+1)+"句话的相似度为:"+str(sim[i]))
```

**图 9-10　相似文本匹配参考代码**

输出结果如下。

```
查询与第 1 句话的相似度为：0.399284
查询与第 2 句话的相似度为：0.347683
查询与第 3 句话的相似度为：0.0
```

2. 使用 ChatGPT 或百度文心一言等大语言模型，对比使用提示工程与不使用提示工程的回答结果。

3. 使用 ChatDOC 快速理解某一领域的文献。具体步骤如下。

(1)前往 ChatDOC 官网，上传一篇英文文献。

(2)使用如下提问方式对文章进行总结："请帮我总结这份文献的主要工作"。

(3)对于不理解的细节语句，利用 ChatDOC 的"灯泡图标"功能，单击并弹出相关问题参考。

习题解析