第 10 章 数据科学竞赛

章节导航

- 了解国内外大数据竞赛平台的基本情况，熟悉大数据竞赛平台的主要功能、风格及竞赛开展方式。
- 了解参加数据科学竞赛的基本流程。
- 通过 2021 年“数字中国”创新大赛大数据赛道——城市管理大数据专题赛题解析，了解并掌握数据科学竞赛的解题流程与关键步骤，为参加数据科学竞赛积累经验。

本章知识导图

10.1 竞赛平台

本节将简要介绍国内外精彩纷呈的大数据竞赛平台，让读者了解参赛途径，积极参与自己感兴趣的赛事。

kaggle 比赛的报名与参赛

10.1.1 kaggle

kaggle 竞赛平台首页(https://www.kaggle.com)如图 10-1 所示。kaggle 成立于 2010 年，是一个数据科学和机器学习社区平台，2017 年 3 月被谷歌 Cloud 收购。企业和研究者可在 kaggle 上发布数据，统计学者和数据挖掘专家可在平台上进行竞赛以获得最好的模型。

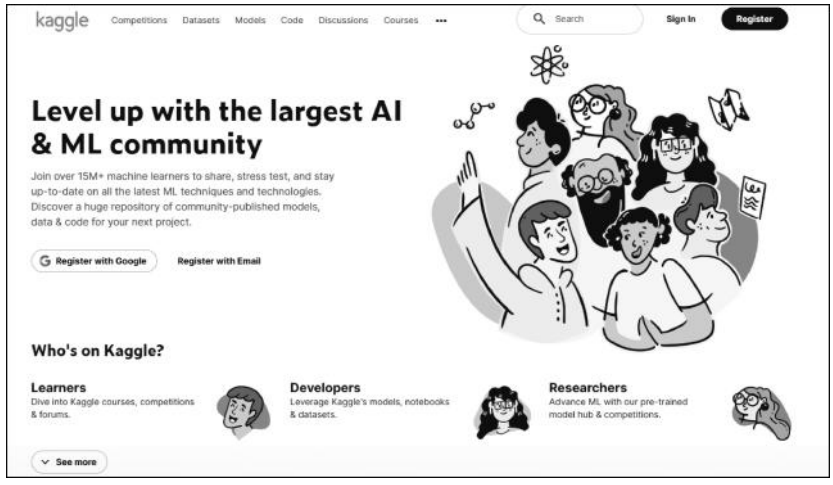

图 10-1 kaggle 竞赛平台首页

kaggle 中的数据科学家和机器学习爱好者可以访问大量的开放数据集，参与数据竞赛，分享项目和代码，以及学习最新的数据科学技术和方法，同时，kaggle 也为用户提供了项目协作、项目学习的机会。该平台还提供了一个内置的 Python 环境和 GPU 支持，以帮助用户进行数据分析和机器学习建模。kaggle 作为知名的数据科学社区，为参与者提供了各种协作与知识共享的机会。

10.1.2 DrivenData

DrivenData 竞赛平台首页（https://www.drivendata.org）如图 10-2 所示，DrivenData 是德国的一个与数据科学相关的众包网站。DrivenData 举办数据科学竞赛的目的是要建设更美好的世界，用最先进的预测模型来解决世界上最棘手的问题。DrivenData 在国际发展、医疗、教育、研究和保护及公共服务等领域举办数据科学竞赛，以谋求社会效益。

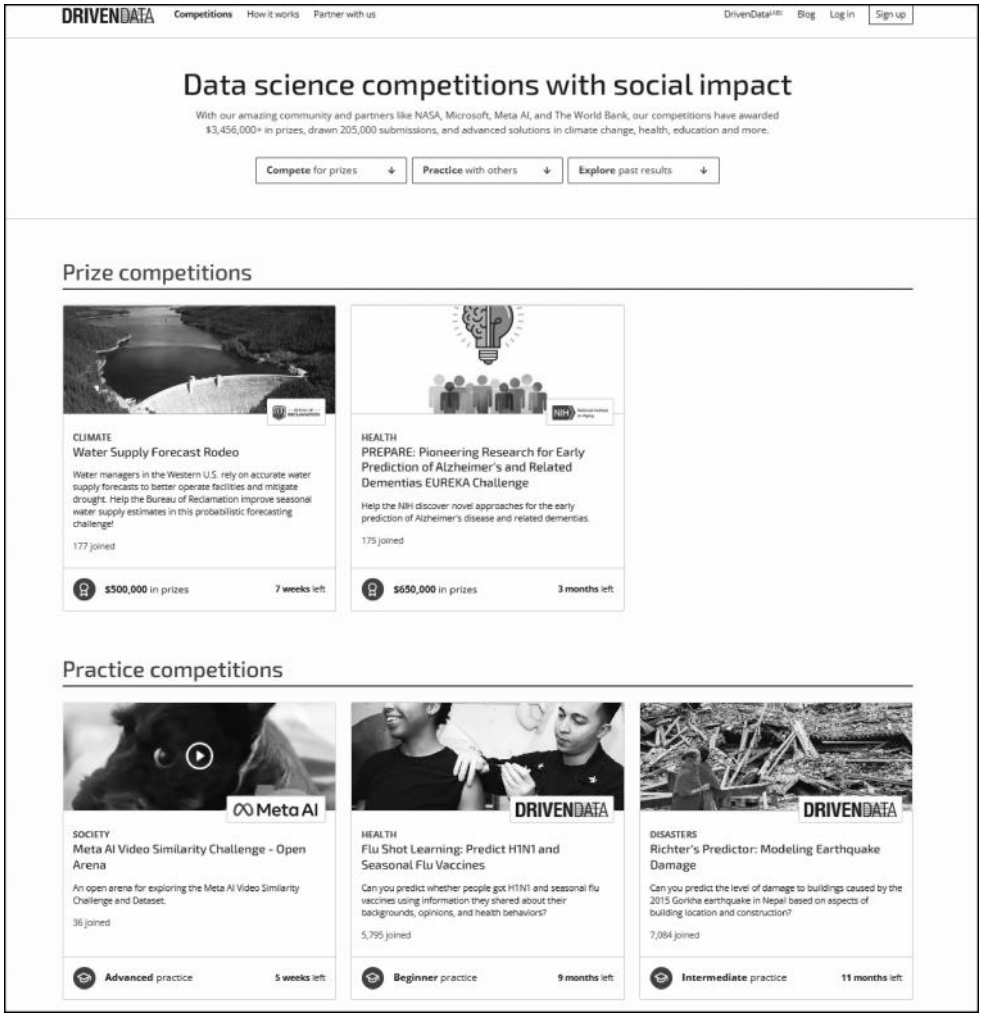

图 10-2　DrivenData 竞赛平台首页

用户可以参加 DrivenData 平台上的竞赛，也可以通过该平台举办自己的竞赛。发起人

可将竞赛托管给 DrivenData 平台(竞赛时间通常为 2～3 个月)。该网站有专门的示例项目部分，以案例研究的形式展示了一些成功的项目。DrivenData 列出的数据集都与一些非营利组织相关，数据从野生动物保护到公共卫生都有。

10.1.3　阿里云天池

阿里云天池竞赛平台首页(https://tianchi.aliyun.com)如图 10-3 所示。阿里云天池是国内的一个大数据竞赛平台。大数据竞赛面向全社会开放，高等院校、科研单位、互联网企业等人员均可报名参赛，挖掘复杂异构多源数据之间的关联关系，开发并创作各种正能量的作品，并以形象生动的方式呈现给公众。平台理念是用算法解决社会或业务问题。竞赛主要包括算法大赛、创新应用大赛、云开发大赛等。

图 10-3　阿里云天池竞赛平台首页

阿里云天池竞赛平台的主要特色是为参赛者提供算力。众所周知，处理庞大的数据量往往需要配置高性能的计算机作为支持，对于没有条件追求高性能计算机的参赛者来说这是一个不利因素，阿里云天池竞赛平台充分考虑这一因素，为每位参赛选手提供了远程计算平台，即分布式计算平台，消除硬件配置对参赛者的影响。

10.1.4　DataCastle

DataCastle(DC)竞赛平台首页(https://www.datacastle.cn)如图 10-4 所示。DataCastle 是为企业和科研院所提供服务的竞赛平台，它的竞赛形式主要有算法竞赛、创意竞赛、与企业合作的开发竞赛。例如，某企业 Watch APP 应用开发大赛，基于 Android 系统，结合企业提供的系统用户界面(user interface，UI)规范、控件库、软件开发工具包(software development kit，SDK)等内容进行定制化开发等。

DataCastle 竞赛平台的参赛题目大多采取开放式，涉及生活、内容、社交、健康、休闲小程序等。

图 10-4　DataCastle 竞赛平台首页

10.1.5　DataFountain

DataFountain（DF）竞赛平台首页（https://www.datafountain.cn）如图 10-5 所示。DataFountain 通过众包模式汇集各类大数据资源；以“众筹”模式汇集行业需求，形成大数据问题求解、科学发现、人工智能、商业智能、情报挖掘、大数据分析和大数据管理等具挑战性的问题集合；以众创模式吸引全国最大规模的数据创新创业人才和最优秀的数据科学家共同解决复杂的大问题；通过创意大赛挖掘有价值的大数据应用及创新的商业模式。

图 10-5　DataFountain 竞赛平台首页

DataFountain 是中国计算机学会(China Computer Federation，CCF)指定的专业大数据及人工智能竞赛平台，支持 CCF 主办的大数据及人工智能领域算法挑战及应用创新大型赛事。CCF 大数据与计算智能大赛每年由不同的高校或者企业出题，赛事题目比较前沿且具有挑战性。

10.1.6　ChinaVis

ChinaVis 竞赛平台首页(https://chinavis.org)如图 10-6 所示。ChinaVis 竞赛平台定期举办 ChinaVis 挑战赛，这是中国可视化与可视分析大会的一个重要环节。挑战赛邀请科研人员、开发人员和爱好者使用他们最有效的可视分析技术和工具来完成数据分析任务。挑战赛旨在帮助研究人员、开发人员和爱好者评估他们的技术与工具在解决复杂问题中的有效性和新颖性，并促进我国可视化与可视分析相关研究及应用的发展和进步。

图 10-6　ChinaVis 竞赛平台首页

该平台的功能较广，除了可视化竞赛，还涉及国内可视化领域学术会议、学术交流、可视化技术应用课程、科普等多项功能，是我国可视化领域学术交流的综合性平台。

10.1.7　和鲸社区

和鲸社区(https://www.heywhale.com)是中国知名的第三方数据科学协同平台之一。用户可向平台申请举办比赛，公开发布比赛信息，参赛者可选择感兴趣的比赛参与。平台汇集来自企业和科研机构的数据科学任务，用户可以自由申请参加比赛，锻炼实战能力，获得悬赏奖金。

和鲸社区使用指南

表 10-1 是上述国内外大数据竞赛平台一览表。

表 10-1　大数据竞赛平台一览表

竞赛平台	简介
kaggle	国际认可度最高的竞赛平台之一，众包平台，集竞赛、在线学习、竞赛练习、社区于一体
DrivenData	数据科学相关的众包网站，开放的数据源

续表

竞赛平台	简介
阿里云天池	阿里巴巴公司主办的竞赛平台，国内认可度最高，比赛奖金较高，难度较大，参赛人数很多
DataCastle	电子科技大学主办的竞赛平台，比赛很多、较成熟
DataFountain	CCF 数据竞赛指定平台
ChinaVis	ChinaVis 挑战赛官方平台，支持国内可视化领域学术会议、学术交流、课程、科普等活动
和鲸社区	众包网络平台，集数据集、比赛、众包项目、大数据 AI 教学/科研平台于一体
其他	Biendata(人工智能技术竞赛平台)、百度点石隐私计算平台、腾讯云开发者社区竞赛平台、华为云开发者竞赛平台等

10.2 参赛流程

在数据科学竞赛中，参赛选手通过对赛题的理解、分析，形成的输出成果主要有算法报告、决赛答辩演示、系统原型、算法工具、市场分析报告、应用程序等。下面以某证券公司基于大数据的 A 股市场选股咨询平台的赛题为例，从需求分析、数据治理、算法分析、应用创新、落地实施践行等角度分析，介绍参加大数据竞赛的流程。

第一步，参赛选手需要对赛题进行需求分析。首先需要进行大量的文献调研，深入了解他人所做的前沿工作，借鉴前人处理问题的思路、技术路线与方法论。以本赛题为例，参赛选手在充分调研后，了解到 A 股市场选股咨询平台的现状如下：

(1)根据多年的炒股经验预测股价；

(2)根据历史基本面数据和交易数据预测股价。

通过数据建模，参赛选手想要达到的预期效果是充分挖掘出 A 股的新闻事件与文本信息，并利用这些信息，给客户提供准确和实时的股票推荐。

第二步，充分理解赛题的基本任务后，需要获取数据。这部分工作主要涉及数据隐私，可通过公开渠道获取 A 股市场的基本面数据和交易数据，例如，通过网络爬虫技术爬取上市公司的公告文本和新闻标题。数据采集完成后，开始对数据进行预处理，主要包括对数据进行清洗和对数据进行标准化，如归一化处理。

在这个赛题的解析过程中，可以通过爬取上市公司公告的方式获取相关文本信息，对采集到的数据进行清洗后，用文本处理方法就能够得到一系列结构化数据，如图 10-7 所示。


```
"000806-*ST 银河-关于公司相关人事变动的公告":{
    "证券代码":"000806",
    证券简称":"*ST 银河",
    "人事变动":{
        "高职高管姓名":"谢家浩",
        "高职高管性":"先生",
        "高职高管职务 ":"监事",
        "高职原因":"个人原因",
        "继任者姓名":" ",
        "继任者性别":" ",
        "继任者职务":" ",
    },
    {
        "高职高管姓名":"裴小静",
        "高职高管性别":"女士",
        "高职高管职务":"监事",
        "高职原因":"个人原因",
        "继任者姓名":" ",
        "继任者性别":" ",
        "继任者职务":" ",
    },
    {
        "高职高管姓名":"李武",
        "高职高管性别":"先生",
        "高职高管职务":"独立董事",
        "高职原因":"个人原因",
```


图 10-7　一系列结构化数据

第三步，建模。基于采集数据对赛题的基本任务建立数学模型。建模分为以下几个步骤：

(1)基本面分析；

(2)利用增持发生前的基本面数据和交易数据对收益进行建模与预测；

(3)利用公告文本、历史基本面数据和交易数据对收益进行建模与预测；

(4)利用新闻标题、基本面数据和交易数据对收益进行建模与预测。

第四步，将前端与后台结合，如图 10-8 所示，完成一个股票咨询平台。至此，整个赛题的基本流程就结束了。

综上所述，数据科学竞赛流程如图 10-9 所示。首先，要做数据准备，包括理解任务、导入数据、数据清洗；其次，要构建模型，设计算法框架，进行模型预训练，训练现有数据集，并完善模型；再次，选择合适的评价指标，对模型进行评估，再将之转化为最终的参赛作品；最后，提交作品并进行计分排名，进行最终的答辩准备与提交成果报告。

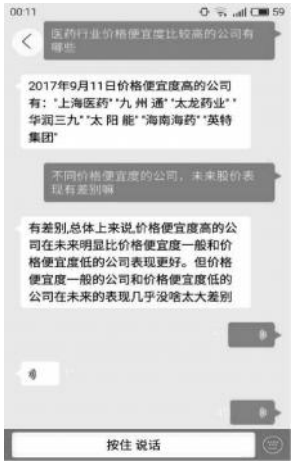

图 10-8　股票咨询平台成果展示

图 10-9　数据科学竞赛流程

10.3 赛题解析

本节将以 2021 年“数字中国”创新大赛大数据赛道——城市管理大数据专题的获奖案例为例，对赛题(早高峰共享单车潮汐点的群智优化)进行详细分析与讲解，并给出赛题的算法分析报告与答辩报告。

10.3.1　算法分析报告

1. 赛题需求

在早高峰(7:00—9:00 AM)，部分繁忙地段时常发生因共享单车围栏爆满或缺乏导致的共享单车占道及“乱停车”问题。通过对哈啰单车调度人员的调查发现，目前较为常用的解决“借不到”“还不进”问题的方案是：通过调度车全天将单车淤积严重地区的共享单车运送至邻近的非淤积点，较为耗费人力、物力。

早高峰共享单车潮汐点的群智优化赛题解析

本赛题中，城市公共自行车从业者将发生在早晚高峰时段共享单车“借不

到”“还不进”的问题称为潮汐现象。为更好地掌握早高峰潮汐现象的变化规律与趋势，参赛者需基于主办方提供的数据进行数据分析和计算模型构建等工作，聚集“还不进”问题，识别出工作日早高峰(7:00—9:00 AM)潮汐现象最突出的 40 个区域，列出各区域所包含的共享单车停车点位编号、名称，并提供计算方法说明及计算模型。参赛选手需根据计算得到的 40 个区域，进一步设计高峰期共享单车潮汐点优化方案，通过主动引导停车用户到邻近停车点位停车，进行削峰填谷，缓解潮汐点停车位(如地铁口)的拥堵问题。大赛中，允许参赛选手自带训练数据，但需在参赛作品中说明自带数据的来源及使用方式，保证其合法合规。

2. 数据来源

官方提供的数据为共享单车停车点位数据及共享单车订单数据，主要包括以下内容。

数据集 1：共享单车停车点位(电子围栏)数据（fence）。

(1)FENCE_ID：电子围栏唯一编号。

(2)FENCE_LOC：电子围栏位置坐标串(包括电子围栏所在位置 4 个顶点的坐标信息，WGS84 坐标)。

数据集 2：共享单车订单数据（bike）。

(1)BICYCLE_ID：车辆编码。

(2)LATITUDE：纬度(WGS84 坐标)。

(3)LONGITUDE：经度(WGS84 坐标)。

(4)LOCK_STATUS：锁的状态(0 表示开锁，1 表示关锁)。

(5)UPDATE_TIME：锁状态更新时间。

3. 数据清洗

数据的统计量分析如图 10-10 所示。

	BICYCLE_ID	LATITUDE	LONGITUDE	LOCK_STATUS	UPDATE_TIME
count	585292	585292.000000	585292.000000	585292.000000	585292
unique	53630	NaN	NaN	NaN	67030
top	1677a23507c85c2e90f7d6f7fb30d07e	NaN	NaN	NaN	2020-12-25 08:18:42
freq	687	NaN	NaN	NaN	55
first	NaN	NaN	NaN	NaN	2020-12-21 06:00:01
last	NaN	NaN	NaN	NaN	2020-12-25 09:59:59
mean	NaN	24.493837	118.126170	0.384367	NaN
std	NaN	0.023531	0.031745	0.486446	NaN
min	NaN	24.425358	118.058908	0.000000	NaN
25%	NaN	24.476612	118.100946	0.000000	NaN
50%	NaN	24.490166	118.122539	0.000000	NaN
75%	NaN	24.511676	118.151563	1.000000	NaN
max	NaN	24.559082	118.195922	1.000000	NaN

图 10-10　数据的统计量分析

数据清洗任务主要是清洗以下两种情况的数据：

(1)存在连续的开关锁数据(某些锁已损坏)；

(2)提供的数据其 UPDATE_TIME 并不在 7 点至 9 点之间。

4. 特征挖掘

根据官方提供的参赛数据，可以对共享单车开/关锁数据进行进一步特征挖掘与可视化分析。

1)关于“乱停车”现象集中时段和地区的探索

共享单车“时间-停放量”可视化结果如图 10-11 所示，在允许范围外停车/取车量与在允许范围内停车/取车量的变化趋势没有特别明显的不同。

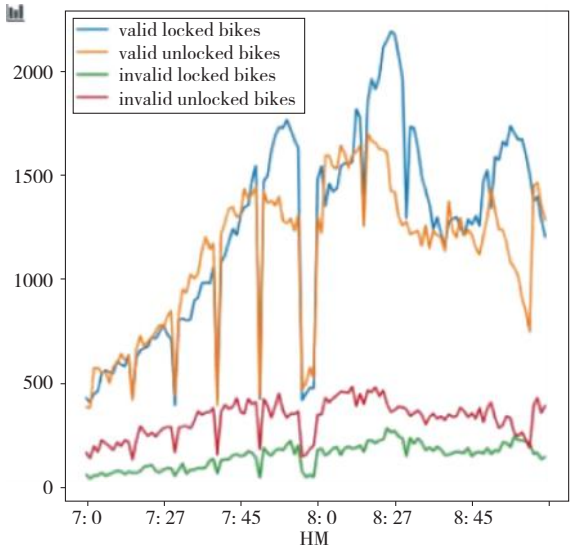

图 10-11　共享单车“时间-停放量”可视化结果

2）不同日期下的开/关锁数据分布情况

12 月 21 日—12 月 25 日的共享单车开/关锁数据分布如图 10-12 和图 10-13 所示，根据对比分析可知，可能因为圣诞节的缘故而导致早高峰潮汐现象的地点不同。

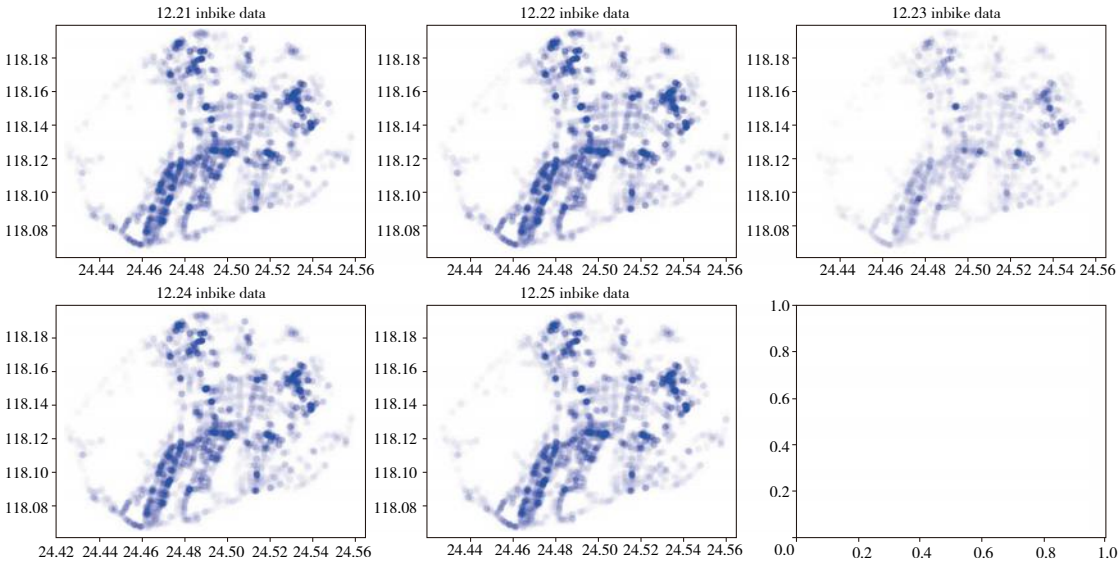

图 10-12　共享单车关锁数据分布

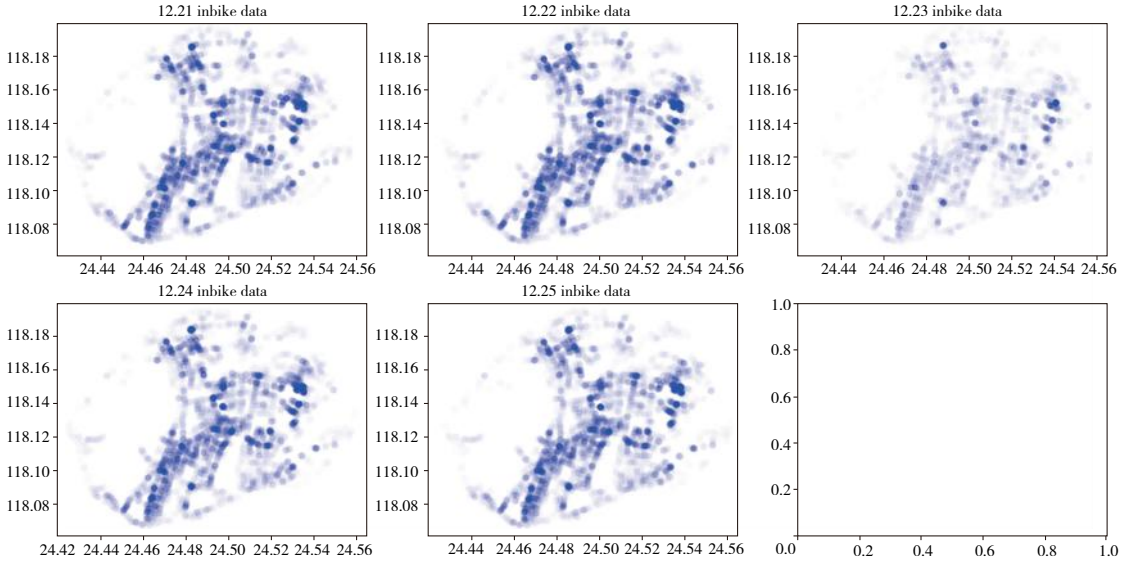

图 10-13　共享单车开锁数据分布

5. 区域划分模型选择

目前常用但有较明显缺陷的停车围栏区域划分策略包括网格划分法、街道名划分法、k 均值算法、DBSCAN 算法。

1)网格划分法

网格划分法的原理是将地图变成一个个方块，将同方块内的点作为同一个类进行处理。

如图 10-14 所示，在使用固定地理网格划分时，a、b、c、base 四个点会出现以下错误划分。

簇 A：(a，b，base)

簇 B：(c)

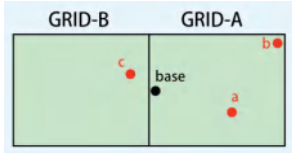

图 10-14　网格划分法

事实上 base 点与 c 点的距离远远小于 base 点与 a、b 点的距离，不应将 base 点与 c 点归为不同的簇而将 base 点与 a、b 点当作同一个簇。

2)街道名划分法

如图 10-15 所示，以长乐路与长浩路为例，部分区域(如圆圈所示)的共享单车围栏存在非常明显的与同街道其余点分离的情况，而在长浩路与长乐路的交界处(包含部分长乐路停车围栏与部分长浩路停车围栏)，停车围栏的离散程度极低，应作为同一簇处理。

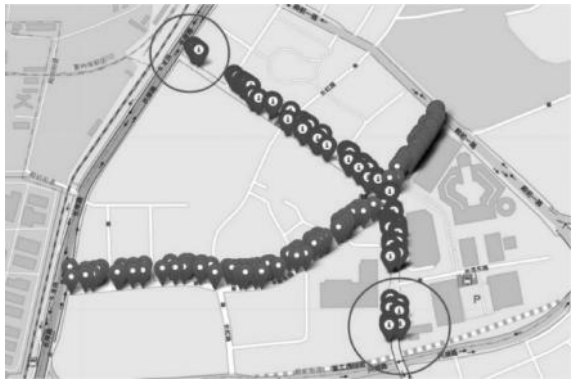

图 10-15　街道名划分法

3)k 均值算法

k 均值算法非常适合处理空间直线距离等于实际距离且已知分类树(分类树指根据训练数据集构造的一个类似树形的分类决策模型，可用来辅助决策)凸集的情况，但在实际地理信息中，经常出现“内外环”“两条直线距离极近的平行街道不互通”的状况。也就是出现不连通的非凸集合时，会出现错误的分类。在本项目中，无法确定簇数量，即无法定义 n_clusters 参数。

4)DBSCAN(密度聚类)算法

DBSCAN 是目前较为常用的聚类不规则形状簇的算法。本项目曾尝试过使用该算法进行聚类，发现了以下两个问题：

(1)DBSCAN 对 epsilon 参数极为敏感(该参数的细微变化都会导致结果截然不同，而如果不知道恰当的 epsilon，则无法进行聚类)；

(2)存在链式传导，即只要有少量的点断开，就会导致本应被分为同一个簇的点分裂为多个簇。

根据以上分析，区域划分模型的最终方案采取的划分方式为 HDBSCAN(hierarchical density-based spatial clustering of application with noise)。HDBSCAN 是 DBSCAN 算法与层次聚类算法的结合，可用于发现任意形状的簇，且在存在少量不连续点时也不会错误地将簇分裂。DBSCAN 和 HDBSCAN 算法的聚类效果的区别如图 10-16 所示。

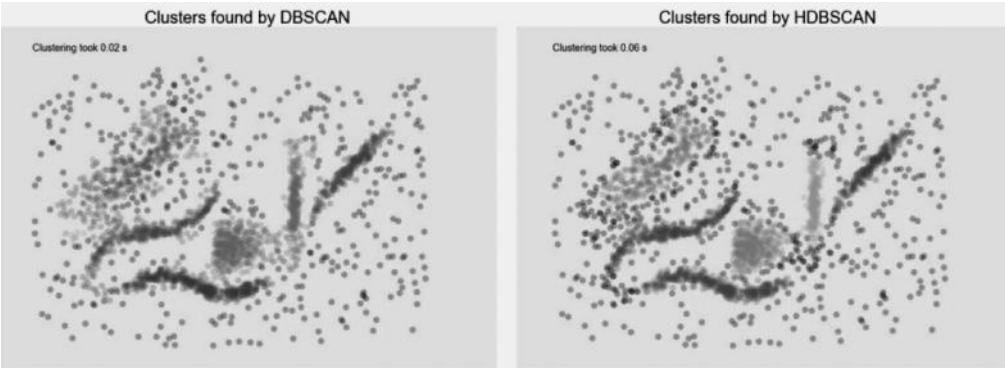

图 10-16　DBSCAN 和 HDBSCAN 算法的聚类效果的区别

最终基于 HDBSCAN 算法的区域划分结果生成了 1 733 个簇和分类为－1 的离群点集。其中，在原始 HDBSCAN 算法的基础上增加了合并簇的规则：若两簇之间的距离小于 33 m（规格小于双向六车道加绿化带的道路），或者中间无道路横穿的围栏，则应判断为同一区域。源代码如图 10-17 所示。

```
x = list(zip(fences['F_LATITUDE'].tolist(), fences['F_LONGITUDE'].tolist()))
cluster = hdbscan.HDBSCAN(min_cluster_size=2, gen_min_span_tree=True, cluster_selection_epsilon = 0.0003).fit(x).labels_

fences['CLUSTER'] = cluster
cluster_counter = collections.Counter(cluster)
print("{} fences in {} clusters".format(len(fences), len(cluster_counter)))
sorted_cluster =sorted(cluster_counter, key=lambda x: cluster_counter[x], reverse = True)
max_index = sorted_cluster[0] if sorted_cluster[0] != -1 else sorted_cluster[1]
print("Cluster {} has maximun number of fences, with fence number {}".format(max_index, cluster_counter[max_index]))
```

```
14071 fences in 1733 clusters
Cluster 1565 has maximun number of fences, with fence number 100
```

图 10-17　源代码-1

最后，再将每个离群点单独作为一个簇，最终簇数量为 3 109。源代码如图 10-18 所示。

```
fences['CLUSTER'] = cluster
cur = len(cluster_counter) - 1
# 将离群点(hdbscan分类为-1)提出来变成一个单独的簇,而不都是-1
for i in range(len(fences['CLUSTER'])):
    if fences.loc[i, 'CLUSTER'] == -1:
        fences.loc[i, 'CLUSTER'] = cur
        cur += 1
print("Number of clustering after let all outlier points become a single cluster: {}".format(cur))
```

```
Number of clustering after let all outlier points become a single cluster: 3109
```

图 10-18　源代码-2

10.3.2　答辩报告

在对 2021 年“数字中国”创新大赛大数据赛道——城市管理大数据专题分析报告有基本认识后，本节将根据参赛获奖者的答辩报告对赛题做更深层的解析，从解决方案、应用设计、总结思考 3 部分逐一作详细的报告。

1. 解决方案

解决方案部分主要针对共享单车潮汐区域的“车多”“车挤”“又多又挤”3 种识别方法做解析。代码中的 cluster _ detail 为按区域聚合后的数据表。

1)按区域内共享单车留存数量进行排序(车多)

如图 10-19、图 10-20 和图 10-21 所示，首先将 cluster _ detail 按照 FLOW 字段(共享单车留存数量)降序排列，观察前 40 个区域，其中一共包括 559 个共享单车围栏，然后用 Folium 库可视化潮汐停车围栏位置。

```
sorted_cluster_detail = cluster_detail.sort_values("FLOW", ascending = False)
sorted_cluster_detail.head(40)
```

图 10-19　源代码-3

```
top_40_flow = sorted_cluster_detail.index[:40]
top_40_flow_numbers = sum(sorted_cluster_detail['FID'][:40])
print("Number of fence in top 40 crowded clusters is :{}".format(top_40_flow_numbers))

Number of fence in top 40 crowded clusters is :559
```

图 10-20　源代码-4

图 10-21　潮汐停车围栏位置可视化-1

2)按区域内共享单车留存密度进行排序(车挤)

如图 10-22 和图 10-23 所示，首先将 cluster detail 按照 FLOW_DENSITY 字段(共享单车留存密度)进行排序，观察前 40 个区域，其中只有 64 个围栏。观察到这些数据中大部分留存密度较大的围栏都是单独成簇，即距离其他围栏较远，然后用 Folium 库可视化潮汐停车围栏位置。

```
top_40_density = sorted_density_detail.index[:40]
top_40_density_numbers = sum(sorted_density_detail['FID'][:40])
print("Number of fence in top 40 crowded clusters is :{}".format(top_40_density_numbers))

Number of fence in top 40 crowded clusters is :65
```

图 10-22　源代码-5

图 10-23　潮汐停车围栏位置可视化-2

3)按区域内共享单车留存数量与留存密度的综合指标进行排序(又多又挤)

如图 10-24、图 10-25 和图 10-26 所示，首先，将留存数量和留存密度采用 z-score 标准化后相加，以此排序，这样可以兼顾留存数量和留存密度两个指标，可以看到前 40 个区域共包含 353 个围栏，然后用 Folium 库可视化潮汐停车围栏位置。

```
flow_zscore = (cluster_detail['FLOW'] - cluster_detail['FLOW'].mean())/cluster_detail['FLOW'].std()
density_zscore = (cluster_detail['FLOW_DENSITY'] - cluster_detail['FLOW_DENSITY'].mean()) /cluster_detail['FLOW_DENSITY'].std()
cluster_detail['MIXED_SCORE'] = flow_zscore + density_zscore
```

图 10-24　源代码-6

```
export_res(top_40_mix, '../result.txt', fences)
f = pd.read_csv('../result.txt', sep = '|')
sum(f['FENCE_TYPE'])

353
```

图 10-25　源代码-7

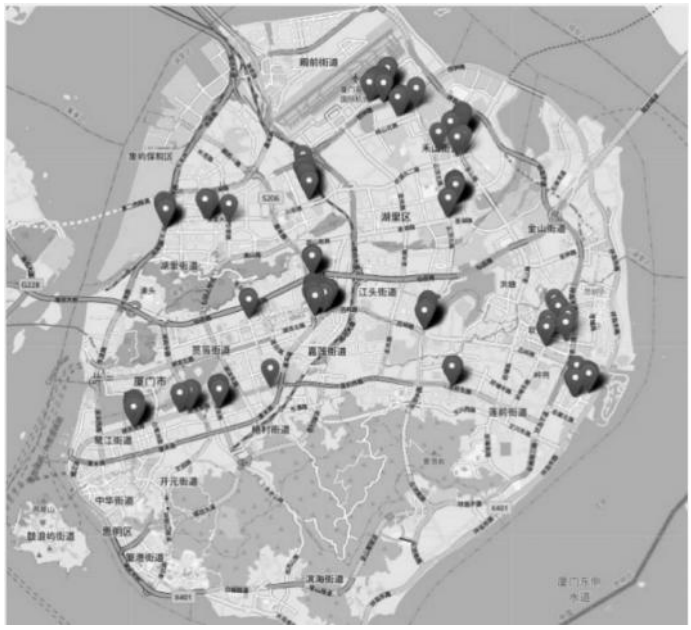

图 10-26　潮汐停车围栏位置可视化-3

在针对共享单车潮汐区域的“车多”“车挤”“又多又挤”3 种识别方法做解析后，继续探讨“又多又挤”指标下的聚类结果分析及调度可行性。

如图 10-27 所示，经地图放大和实地调研后，可以发现：潮汐簇所处区域均为企业密集区域、学校或商业区，如五一文化广场周边、双十中学周边、金源大厦周边、软件园 2/3 期等，符合实际情况。

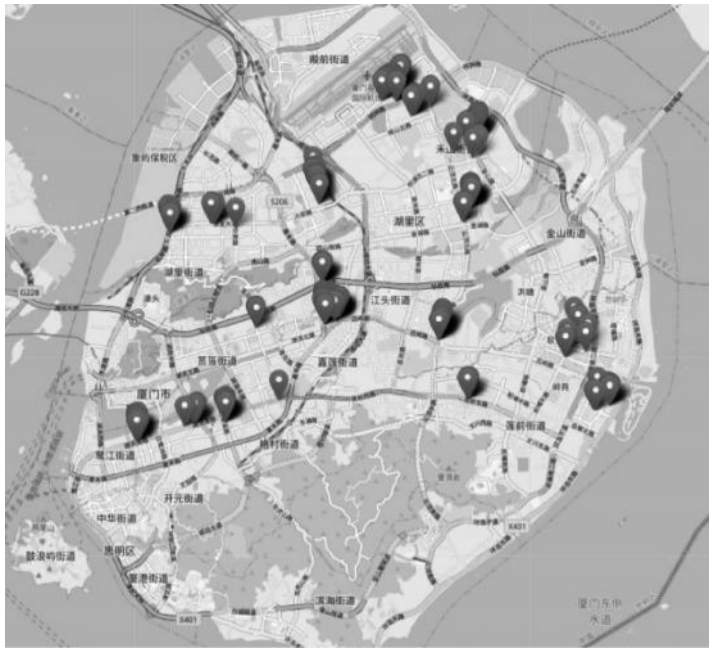

图 10-27　潮汐停车围栏位置可视化-4

在混合指标下排名第 800 位的共享单车围栏的拥挤程度已经可以接受(5 日留存数量 27，留存密度 1.51，综合分数 1.616 992)。将“又多又挤”程度排名在 800 位之前的围栏称为繁忙围栏，其余称为不繁忙围栏。如图 10-28 所示，对前 40 个繁忙簇中 353 个围栏进行繁忙度区分后，发现其中有 52.41%属于不繁忙围栏。而剩下的 47.59%繁忙围栏中存放了 92.86%（14 766 辆)的滞留单车，接下来可以选取一个繁忙簇进行观察，以证明相邻或相近的停车围栏是否存在着较大潮汐程度差距。

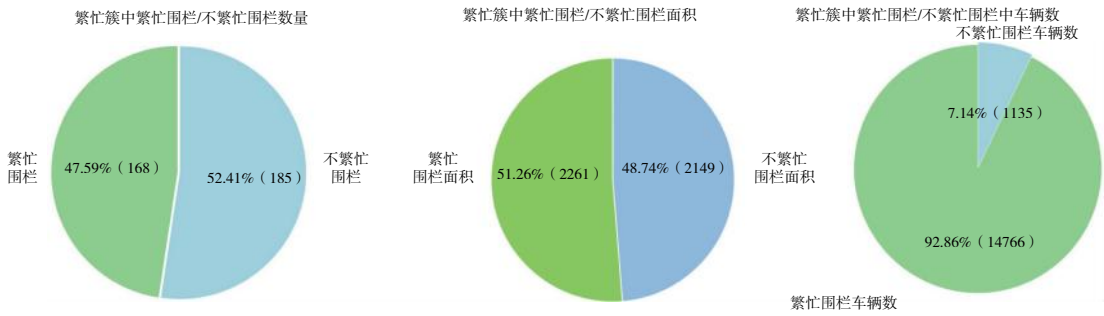

图 10-28　繁忙簇中繁忙/不繁忙围栏的分布

如图 10-29 所示，选取一个拥有 35 个停车围栏的繁忙簇进行观察，将综合分数高于 8 的围栏标记为黑色，其余繁忙围栏（1.61＜综合分数＜8)标记为红色，将不繁忙围栏标记为绿色。可以发现距离相近甚至相邻的围栏中，繁忙程度也有极大差距。这充分说明繁忙簇中距离相近的围栏中也存在着部分较为空闲的围栏可供潮汐围栏分流，为后续的共享单车调度提供了可行性支持。

图 10-29　繁忙簇中不同停车围栏的繁忙程度

2. 应用设计

应用设计这一部分，首先针对共享单车“还不进”问题设计用户调度算法，然后基于早高峰“乱停车”数据给出相关科学建议，最后对共享单车引导系统进行详细设计。

1)共享单车“还不进”问题的用户调度算法

经过对哈啰单车调度人员的调查，得知共享单车调度是全天进行的。因此，实际上拥挤围栏和算法中的繁忙围栏可能存在着差距，如若某个围栏刚刚实行过单车调度，那么这个围栏在之后的一段时间其实是不拥挤的。应使用当前共享单车存量和存量密度代替之前计算的流量与流量密度作为指标进行调度。所以可以将面临“停车难”问题的用户引导至较近的、符合以下规则之一的停车围栏：

(1)现存车辆较少且车辆密度较小；

(2)预计入流量及预计入密度较小。

其中预计入流量/入密度可通过将共享单车围栏的流量数据按照时间段划分后进行时间序列数据分析得到。因缺乏较为长期的时间序列数据，故没有在模拟引导中体现。

详细的算法调度过程的实施步骤如下。

(1)采用 geohash 算法获取当前坐标点的 geohash，并列举出当前 geohash 单元格及临近 8 个单元格的所有围栏。

(2)使用 Dijkstra 算法算出当前共享单车所在点与这些围栏之间在有向有权图中的最短路径。

(3)抛弃用户接受范围（max_distance)外的围栏，即移除最短路径距离大于该值的围栏。

(4)将停车围栏“又多又挤”的程度(现存车辆与现存车辆密度的 z-score 之和，若已知预计入流量，可用预计入流量代替“又多又挤”程度，或将其作为一个新的维度)、当前距离、正流量天数(可不用)标准化，分别乘以不同的正经验权重 k_1、k_2、k_3。设“又多又挤”程度为 x_1、当前距离为 x_2、正流量天数为 x_3，那么最终得到分数 $s=k_1\times x_1+k_2\times x_2+k_3\times x_3$，将用户引导至 s 最小的点。需要注意的是调度决策做出之后需要将目标围栏的车辆数暂时+1，防止出现相近时间多车同时调度导致的全部车辆涌向同一个点的问题。若接受调度的车辆最终关锁点不属于目标围栏，则目标围栏车辆计数−1。

最后基于上述调度算法，设计的模拟网页版 demo(bike _ app 应用)，如图 10-30 和图 10-31 所示。本次设置 $k_1=0.3$，$k_2=0.5$，$k_3=0$，max _ distance=500，实际应用中应根据具体情况修改。

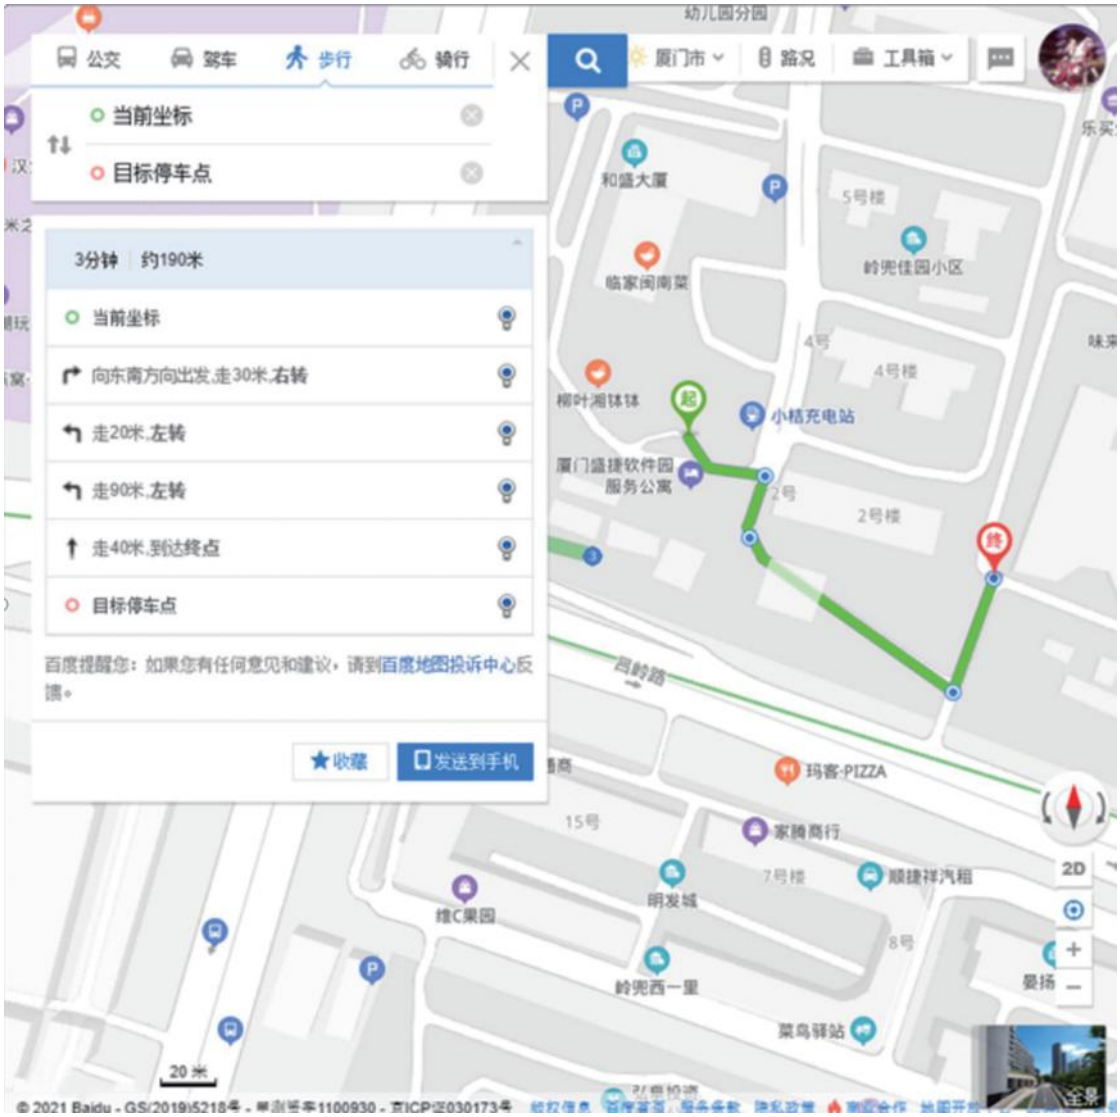

图 10-30　bike_app 应用展示图-1

	FID	ACTIVE_DAYS	DENSITY	FLOW	MIXED_SCORE	DISTANCE	LATITUDE	LONGITUDE	SCORE
16	1758	0	-0.761995	-9	-0.735531	189	24.490702	118.183098	-1.670227
8	9678	0	-2.615640	-18	-1.849687	370	24.488785	118.183478	-0.758149
5	9679	0	-2.221277	-17	-1.648761	393	24.488745	118.183476	-0.515803
15	9677	4	0.622175	5	0.383801	255	24.490640	118.183468	-0.313108
2	9731	1	-0.317668	-7	-0.474674	364	24.491127	118.183547	-0.179060
6	9680	0	-1.857759	-15	-1.420987	431	24.488430	118.183441	-0.153871
12	1752	0	-0.552064	-6	-0.531159	395	24.488707	118.183476	-0.088582
1	9732	0	0.000000	0	-0.068293	376	24.490747	118.183530	-0.056621
3	9675	1	-0.128349	-1	-0.160314	369	24.490716	118.183468	-0.026446
7	9733	0	-0.958979	-14	-1.013553	436	24.488272	118.183422	0.033104
10	1754	2	0.000000	0	-0.068293	371	24.490680	118.183471	0.137478
9	1751	0	-0.254171	-3	-0.290776	435	24.488336	118.183430	0.292628
13	9681	1	-0.368869	-3	-0.337734	432	24.488385	118.183436	0.368686
4	1753	4	0.689647	5	0.411424	377	24.490686	118.183524	0.589108
11	1757	5	1.477587	20	1.326136	319	24.491269	118.183139	0.618057
14	1759	3	0.259898	3	0.156535	440	24.488622	118.182973	0.840312
0	9750	3	0.587687	4	0.330206	437	24.488528	118.182975	0.882493

即将导航前往共享单车围栏会展路(塔埔路至目岭路段)_L_2, 该围栏单车流量为-9, 流量密度为-0.7619954224846628, 距离当前位置189米

图 10-31　bike_app 应用展示图-2

2)基于早高峰“乱停车”数据的建议

首先使用 HDBSCAN(min _ cluster _ size=500 表示一个簇的最小数据量为 500)，对前面所定义的停车允许范围外的共享单车(包括开锁和关锁，开锁处若为允许范围外，说明在 7 时之前出现了“乱停车”现象)进行聚类，发现存在 19 处较为集中的“乱停车”点，其分布图如图 10-32 所示。

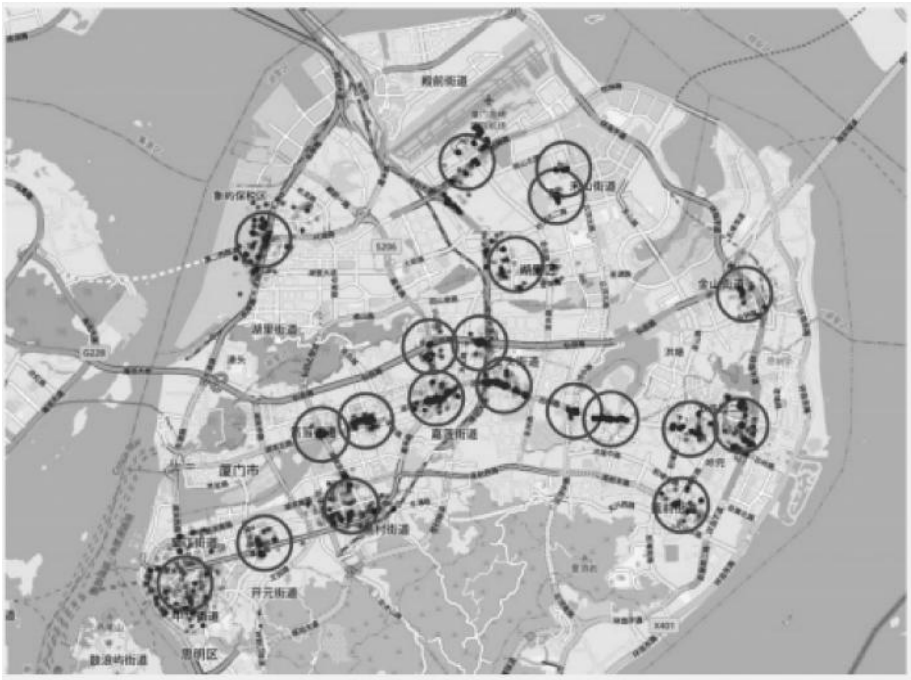

图 10-32　“乱停车”点分布图

图 10-33 是在中山路步行街附近(中华街道)的“乱停车”现象，可以看出，较近的共享单车围栏分布在镇海路、厦禾路和轮渡一侧，而该区域道路狭窄，车流量大，店铺众多，共享单车是此处最为便捷的出行方式。

图 10-33　中山路步行街附近的“乱停车”现象

前往该处进行实地调查后发现以下问题。

(1)咨询执勤交警得知，中山路步行街内不允许骑自行车进入。

(2)思明南路与思明西路部分未开业的商铺门口存在不少随意停放的共享单车。

(3)如图 10-34 所示，思明南路、思明北路、思明东路、思明西路道路狭窄，两侧均为商铺，不适合设立共享单车停车围栏。

(4)该区域小巷极多，调度车辆（在之前对于调度人员的调查中发现调度车辆均为小型卡车)难以进入，调度人员也很难在纵横交错的小巷中准确找到被随意停放的共享单车。

图 10-34　思明区附近某街道实况图

对此“乱停车”现象，除单车调度方法外，具体的实施建议如下。

(1)观察到中山路步行街入口处较为宽敞，是否可以在市政规划及市容允许的前提下于此处设立共享单车围栏。

(2)因小巷内散落共享单车的收集难度过高，应适当提高“乱停车”的处罚力度，并使用后续的调度系统进行引导。

3)共享单车引导系统的设计

共享单车引导系统主要由 3 部分组成，其元素关系图如图 10-35 所示。

(1)总调度数据库(可以考虑放置在厦门)及其 API：提供实时围栏存量信息或最新基于时间序列的预测信息供多个共享单车商家调用，避免企业间信息不互通导致的调度混乱问题，并可接收共享单车商家方回传的用户开/关锁信息供持续改进。

(2)地图 API（如百度地图、高德地图等）：提供城市图数据及最短路算法计算出的距离、提供实时寻路功能。

(3)共享单车商家方：从总数据库处请求实时停放情况，使用 APP 接入地图 API 获取当前点到各个围栏的实际距离，综合实时围栏存量等信息计算出围栏分数 s 并结合地图 API 实时寻路功能进行引导，传递开/关锁信息，确定奖惩措施。

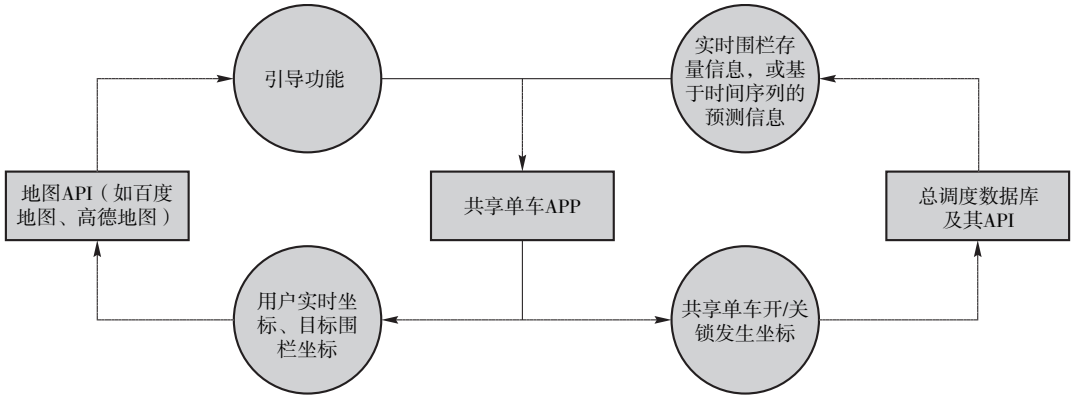

图 10-35　共享单车引导系统的元素关系图

3. 总结思考

基于上述对“数字中国”创新大赛——共享单车案例的具体分析，对本次作品做一个价值总结，主要从以下两方面总结。

1)基于共享单车商家和城市规划层面

(1)针对潮汐现象进行削峰填谷，使共享单车得到合理的调度，减少调度车使用次数，节约成本。

(2)针对开/关锁状态分析，能够发现共享单车是否存在故障现象，方便商家及时检查维修损坏车辆，保证共享单车的可用性。

(3)通过研究共享单车停放数据得出的用户通勤特征，结合实地考察分析“乱停车”现象，可以帮助设立更多合理的停车点，用以减少“乱停车”现象，美化市容市貌。

(4)通过数据交互实现市政与多个共享单车企业联动，提高共享单车交通治理效率；共

享单车企业可通过优惠券的形式进行“留客”。

2)基于用户层面

(1)缓解用户找不到最近停车围栏被迫“乱停车”被罚款的问题，改善用户体验。

(2)可以大大减少在下班高峰期、节假日的用餐时间等用车拥挤时段用户“还不进”车的问题，使得用户的生活出行变得更加便利、高效。

(3)以服从引导提供优惠券或 APP 游戏数值的形式，减少用户因“还不进”导致的烦躁感，为生活提供额外趣味。

习　题

1. 金融舆情信息识别分析

【赛题背景】

近年来，随着互联网和个人移动信息终端的持续发展，金融行业相关舆情(简称金融舆情)呈现新的态势，舆情出现时间集中、信息交互量大且传播速度快。金融舆情的产生和传播对投资者、金融机构乃至金融业都会产生显著的影响。某些小范围的信用危机，经过金融舆情的传导，则有可能酿成金融危机事件。因此，对金融舆情进行准确识别、自动分析和实时监测尤为重要。

【赛题任务】

根据给定的金融文本和文本中出现的金融实体列表，判定文本中是否包含金融实体的负面信息。如果该文本不包括负面信息，或包含负面信息但负面信息未涉及金融实体，则负面信息判定的结果为 0。

【数据】

(1)数据概况。

数据说明：中文自然语言文本——金融网络文本。

数据量：训练集数据量 5 000 条，测试集数据量 5 000 条，训练数据与测试数据样本包含的字段信息如表 10-2 和表 10-3 所示。

(2)字段说明。

数据全部以 .csv 格式给出。

训练数据样本包括标识号(id)、文本标题(title)、文本内容(text)、是否负面(negative)。

测试数据样本包括标识号(id)、文本标题(title)、文本内容(text)。

表 10-2　训练数据样本的字段信息

字段信息	类型	描述
id	String	标识号
title	String	文本标题
text	String	文本内容
negative	Int	文本是否包含负面信息， 0 代表正面，1 代表负面

表 10-3　测试数据样本的字段信息

字段信息	类型	描述
id	String	标识号
title	String	文本标题
text	String	文本内容

2. 2019 年腾讯广告算法大赛

【赛题背景】

广告曝光预估的目的是在广告主创建新广告和修改广告设置时，为广告主提供未来的广告曝光效果参考。通过这个预估参考，广告主能避免盲目地尝试优化，有效缩短广告的优化周期，降低试错成本，使广告效果尽快达到广告主的预期范围。比赛中使用的数据经过脱敏处理，本次大赛旨在挑选出更为优秀的曝光预估算法，以及遴选出杰出的社交广告算法达人。

【赛题任务】

腾讯效果广告采用的是 广义第二价格(generalized second-price，GSP)竞价机制，广告的实际曝光取决于广告的流量覆盖大小和在竞争广告中的相对竞争力水平。其中广告的流量覆盖取决于广告的人群定向(匹配对应特征的用户数量)、广告素材尺寸(匹配的广告位)及投放时段、预算等设置项。

【数据】

测试集是新的一批广告设置(有新的广告 id，也有老的广告 id 修改了设置)，要求预估这批广告的日曝光量 。

注意：

(1)目标为预测广告在特定配置下指定日期的曝光量；

(2)数据没有直接给出 label，需要自己从曝光日志数据中统计每个广告在每天的曝光量。

习题解析

附　录　DT 数据科学平台

1. 平台简介

DT 数据科学平台(ds. ditwin. cn)由本书编写组与协作单位联合开发。平台提供数据科学案例学习、实训案例练习、资讯浏览等功能。平台支持在线编码与调试，用户无须安装编程环境。平台案例模块收录了数据科学建模领域的经典案例，并提供详细的赛题解析、算法建模流程和性能测试功能。实训模块提供在线建模与评分功能。用户可以在线组队，提交实训结果，查看得分，并通过建模分析与系统评价不断优化模型效果。资讯模块包含平台更新动态、机器学习建模调参技巧、数据科学领域研究成果等资讯，供用户闲暇时浏览、学习。该平台目前仅对厦门大学自动化系研究生开放，其他读者如需注册请联系本书编者。

数据科学实训平台使用指南

2. DT 使用手册

(1)DT 数据科学平台的登录页如图 A-1 所示，未登录的用户访问该平台时，会跳转至登录页面。

图 A-1　DT 数据科学平台的登录页

（2）DT 数据科学平台的首页如图 A-2 所示。

图 A-2　DT 数据科学平台的首页

（3）DT 数据科学平台的案例页如图 A-3 所示，平台提供数据科学分析的各类案例，用户可以根据个人喜好学习不同案例，提升自己的数据处理与分析技能。

图 A-3　DT 数据科学平台的案例页

图 A-4 为 DT 数据科学平台的案例详情页，其中展示了案例的详细代码介绍。用户如果对案例感兴趣，可以单击“Fork 案例”按钮，将案例添加到个人中心。

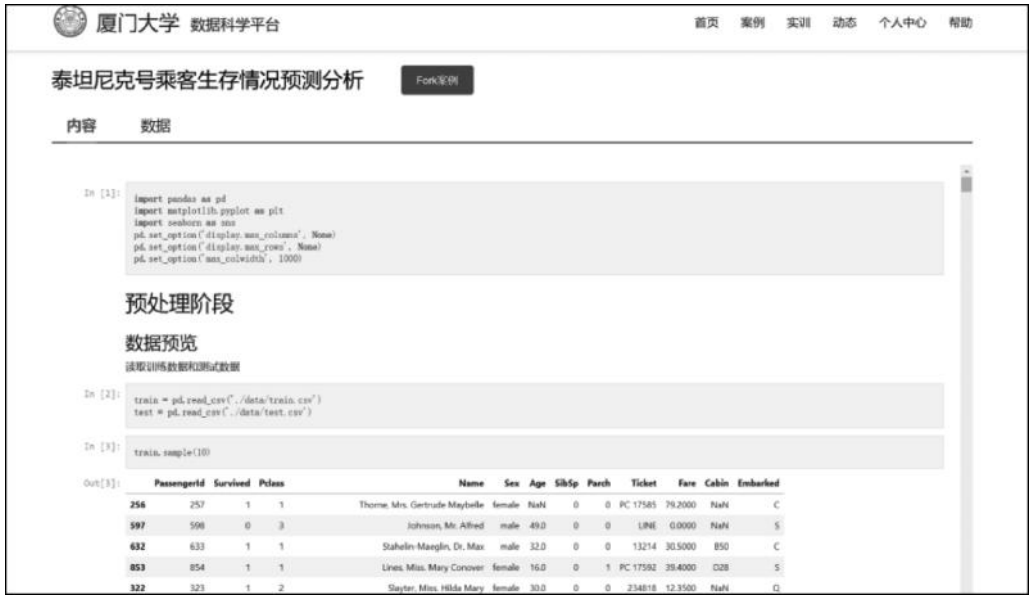

图 A-4　DT 数据科学平台的案例详情页

添加后，在“个人中心”→“我的案例”页会显示新增的案例，如图 A-5 所示，用户每次登录后可快速访问、学习所选案例。

图 A-5　DT 数据科学平台的我的案例页

如图 A-6 所示，用户可以对个人中心中的案例源代码进行在线编辑、在线运行。

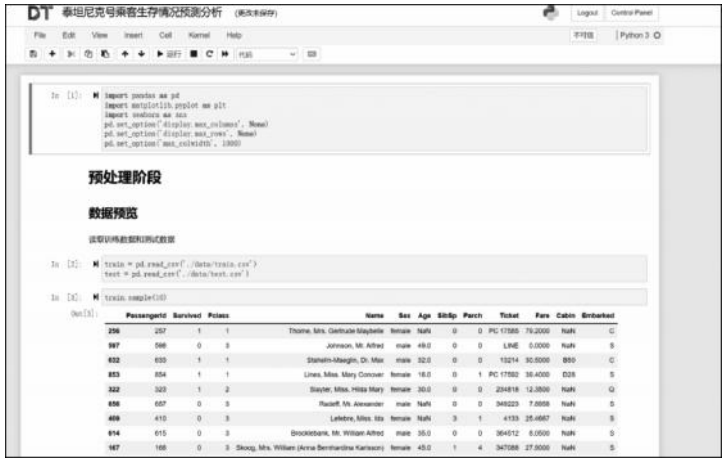

图 A-6　DT 数据科学平台的在线编程页

（4）如图 A-7 所示，官方发布新的赛题后，用户可以参加在线实训比赛。

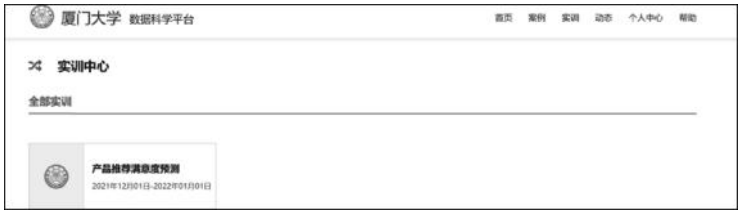

图 A-7　DT 数据科学平台的实训页

实训详情页如图 A-8 所示，用户根据实训比赛的题目要求进行多人在线编程比赛。参赛前，每个人都需要有一支队伍，同时允许单人参加比赛。

图 A-8　DT 数据科学平台的实训详情页

（5）如图 A-9 和图 A-10 所示，数据科学平台还会发布数据科学相关资讯动态，供用户参考和学习。

图 A-9　DT 数据科学平台的动态页

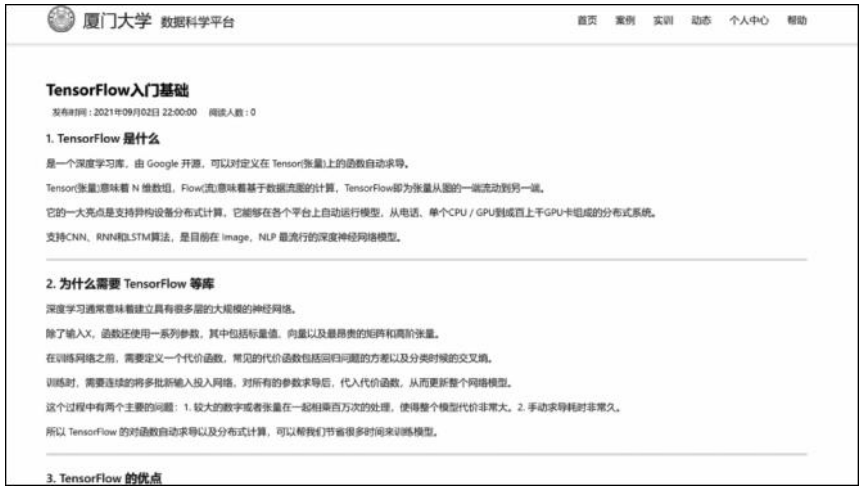

图 A-10　DT 数据科学平台的动态详情页

(6)如图 A-11 和图 A-12 所示，用户的详细个人信息，添加过的所有案例，参加过的所有实训比赛都会在个人中心展示。

图 A-11　DT 数据科学平台的个人信息页

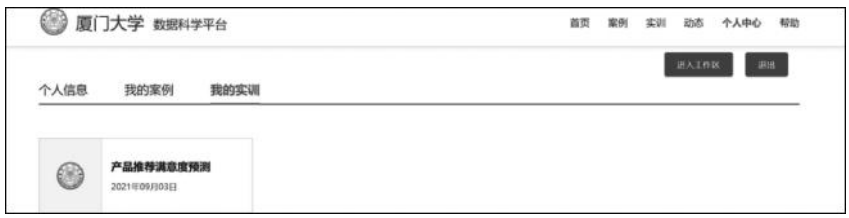

图 A-12　DT 数据科学平台的我的实训页

3. DT 在线案例

(1)StackOverflow 用户调查问卷 EDA。

(2)2021 数字中国大数据竞赛算法题数据清洗。

(3)泰坦尼克号乘客生存预测。

(4)特斯拉股票价格预测。

(5)新浪微博文本数据 EDA。

(6)金融舆情分析。

(7)以客户特征聚类为基础的产品营销。

(8)计算机视觉基础。